DATA SCIENCE & MACHINE LEARNING · PROJET FIL ROUGE

Les déchets des départements français

Prédire la production par habitant (supervisé), puis identifier des profils de départements (non supervisé)

ALVES Rudy · ANTHONY Josselin · BENASSIE Noé · TAVERNIER Florian
iRUP Alternance · Données publiques ADEME et INSEE · github.com/Rxdy/ML-DMA

Sommaire

Partie 1

Explorer : les données et leur thème

Le thème, ce qu'on peut en faire, les sources et leur qualité

Partie 2

Prédire et évaluer

X et Y, modèles, performance, géolocalisation des erreurs

Partie 3

Segmenter : les profils de départements

K-means, choix des variables, interprétation des clusters, PCA, robustesse

Partie 4

Prise de recul : conclusions, limites, pistes

Ce qui manque au modèle, limites, pistes d'amélioration

Partie 1

Explorer : les données et leur thème

Le thème : qu'est-ce qu'on peut faire de ces données ?

Chaque département produit des déchets ménagers et assimilés (DMA) : ordures ménagères, recyclables, déchets verts, encombrants, déchets dangereux. L'ADEME les recense (base SINOE), l'INSEE fournit la population et le revenu.

Prédire

Quelle quantité par habitant à la prochaine enquête ? Apprentissage supervisé : une réponse connue sert d'exemple.

Segmenter

Les départements se ressemblent-ils par ce qu'ils jettent ? Non supervisé : aucune réponse attendue.

Décider

Savoir où l'on se situe pour adapter collecte, tri et compostage.

Quatre sources publiques

Fichier	Producteur	Lignes	Période	Rôle
sinoe_dma	ADEME (SINOE)	14 660	2009–2021	Tonnage par déchet et traitement
sinoe_chiffres_cles_hors_gravats	ADEME (SINOE)	800	2009–2023	Base de la régression
sinoe_chiffres_cles_avec_gravats	ADEME (SINOE)	701	2009–2021	Contrôle des populations, écarté
insee_revenu_median_dep	INSEE (Filosofi)	491	2013–2021	Test du revenu médian

Licence Ouverte 2.0 (data.gouv.fr). Fichiers bruts inclus dans le dépôt : tout se rejoue sans téléchargement.

Exploration : qualité des données et périmètre

- **Aucune valeur manquante, aucun doublon** (lignes identiques et clés répétées vérifiées)
- **Enquête biennale** : années impaires seulement, ce n'est pas un trou à combler
- **Gravats exclus** : ils viennent des chantiers, pas des ménages. Écart-type du ratio : 100,6 kg/hab avec gravats, **80,3 sans**
- **Cible = ratio kg/habitant** : le tonnage est corrélé à 97 % avec la population, le prédire reviendrait à réapprendre une multiplication

Partie 2

Prédire et évaluer

Le problème : X et Y, et un test honnête

Question : peut-on prédire le ratio de déchets par habitant d'un département à la prochaine enquête ?

Rôle	Variables
Y (cible)	ratio DMA en kg/habitant
X	ratio et tonnage de l'enquête précédente, population, profil de traitement (cluster)

- **Découpage dans le temps** : entraînement 2011–2019 (501 lignes), test 2021 et 2023 (198 lignes)
- **Pipeline** (MinMaxScaler, OneHotEncoder) calibrée sur l'entraînement seul : pas de fuite de données

Résultat : aucun modèle ne bat la règle naïve

Modèle (test 2021–2023)	MAE kg/hab	RMSE	R^2
Baseline moyenne	61,99	82,14	−0,010
Baseline naïve (enquête précédente)	36,49	44,58	0,702
Régression linéaire	**35,75**	**43,53**	**0,716**
Arbre de décision	37,04	45,58	0,689
Random Forest	36,08	44,36	0,705

MAE (erreur absolue moyenne)
Moyenne des écarts, en valeur absolue, entre la prédiction et la réalité, en kg/hab. Plus c'est bas, mieux c'est.

RMSE (racine de l'erreur quadratique moyenne)
Même unité que la MAE, mais les grosses erreurs pèsent plus. Plus c'est bas, mieux c'est.

R^2 (coefficient de détermination)
Part de la variation entre départements expliquée par le modèle : 1 = parfait, 0 = pas mieux que la moyenne.

Gain sur la règle naïve : **0,74 kg/hab, soit 2 % de l'erreur**.

Le Random Forest : ce qu'il utilise vraiment

Le principe

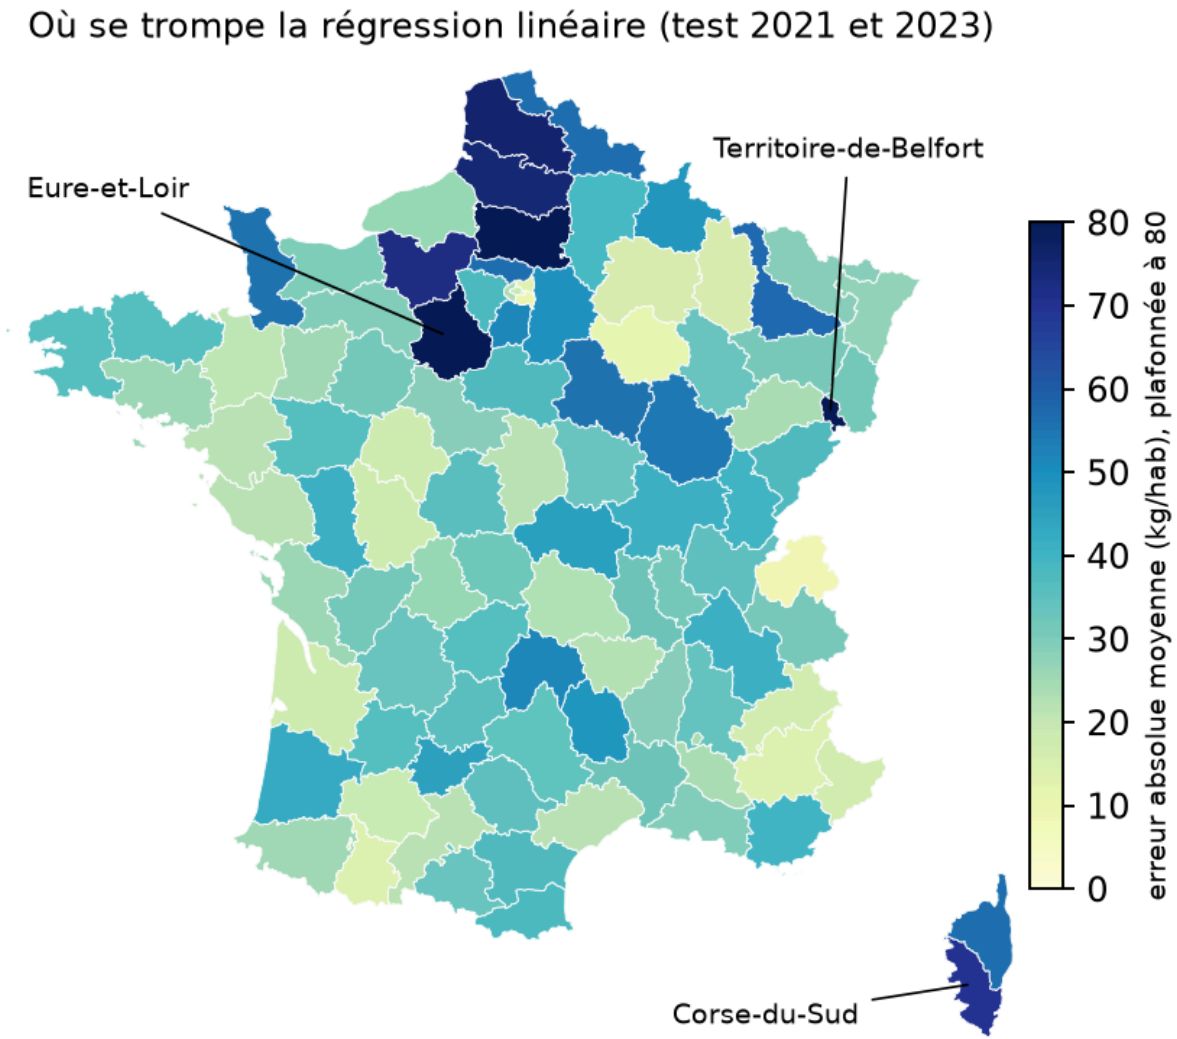
- 300 arbres de décision, de profondeur 6 au plus
- Chaque arbre prédit un ratio, le modèle fait la **moyenne** des 300 prédictions
- L'**importance** d'une variable : sa part dans la baisse d'erreur obtenue par les arbres (le total fait 100 %)

Variable donnée au modèle	Importance
Ratio de l'enquête précédente	**94,9 %**
Tonnage de l'enquête précédente	1,9 %
Population	1,7 %
Profil de traitement (4 clusters)	1,6 %

Les arbres découpent presque toujours selon la valeur précédente : le modèle **recopie** ce que le département produisait déjà, avec de petits ajustements. C'est pour cela qu'il fait presque comme la règle naïve (R^2 de 0,705 contre 0,702).

Où le modèle se trompe : la géographie des erreurs

- Les erreurs ne sont pas réparties au hasard
- **Corse : +51,8 kg/hab** de surestimation moyenne (10 à 15 pour la plupart des régions)
- Hypothèse : les touristes ne sont pas comptés dans la population résidente
- **Eure-et-Loir** et **Territoire-de-Belfort** se distinguent aussi : on y revient en conclusion



Partie 3

Segmenter : les profils de départements

Une autre question

En supervisé : une réponse connue à prédire.
Ici : **aucune réponse**, on cherche des groupes qui se ressemblent.

> **Existe-t-il des profils types de départements selon la façon dont leurs habitants jettent leurs déchets ?**

Le clustering regroupe sur les variables qu'on lui donne : **choisir les variables, c'est décider de ce que « se ressembler » veut dire.**

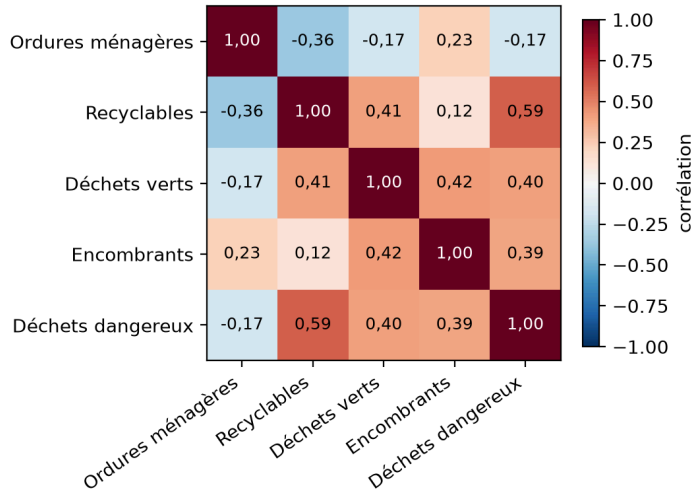
Choix des variables : 5 flux de production

Variable (kg/habitant)	Moyenne	Min	Max
Ordures ménagères résiduelles (OMR)	239	135	459
Matériaux recyclables	132	21	201
Déchets verts et biodéchets	88	1	280
Encombrants	78	35	122
Déchets dangereux	10	0,2	28

- **Production retenue**, traitement écarté : déchets verts et compostage corrélés à 0,71, ce serait compter deux fois la même chose
- **Écartés** : gravats, « autres », total (somme des autres)
- **Gardés pour interpréter** : population, revenu, traitement

Préparer : kg par habitant et standardisation

- **kg/habitant, pas tonnes** : pour comparer Paris et la Lozère
- **Une ligne par département** : moyenne des enquêtes 2019 et 2021 → **100 départements** (Mayotte sans détail)
- **Standardisation** (moyenne 0, écart-type 1) : sans elle, les OMR (~240 kg) pèseraient **24 fois** plus que les déchets dangereux (~10 kg) dans les distances



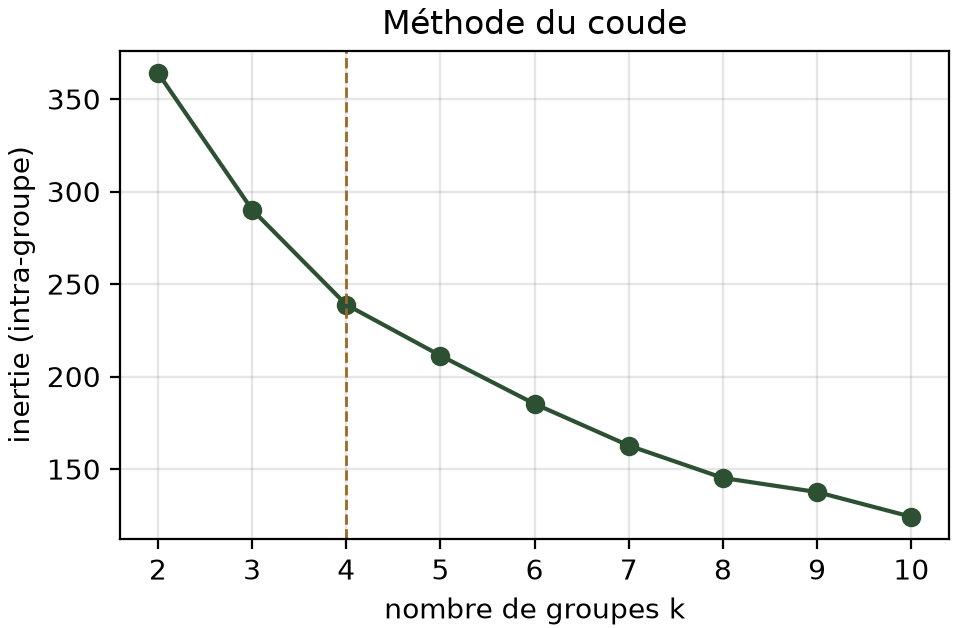
K-means : comment ça marche

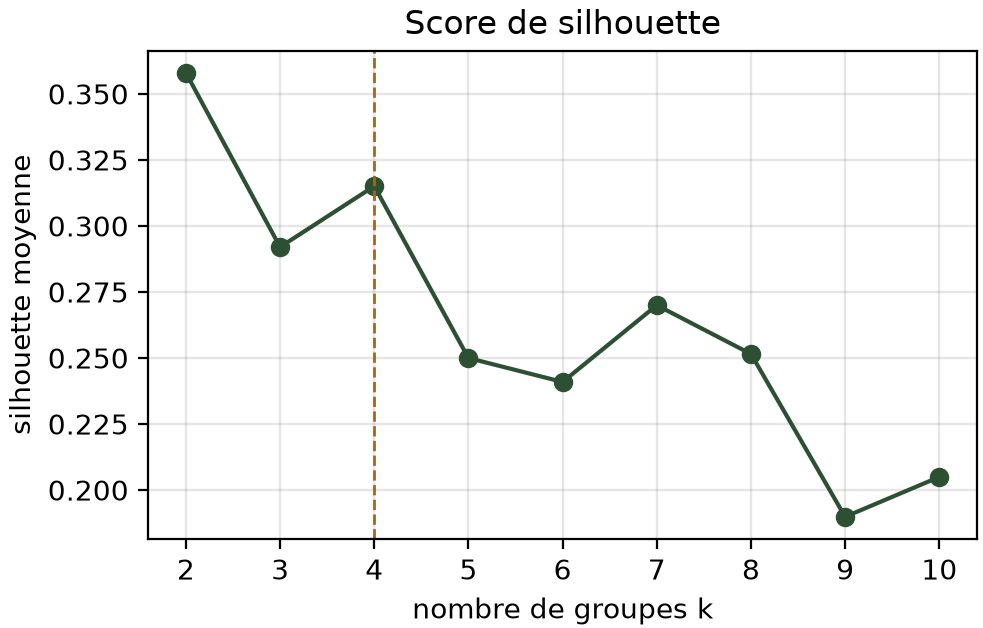
1. **Initialisation** : k centres tirés au hasard
2. **Affectation** : chaque département rejoint le centre le plus proche
3. **Mise à jour** : chaque centre devient la moyenne de son groupe
4. **Itération** jusqu'à stabilité

- **Distance euclidienne** (ligne droite) : d'où la standardisation
- **Inertie (WCSS)** : somme des distances² aux centres. Faible = groupes compacts

Limite	Ce que nous avons fait
Choisir k à l'avance	Coude + silhouette, puis dendrogramme
Dépend du départ aléatoire	20 lancements, graine fixe, stabilité testée sur 10 autres graines
Groupes « arrondis »	Standardisation, DBSCAN en comparaison

Combien de groupes ? Coude et silhouette





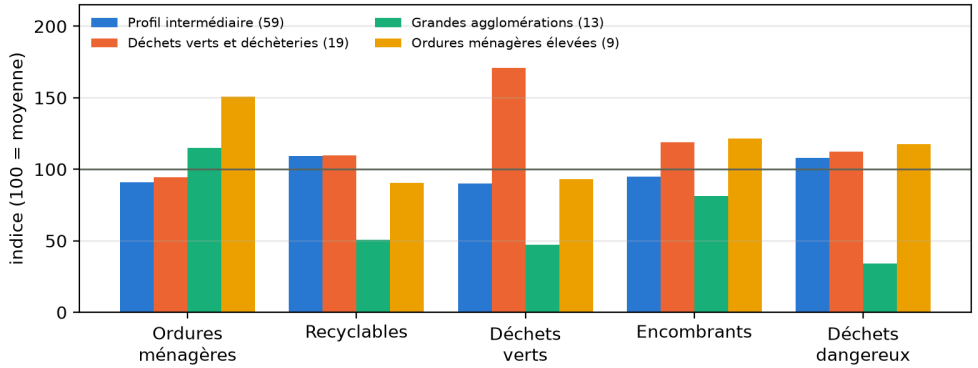
- **Inertie** : baisse toujours, on cherche le coude
- **Silhouette** (−1 à 1) : proche de 1, le département est bien placé ; négatif, il serait mieux ailleurs

Décision : k = 4

k	Inertie	Baisse	Silhouette	Plus petit groupe
2	364	—	0,358	21
3	290	−20 %	0,292	13
4	**239**	**−18 %**	**0,315**	**9**
5	211	−12 %	0,250	10
6	185	−12 %	0,241	1

- **Coude à 4** et pic local de silhouette
- k = 2 : meilleure silhouette mais trop grossier (grandes villes + Méditerranée / reste)
- **k ≥ 6** : un groupe réduit à la Guadeloupe, un cas extrême, pas un profil

Les 4 profils



Groupe	Dép.	OMR	Recyclables	Déchets verts	Encombrants	Dangereux	Total
Profil intermédiaire	59	217	144	80	74	11	528
Déchets verts et déchèteries	19	226	145	151	93	12	629
Grandes agglomérations	13	275	67	42	64	3	456
Ordures ménagères élevées	9	361	120	82	95	12	674

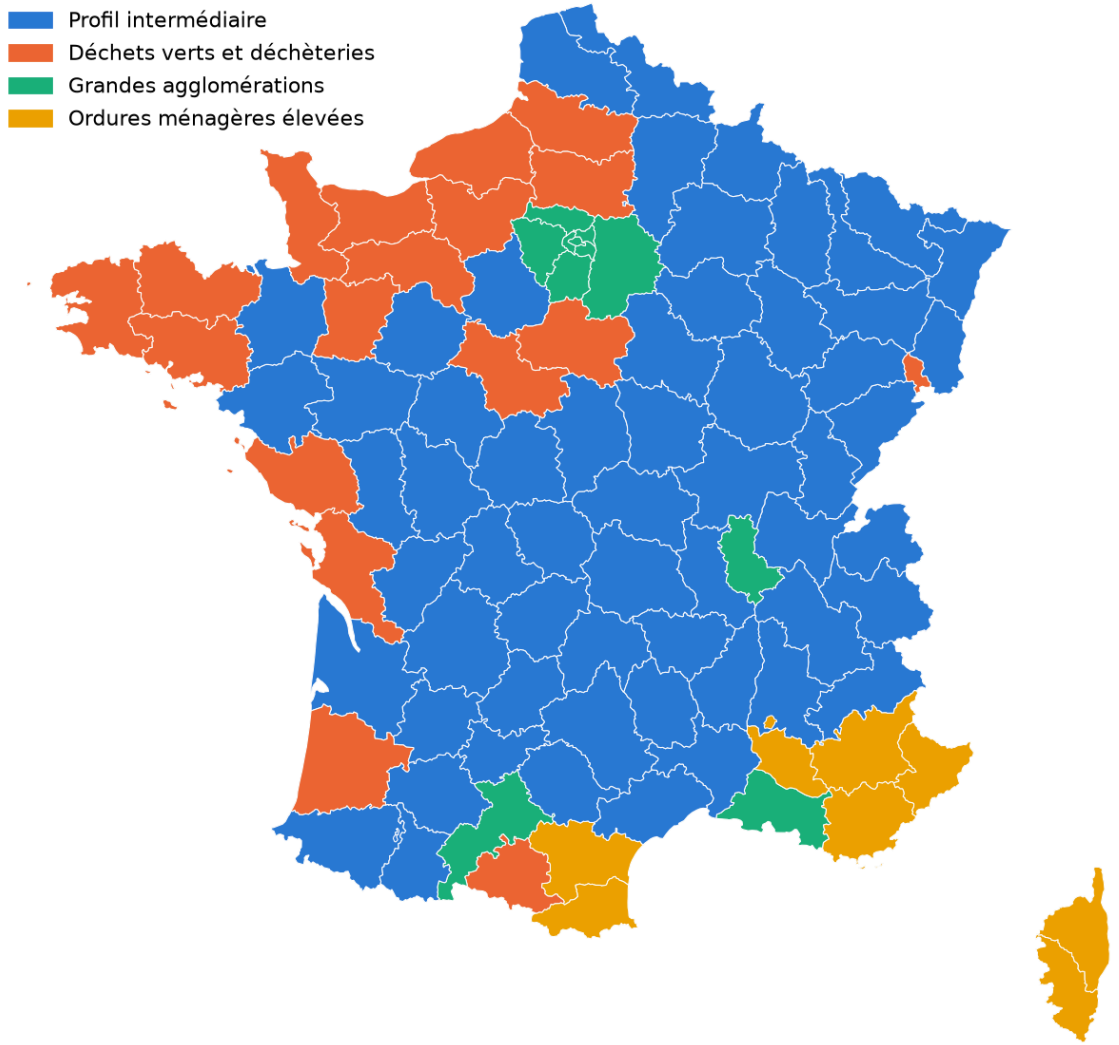
kg par habitant. **OMR** : ordures ménagères résiduelles, la poubelle « classique » (déchets non triés). **Déchets verts** : déchets verts et biodéchets. **Dangereux** : déchets dangereux. Total hors gravats.

Une géographie retrouvée sans donnée géographique

Le modèle n'a reçu **que des kilos de déchets** :
ni région, ni coordonnées.

Les groupes dessinent pourtant :

- le **Grand Ouest**
- les **grandes agglomérations**
- la **Méditerranée et la Corse**
- une **France intermédiaire**



Outre-mer : Guadeloupe (Ordures ménagères élevées) ; Martinique (Grandes agglomérations) ; Guyane (Grandes agglomérations) ; La Réunion (Déchets verts et déchèteries). Mayotte : pas de détail par type de déchet.

Interpréter les groupes

Profil intermédiaire (59)

France « moyenne » : Centre, Est, Massif central. Le plus cohérent (silhouette 0,39).

Déchets verts et déchèteries (19)

Grand Ouest. Verts ×1,7 (151 kg/hab). Compostent le plus (22 %). Hypothèse : maisons avec jardin.

Grandes agglomérations (13)

Île-de-France, Lyon, Marseille, Toulouse. Le moins de déchets (456) mais le moins de tri. Incinèrent le plus (49 %).

Ordures ménagères élevées (9)

Méditerranée et Corse. OMR ×1,5 (361 ; 459 en Corse-du-Sud). Stockage 37 %. Hypothèse : tourisme.

On confronte aux variables non utilisées

Groupe	Population	Revenu médian	Incinération	Stockage	Valorisation organique
Profil intermédiaire	562 000	21 900 €	21 %	22 %	15 %
Déchets verts et déchèteries	592 000	21 700 €	21 %	18 %	**22 %**
Grandes agglomérations	**1 407 000**	**23 000 €**	**49 %**	16 %	9 %
Ordures ménagères élevées	500 000	**20 700 €**	20 %	**37 %**	11 %

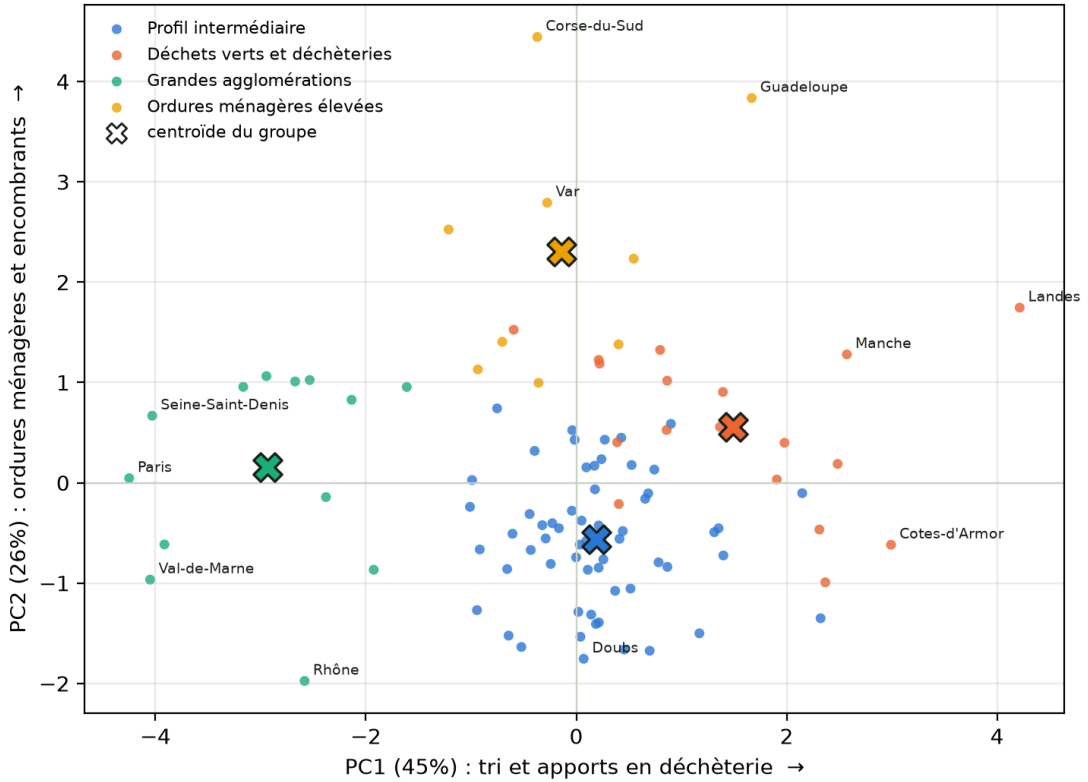
Ces variables **n'ont pas servi** à former les groupes : on évite le raisonnement circulaire. Le traitement suit la production : les groupes qui collectent des déchets verts les compostent.

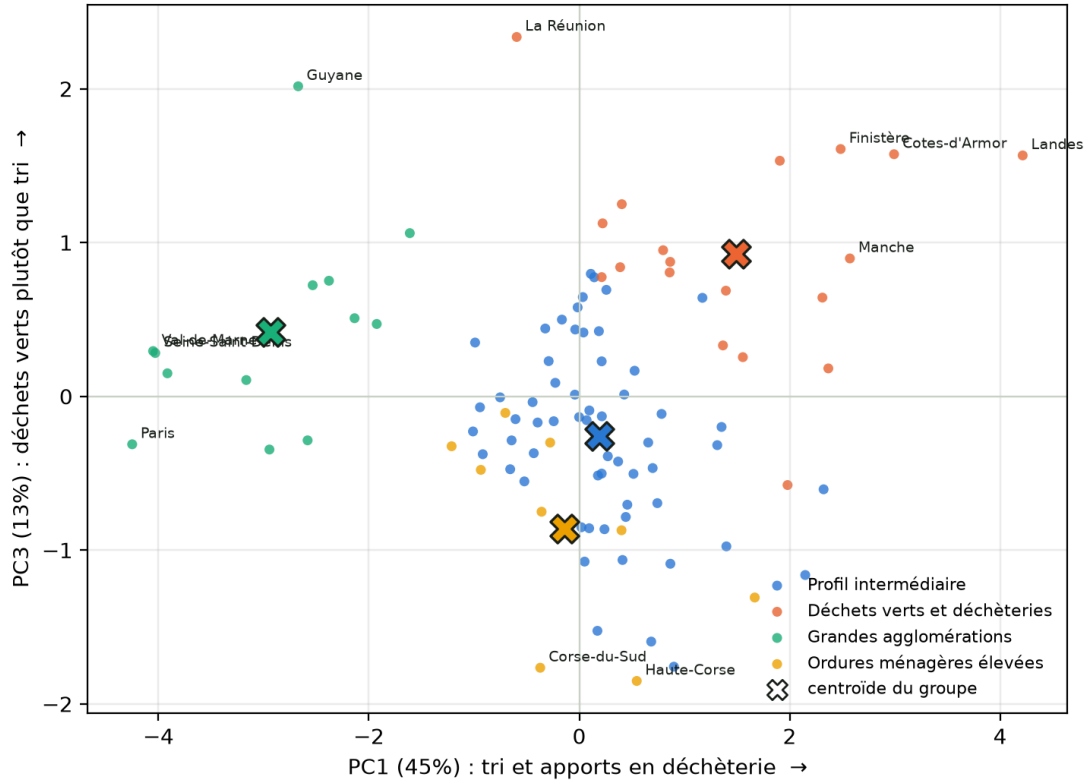
La PCA : réduire de 5 à 3 dimensions

Composante	Valeur propre	Variance	Cumul
PC1	2,27	44,9 %	44,9 %
PC2	1,33	26,3 %	71,3 %
PC3	0,67	13,2 %	**84,4 %**
PC4	0,47	9,2 %	93,7 %

- **3 composantes** : coude de l'éboulis et règle des 80–90 % (84 %)
- **PC1** : le tri et les apports en déchèterie, face à la poubelle ordinaire
- **PC2** : le volume d'ordures ménagères et d'encombrants
- **PC3** : les déchets verts, face au tri des emballages et dangereux

Les groupes sur les axes de la PCA





Chaque groupe occupe sa zone : agglomérations à gauche (peu de tri), Ouest à droite, Méditerranée en haut. **Les groupes ne sont pas un artefact du k-means.**

Les groupes sont-ils solides ?

Essai	ARI avec nos 4 groupes	Silhouette
k-means, 10 autres graines	0,81 à 1,00	0,312 à 0,319
Clustering hiérarchique (Ward)	0,82	0,315
k-means sans l'outre-mer	0,65	0,291
Clustering du traitement (supervisé)	0,006	—

- **Stables** d'une graine à l'autre : seule la frontière « déchets verts » bouge
- Sans l'outre-mer : les **cœurs** restent, les **frontières** se déplacent
- ARI 0,006 : production et traitement sont **indépendants**, ils ne devaient pas être mélangés

ARI (indice de Rand ajusté)
Compare deux découpages en groupes : 1 = exactement les mêmes groupes, environ 0 = pas plus de points communs qu'un découpage fait au hasard.

Silhouette
Mesure si chaque département est bien placé dans son groupe : proche de 1, bien placé ; proche de 0, à la frontière ; négatif, mieux dans un autre groupe.

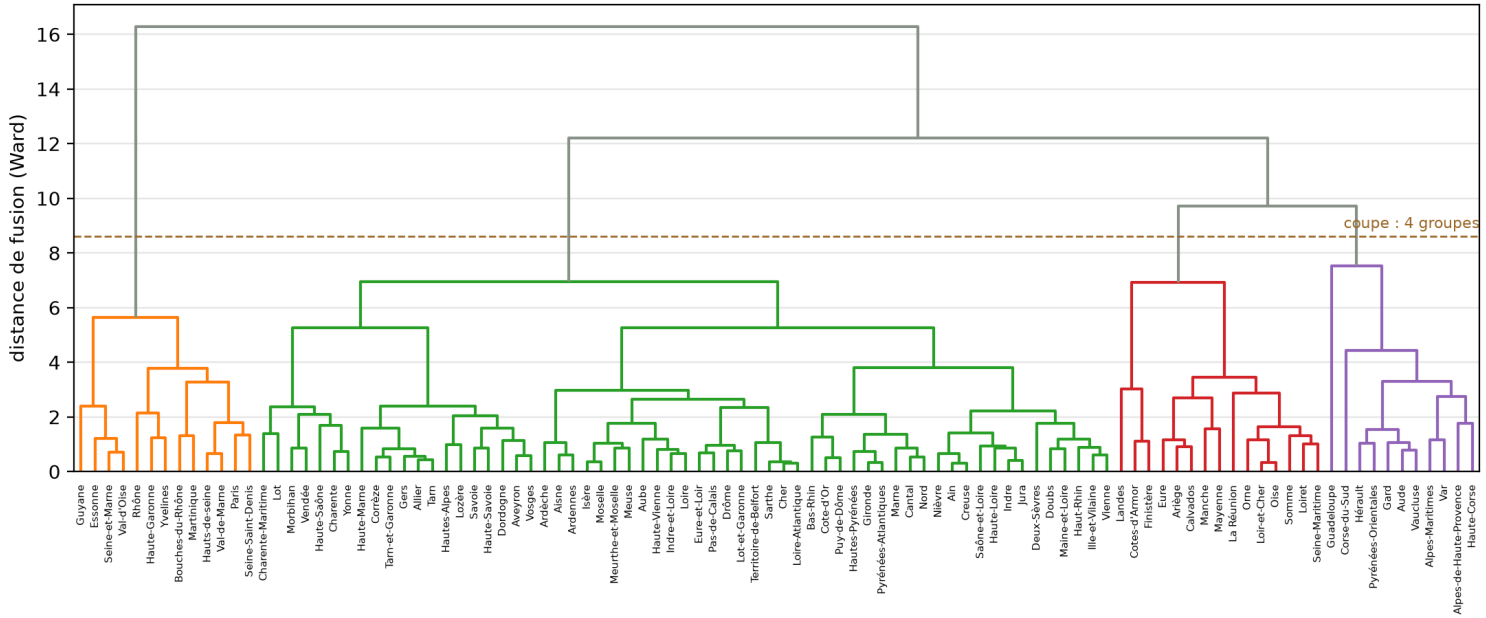
Deux autres méthodes : hiérarchique et DBSCAN

Clustering hiérarchique (Ward)

Grands sauts de hauteur jusqu'à 4 groupes (4,07 → 2,50 → 2,19), puis effondrement (0,58 → 0,02) : **4 est la coupe la plus fine qui ait un sens.**

DBSCAN (MinPts = 10, ε = 2,53)

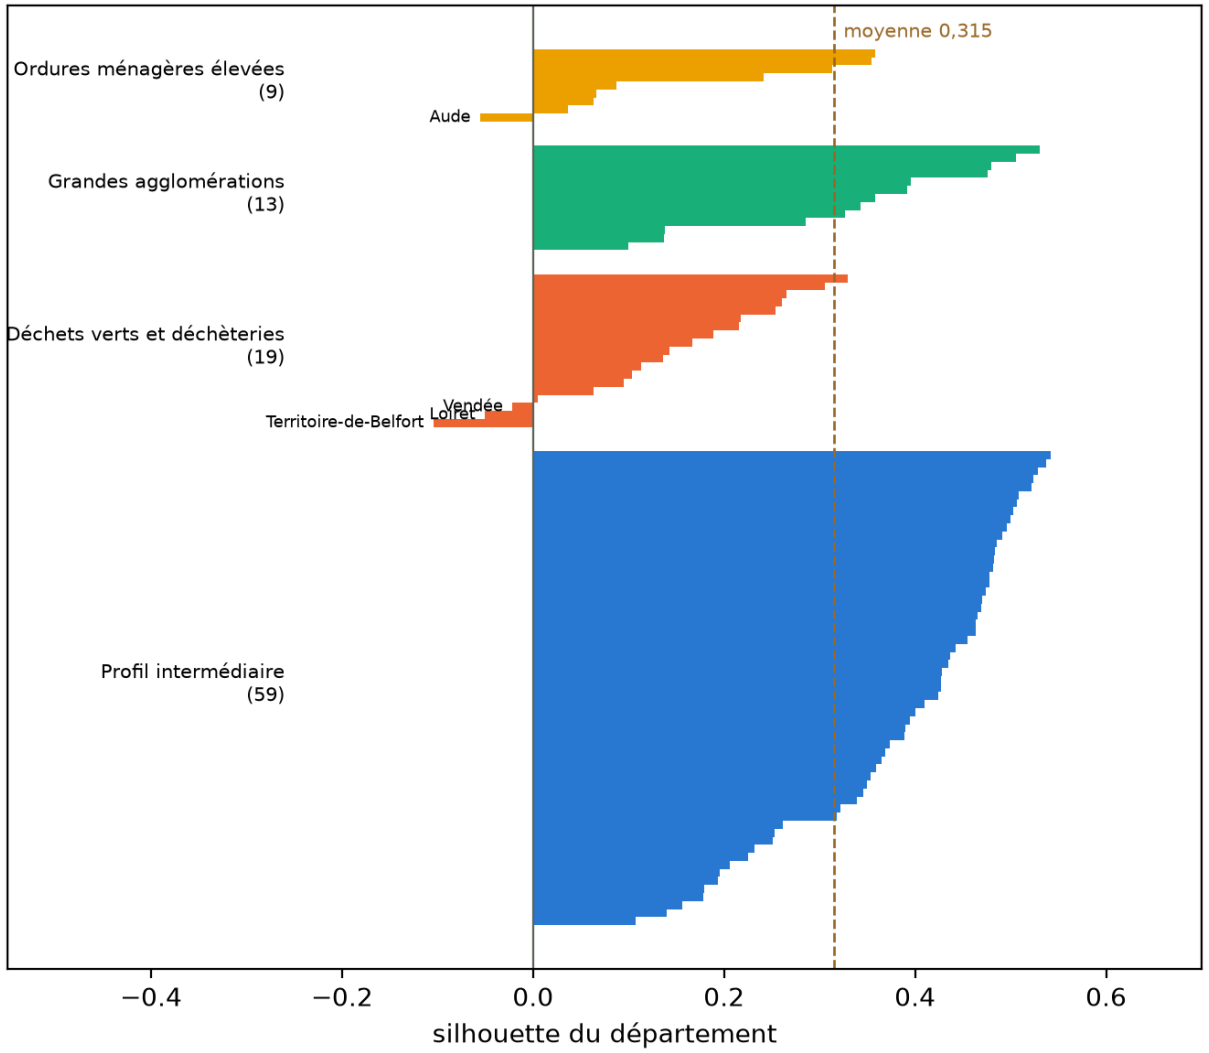
Un seul groupe dense et 2 points de bruit : **Landes** et **Guadeloupe**. Les départements forment un **continuum**, pas des îlots.



Où les groupes sont fragiles

- Cohérents : intermédiaire (**0,39**) et agglomérations (**0,34**)
- Fragiles : déchets verts (**0,14**) et OMR élevées (**0,16**)
- **4 cas frontières** (silhouette négative) : Aude, Loiret, Vendée, Territoire-de-Belfort

À ne pas sur-interpréter.



Partie 4

Prise de recul : conclusions, limites, pistes

Ce qu'il faut retenir

- **Supervisé** : prédire revient presque à recopier l'enquête précédente (R^2 0,716 contre 0,702)
- **Non supervisé** : **4 profils** de départements, géographiques, retrouvés sans coordonnées
- Deux facteurs semblent structurer la carte : **le type d'habitat** et **le tourisme** (hypothèses)
- Les profils expliquent **pourquoi** les niveaux diffèrent durablement ; la prédiction montre que ces niveaux **bougent peu**
- **Aucun profil n'est « meilleur »** : les agglomérations produisent le moins mais trient le moins ; l'Ouest produit beaucoup mais composte

Ce qui manque au modèle : une information nationale

	2021	2023
Évolution moyenne des départements	+21,5 kg/hab	−43,8 kg/hab
Départements en baisse	11 %	97 %
Erreur du modèle	−22	+43

Tous les départements se trompent **dans le même sens** : l'erreur est **commune**, pas locale. Il manque une valeur **nationale qui change d'une année à l'autre** (inflation, pouvoir d'achat, consommation).

Si on connaissait l'évolution nationale : **MAE 36,5 → 19,9, R^2 0,70 → 0,88** (plafond théorique, inconnue à l'avance).

Hypothèse et cas à vérifier

Hypothèse : le pouvoir d'achat. Les prix ont fortement augmenté en 2022–2023 : moins d'achats, moins de déchets, partout. Non vérifiable avec nos données : le revenu médian INSEE s'arrête en 2021 et ignore les prix.

Eure-et-Loir et Territoire-de-Belfort : les plus grosses erreurs (123 et 110 kg/hab).

Ratio (kg/hab)	2019	2021	2023
Eure-et-Loir	513	609	454
Territoire-de-Belfort	502	603	479
Oise (comparaison)	559	607	492

Ces deux séries s'écartent plus que les autres, **sans preuve d'erreur** : à vérifier à la source.

Limites

Supervisé

- 8 enquêtes seulement, une tous les 2 ans
- Variables trop stables pour expliquer un changement
- Rupture 2021–2023 de cause inconnue : Covid, consignes de tri, pouvoir d'achat sont des **hypothèses**
- Périmètres légèrement différents : gravats inclus dans le clustering de traitement, exclus de la cible

Non supervisé

- Structure modérée (silhouette 0,315) : un seul nuage pour DBSCAN
- 2 groupes fragiles, 4 départements frontières
- Sensible aux valeurs extrêmes et à l'outre-mer (ARI 0,65 sans)
- Une photo 2019–2021, pas un film
- Explications (habitat, tourisme) = **hypothèses**

Pistes d'amélioration

Dans le temps
Données **mensuelles** : 12 points par an, ruptures et saisonnalité touristique.

Dans l'espace
Données **par ville** : lien avec la taille de la ville, écarts au sein d'un département.

Par zone
Chaque ville rattachée à sa zone et son département : on retrouve le compte rendu départemental.

Le prix à payer : ces données n'existent pas dans les bases publiques. Il faut davantage de moyens (recueil mensuel auprès de chaque collectivité, format commun). Bénéfice : meilleure gestion des déchets et vue sur les écarts entre territoires.

Piste prioritaire : ajouter une série nationale (inflation, pouvoir d'achat). **Ensuite :** variables INSEE logement et tourisme, tarification incitative.

Merci de votre attention

Avez-vous des questions ?