

Machine learning : Déchets

Clustering : des profils de départements selon ce que leurs habitants jettent

MEMBRES DU GROUPE

ALVES Rudy

ANTHONY Josselin

BENASSIE Noé

TAVERNIER Florian

DATE

24 septembre 2026

DÉPÔT GITHUB

github.com/Rxdy/ML-DMA

Données : ADEME (SINOE) et INSEE, data.gouv.fr, licence Ouverte 2.0

Sommaire

Introduction	3
1. Du supervisé au non supervisé	4
2. Les données de départ	5
3. Choisir les variables	6
4. Les corrélations entre les variables	7
5. Préparer les données	8
6. Réduire la dimension : la PCA	9
7. L'algorithme k-means	15
8. Choisir le nombre de groupes	17
9. Les 4 groupes	19
10. Clustering hiérarchique et dendrogramme	22
11. DBSCAN : un clustering par densité	24
12. Qualité et solidité des groupes	27
13. Synthèse des méthodes	29
14. Problèmes rencontrés et conclusion	30
Glossaire	31
Annexe A. Détail des calculs	33
Annexe B. Guide d'utilisation	35

Introduction

Ce rapport est la suite du rapport sur l'apprentissage supervisé. Il reprend les **mêmes données** (ADEME / SINOE et INSEE), mais change de question : il ne s'agit plus de prédire une valeur connue, mais de **découvrir des groupes** de départements qui se ressemblent. Comme le premier, il suit l'ordre dans lequel nous avons pris nos décisions, et explique pour chacune ce que nous avons fait et pourquoi.

La question posée : existe-t-il des profils types de départements selon la façon dont leurs habitants jettent leurs déchets ?

Le résultat en trois phrases

Les 100 départements se répartissent en **4 profils** : une France intermédiaire, un Ouest des déchets verts, les grandes agglomérations qui trient peu, et la Méditerranée aux ordures ménagères élevées. Ces profils forment une carte cohérente alors qu'aucune information géographique n'a été donnée au modèle, et trois méthodes (k-means, clustering hiérarchique, lecture des composantes principales PC1 et PC2) les confirment. DBSCAN montre en revanche que les départements forment un continuum plutôt que des îlots séparés : ces profils sont des tendances, pas des catégories étanches.

Le code est disponible sur le dépôt github.com/Rxdy/ML-DMA (scripts 12_clustering_production.py, 13_clustering_analyses.py et 14_clustering_hierarchique_dbscan.py).

Chronologie en un coup d'œil

Étape	Ce qui a été fait	Script
1	Passer du supervisé au non supervisé : la question	—
2	Les données de départ : une ligne par département	12
3	Choisir les variables qui définiront les groupes	12
4	Étudier les corrélations entre ces variables	13
5	Préparer les données : kg par habitant, standardisation	12
6	Réduire la dimension : la PCA (PC1, PC2, PC3)	13
7	Comprendre le k-means : distance, inertie, étapes	12
8	Choisir le nombre de groupes : coude et silhouette	12
9	Décrire et interpréter les 4 groupes	12
10	Comparer : clustering hiérarchique et dendrogramme	14
11	Comparer : DBSCAN, un clustering par densité	14
12	Vérifier la qualité et la solidité des groupes	13
13	Synthèse des méthodes	—

ÉTAPE 1 · 24 septembre 2026

1. Du supervisé au non supervisé

En apprentissage **supervisé**, chaque exemple a une réponse connue (y) : le modèle apprend à la retrouver à partir des entrées (X). En apprentissage **non supervisé**, il n'y a pas de y . Le modèle reçoit seulement X et cherche une structure dans les données : ici, des groupes d'éléments proches les uns des autres. C'est le **clustering**.

	Supervisé (premier rapport)	Non supervisé (ce rapport)
Question	Combien de kg par habitant à la prochaine enquête ?	Quels types de départements existe-t-il ?
Données	X et y	X seulement
Une ligne =	un département à une date	un département
Modèles	régression linéaire, arbre, Random Forest	k-means (et Ward pour comparaison)
Évaluation	comparer les prédictions aux vraies valeurs (MAE, R^2)	pas de « bonne réponse » : mesurer la cohésion des groupes (inertie, silhouette) et leur stabilité

Le non supervisé regroupe deux grandes familles de méthodes, toutes deux utilisées dans ce rapport :

- le **clustering**, pour regrouper les données similaires : k-means (chapitres 7 à 9), clustering hiérarchique (chapitre 10) et DBSCAN (chapitre 11) ;
- la **réduction de dimension**, pour simplifier la représentation des données tout en préservant l'information essentielle : la PCA (chapitre 6).

Ce que change l'absence de réponse attendue

Il n'existe pas de « bon » clustering à retrouver. Un clustering est utile s'il forme des groupes compacts, bien séparés, stables, et surtout **interprétables**. C'est pourquoi le choix des variables et l'interprétation comptent autant que l'algorithme.

ÉTAPE 2 · 24 septembre 2026

2. Les données de départ

Nous repartons du fichier principal de l'ADEME, `sinoe_dma.csv`, qui détaille pour chaque département et chaque enquête le tonnage de 7 types de déchets, et du fichier « chiffres-clés hors gravats » pour la population. Les contrôles faits dans la partie supervisée restent valables : aucune valeur manquante, aucun doublon, jointure validée sur la clé département × année.

Une ligne par département

Le clustering compare des départements : il lui faut **une seule ligne par département**. Or les données ont une ligne par département et par enquête. Nous avons retenu la **moyenne des enquêtes 2019 et 2021** :

- ce sont les deux enquêtes les plus récentes détaillées par type de déchet (le détail s'arrête en 2021) ;
- faire la moyenne de deux enquêtes lisse les variations ponctuelles, comme les allers-retours observés dans la partie supervisée.

Résultat : **100 départements**. Mayotte est absente, faute de détail par type de déchet.

ÉTAPE 3 · 24 septembre 2026

3. Choisir les variables

Le clustering regroupe les départements qui se ressemblent **sur les variables qu'on lui donne**. Choisir les variables, c'est décider de ce que « se ressembler » veut dire. C'est l'étape la plus importante.

Trois familles possibles

Famille	Variables	Ce qu'elles décrivent
Production	kg par habitant de chaque type de déchet	ce que les habitants jettent
Traitement	part incinérée, stockée, recyclée, compostée	ce que le territoire fait de ses déchets
Contexte	population, revenu médian	qui est le territoire

Nous avons retenu la **production**, pour deux raisons :

- le traitement a déjà été clusterisé dans la partie supervisée (annexe A du premier rapport) ;
- mélanger production et traitement compterait deux fois la même information. Les départements qui collectent beaucoup de déchets verts sont aussi ceux qui en compostent beaucoup (corrélation de 0,71), et ceux qui collectent beaucoup de recyclables en recyclent beaucoup (0,63).

Le traitement et le contexte ne sont pas perdus : ils servent de **variables illustratives**. Ils ne participent pas à la formation des groupes, mais aident à les interpréter ensuite.

Les 5 variables retenues

Variable (kg par habitant)	Moyenne	Minimum	Maximum
Ordures ménagères résiduelles	239	135,1	459
Matériaux recyclables	132	20,5	201
Déchets verts et biodéchets	88	0,6	280
Encombrants	78	35,3	122
Déchets dangereux	10	0,2	28

Ce qui a été écarté

Écarté	Raison
Déblais et gravats	Ils viennent surtout des chantiers, pas des habitants (même choix qu'en supervisé)
« Autres »	Catégorie presque vide et très irrégulière : son écart-type vaut 1,85 fois sa moyenne
Total de déchets par habitant	C'est la somme des autres : il ferait doublon
Population, revenu, traitement	Gardés comme variables illustratives, pour interpréter

ÉTAPE 4 · 24 septembre 2026

4. Les corrélations entre les variables

Avant de regrouper, on regarde comment les 5 variables évoluent ensemble. Deux variables très corrélées (au-delà de 0,8) porteraient presque la même information et pèseraient deux fois ; il faudrait alors en retirer une.




Figure 1 — Corrélations entre les 5 variables (de -1 à 1).

Paire de variables	Corrélation	Lecture
Recyclables Déchets dangereux	0,59	Les départements qui trient leurs emballages apportent aussi leurs déchets dangereux en déchèterie
Déchets verts Encombrants	0,42	Deux déchets apportés en déchèterie : ils montent ensemble
Recyclables Déchets verts	0,41	Même logique d'apport volontaire
Ordures ménagères Recyclables	-0,36	Ce qui n'est pas trié finit dans la poubelle ordinaire

Ce que ça montre

Aucune corrélation ne dépasse 0,6 : les 5 variables apportent chacune une information propre, on peut toutes les garder. Deux logiques se dessinent déjà : le **tri et les apports en déchèterie** (recyclables, dangereux, verts, encombrants montent ensemble) d'un côté, la **poubelle ordinaire** de l'autre, qui baisse quand le tri augmente.

ÉTAPE 5 · 24 septembre 2026

5. Préparer les données

Des kg par habitant, pas des tonnes

En tonnes, les départements les plus peuplés écraseraient tout : Paris ressemblerait aux Bouches-du-Rhône simplement parce qu'ils ont beaucoup d'habitants. Diviser par la population permet de comparer les comportements.

Standardiser

Le k-means regroupe les départements proches au sens de la **distance**. Or les ordures ménagères (environ 240 kg) et les déchets dangereux (environ 10 kg) n'ont pas la même échelle : sans précaution, un écart de 10 kg d'ordures ménagères compterait autant qu'un écart de 10 kg de déchets dangereux, qui est pourtant énorme pour eux. Les ordures ménagères décideraient seules des groupes. On standardise donc chaque variable (`StandardScaler`) :

$$z = (x - \mu) / \sigma$$

Symbole	Signification
x	valeur d'origine (en kg par habitant)
μ (« mu »)	moyenne de la variable sur les 100 départements
σ (« sigma »)	écart-type : l'écart moyen à la moyenne
z	valeur standardisée : de combien d'écart-types le département s'écarte de la moyenne

Exemple : les Landes collectent 280 kg de déchets verts par habitant. Avec $\mu = 88,4$ et $\sigma = 42,0$, $z = (279,7 - 88,4) / 42,0 = 4,55$: les Landes sont à 4,6 écarts-types au-dessus de la moyenne. Après standardisation, chaque variable a une moyenne de 0 et un écart-type de 1 : elles pèsent toutes autant.

Pourquoi `StandardScaler` et pas `MinMaxScaler` ?

En supervisé, nous avons ramené les variables entre 0 et 1 (`MinMaxScaler`). Ici, un département extrême (les Landes pour les déchets verts) fixerait à lui seul le maximum et tasserait tous les autres près de 0. La standardisation est moins sensible à un seul extrême, et c'est la préparation habituelle avant un k-means.

À la fin de cette étape, X est un tableau de **100 lignes × 5 colonnes**, sans y.


ÉTAPE 6 · 24 septembre 2026

6. Réduire la dimension : la PCA

Chaque département est un point dans un espace à 5 dimensions, impossible à dessiner. Plus il y a de dimensions, plus les données sont difficiles à visualiser et à interpréter : c'est le « fléau de la dimensionnalité ». La réduction de dimension répond à ce problème.

Première approche : les nuages de points, deux variables à la fois

La matrice ci-dessous croise chaque paire de variables (visualisation 2D). Chaque point est un département, coloré selon le groupe qu'il recevra à l'étape 9. Sur la diagonale, la distribution de chaque variable.



Les groupes se séparent déjà en partie (les agglomérations en bas des recyclables et des déchets verts, la Méditerranée en haut des ordures ménagères), mais aucune paire ne sépare à elle seule les 4 groupes : il faut une vue qui résume les 5 dimensions à la fois. C'est le rôle de la PCA.

La PCA (ACP), étape par étape

L'**analyse en composantes principales** (PCA en anglais, ACP en français) transforme les 5 variables, corrélées entre elles, en 5 nouvelles variables non corrélées : les **composantes principales**, notées **PC1, PC2, PC3...** (*Principal Component*). PC1 capte le plus possible des différences entre départements, PC2 le plus possible de ce qui reste, et ainsi de suite. Nous avons suivi les 5 étapes du cours :

Étape du cours	Ce que nous avons fait
1. Standardisation des données	Déjà faite au chapitre 5 : chaque variable a une moyenne de 0 et un écart-type de 1.
2. Calcul de la matrice de covariance	Sur des données standardisées, la matrice de covariance est exactement la matrice de corrélation du chapitre 4 : vérifié par le script.
3. Vecteurs propres et valeurs propres	Chaque vecteur propre donne la direction d'une composante ; sa valeur propre, la quantité d'information (variance) qu'elle porte.
4. Sélection des composantes principales	Tri par valeur propre décroissante, puis choix du nombre de composantes avec l'éboulis et la règle des 80-90 %.
5. Projection des données	Chaque département reçoit des coordonnées sur PC1, PC2, PC3 : on peut le dessiner.

Valeurs propres et choix du nombre de composantes

Composante	Valeur propre	Part de la variance	Part cumulée
PC1	2,269	44,9%	44,9%
PC2	1,330	26,3%	71,3%
PC3	0,666	13,2%	84,4%
PC4	0,465	9,2%	93,7%
PC5	0,320	6,3%	100,0%




Figure 3 — Éboulis des valeurs propres (barres) et part cumulée de la variance (courbe) ; pointillé : seuil de 80 %.

La somme des valeurs propres vaut 5, le nombre de variables : chaque variable standardisée apporte une unité de variance. Le cours propose deux critères :

- **le coude de l'éboulis** : la chute est forte de PC1 à PC3, puis la courbe s'aplatit ;

- **la règle des 80–90 %** : il faut **3 composantes** pour dépasser 80 % (84% de l'information).

Décision : 3 composantes, et PC1-PC2 pour les dessins

Nous retenons **PC1, PC2 et PC3** (84% de l'information) pour interpréter les données. Pour les graphiques, le plan PC1-PC2 montre déjà 71% de l'information ; il est complété par le plan PC1-PC3 pour ne pas perdre la troisième dimension.

Donner un sens aux composantes : les chargements

Un **chargement** est la corrélation entre une variable d'origine et une composante (vecteur propre $\times$ racine de la valeur propre). Il indique l'importance et le sens de la contribution de chaque variable. Les vecteurs propres bruts sont donnés en annexe A.

Variable	PC1	PC2	PC3
Ordures ménagères résiduelles	-0,35	0,81	-0,30
Matériaux recyclables	0,79	-0,33	-0,28
Déchets verts et biodéchets	0,75	0,16	0,55
Encombrants	0,52	0,74	0,11
Déchets dangereux	0,83	0,05	-0,42

- **PC1 (45%) : le tri et les apports en déchèterie.** Recyclables, déchets dangereux, déchets verts et encombrants y sont fortement positifs, les ordures ménagères négatives. À droite, les départements qui trient et apportent en déchèterie ; à gauche, ceux où tout va dans la poubelle ordinaire.
- **PC2 (26%) : le volume d'ordures ménagères et d'encombrants.** En haut, les départements qui jettent beaucoup, indépendamment du tri.
- **PC3 (13%) : les déchets verts plutôt que le tri.** Les déchets verts y sont positifs, les déchets dangereux, recyclables et ordures ménagères négatifs. Elle distingue, à niveau de tri égal, les territoires où ce qui est apporté est surtout végétal.

Le cercle des corrélations

Chaque flèche est une variable : sa direction indique la composante à laquelle elle est liée, sa longueur la qualité de sa représentation sur le plan (1 = parfaite).




Figure 4 — Cercle des corrélations sur le plan PC1-PC2.

Projection des départements

Chaque point est un département, coloré par groupe (étape 9) ; les croix sont les **centroïdes** des groupes, c'est-à-dire leur point moyen, projeté de la même façon.




Figure 5 — Les 100 départements sur le plan PC1-PC2, avec les centroïdes des 4 groupes.

Paris et la petite couronne sont à l'extrême gauche (peu de tri), les Landes et la Bretagne à l'extrême droite (beaucoup de tri et de déchets verts), la Corse-du-Sud et la Guadeloupe tout en haut (beaucoup d'ordures ménagères). Les centroïdes sont bien séparés : chaque groupe occupe sa zone du plan.




Figure 6 — Les départements sur le plan PC1-PC3.

PC3 sépare nettement deux groupes que PC2 rapprochait : l'Ouest des déchets verts (en haut) et la Méditerranée (en bas, où la Corse a peu de déchets verts pour beaucoup d'ordures ménagères). La Réunion et la Guyane, en haut, collectent surtout du végétal pour peu de tri des emballages.

ÉTAPE 7 · 24 septembre 2026

7. L'algorithme k-means

Deux notions fondamentales

La **distance** mesure la dissimilarité entre deux départements. Le cours en présente deux :

Distance euclidienne (la ligne droite) : $d(x, y) = \sqrt{\sum (x_i - y_i)^2}$
 Distance de Manhattan (la somme des écarts) : $d(x, y) = \sum |x_i - y_i|$

Symbole	Signification
x, y	deux départements, chacun décrit par ses 5 valeurs standardisées
x_i, y_i	leur valeur sur la variable i ($i = 1$ à 5)
$\sum$	somme sur les 5 variables
$ \dots , \sqrt{}$	valeur absolue, racine carrée

Le k-means utilise la **distance euclidienne** : c'est elle qui définit « le centroïde le plus proche ». C'est aussi pour cela qu'il fallait standardiser : une distance additionne des écarts, qui doivent être exprimés dans la même unité.

L'**inertie**, aussi appelée **WCSS** (*Within-Cluster Sum of Squares*, somme des carrés intra-cluster), mesure la compacité des groupes : la somme des distances au carré entre chaque département et le centroïde de son groupe. Une faible inertie indique des groupes denses et bien définis.

$$\text{Inertie (WCSS)} = \sum_k \sum_{x \in C_k} \|x - c_k\|^2$$

Symbole	Signification
k	numéro du groupe
C_k	l'ensemble des départements du groupe k
c_k	le centroïde du groupe k : la moyenne de ses départements
$\ x - c_k\ $	la distance euclidienne entre le département x et le centroïde de son groupe

Les 4 étapes de l'algorithme

Étape	Ce que fait l'algorithme
1. Initialisation	Choisir aléatoirement k centroïdes initiaux
2. Affectation	Chaque département rejoint le groupe dont le centroïde est le plus proche
3. Mise à jour	Chaque centroïde est recalculé comme la moyenne des départements de son groupe
4. Itération	Répéter 2 et 3 jusqu'à ce que plus rien ne bouge (convergence)

Avantages et limites, et comment nous les avons traitées

Limite du k-means (cours)	Ce que nous avons fait
Il faut choisir k à l'avance	Méthode du coude et score de silhouette (chapitre 8), puis dendrogramme (chapitre 10)
Sensible aux centroïdes initiaux	20 lancements par k (<code>n_init=20</code>), on garde la plus faible inertie ; graine fixe (<code>random_state=42</code>) ; stabilité vérifiée sur 10 autres graines (chapitre 12)
Suppose des groupes « sphériques »	Standardisation pour que toutes les directions pèsent pareil ; DBSCAN, qui n'a pas cette hypothèse, testé en comparaison (chapitre 11)

Ses avantages, simplicité et rapidité, jouent pleinement ici : 100 départements et 5 variables se traitent en une fraction de seconde, ce qui permet de tester k de 2 à 10 et de nombreux tirages.

ÉTAPE 8 · 24 septembre 2026

8. Choisir le nombre de groupes

Nous avons lancé le k-means pour $k = 2$ à 10 et regardé deux indicateurs.

La méthode du coude

L'inertie baisse toujours quand on ajoute des groupes : avec autant de groupes que de départements, elle vaudrait 0. On cherche le **coude**, le point à partir duquel ajouter un groupe n'apporte plus grand-chose.

Le score de silhouette

Pour chaque département, on compare sa distance moyenne aux membres de son groupe (a) et sa distance moyenne aux membres du groupe voisin le plus proche (b) :

$$s = (b - a) / \max(a, b)$$

Symbole	Signification
a	distance moyenne aux autres membres de son groupe : la cohésion
b	distance moyenne aux membres du groupe voisin le plus proche : la séparation
$\max(a, b)$	la plus grande des deux, pour ramener s entre -1 et 1
s	proche de 1 : bien dans son groupe ; proche de 0 : à la frontière ; négatif : mieux ailleurs

Le score de silhouette d'un clustering est la moyenne des s de tous les départements.




Figure 7 — Méthode du coude (à gauche) et score de silhouette (à droite) selon le nombre de groupes.

k	Inertie	Baisse de l'inertie	Silhouette	Plus petit groupe
2	364	—	0,358	21.0 départements
3	290	−20 %	0,292	13.0 départements
4	239	−18 %	0,315	9.0 départements
5	211	−12 %	0,250	10.0 départements
6	185	−12 %	0,241	1.0 département
7	163	−12 %	0,270	1.0 département
8	145	−11 %	0,252	1.0 département
9	138	−5 %	0,190	1.0 département
10	124	−10 %	0,205	1.0 département

Lecture

- **Le coude est à k = 4.** Passer à 3 puis à 4 groupes réduit l'inertie de 20 % puis 18 %. Au-delà, chaque groupe ajouté ne la réduit plus que de 10 à 12 %.
- **La silhouette est la plus haute à k = 2 (0,358)**, puis présente un pic à **k = 4 (0,315)**, mieux que 3 et que 5.
- **À partir de k = 6, un groupe ne contient plus que la Guadeloupe.** Le k-means isole alors un cas extrême au lieu de former un profil : ces valeurs de k sont à écarter.

Décision : k = 4

k = 2 a la meilleure silhouette, mais il se contente de séparer « les grandes villes et la Méditerranée » du reste de la France : trop grossier pour apprendre quelque chose. **k = 4 est le seul point où les deux méthodes s'accordent** (coude et pic de silhouette), sans groupe réduit à un seul département.

ÉTAPE 9 · 24 septembre 2026

9. Les 4 groupes

Groupe	Nb	OMR	Recycl.	Verts	Encombr.	Dang.	Total
Profil intermédiaire	59	217	144	80	74	11	528
Déchets verts et déchèteries	19	226	145	151	93	12	629
Grandes agglomérations	13	275	67	42	64	3	456
Ordures ménagères élevées	9	360	120	82	95	12	674
<i>Moyenne nationale</i>	100	239	132	88	78	10	

En kg par habitant (moyenne 2019–2021). Total : hors gravats, issu du fichier « chiffres-clés ».





Figure 8 — Profil de chaque groupe, en indice : 100 = moyenne des 100 départements.

Variables illustratives

Ces variables n'ont pas servi à former les groupes : elles servent à les comprendre.

Groupe	Population moyenne	Revenu médian	Incinération	Stockage	Valorisation organique
Profil intermédiaire	561 927	21 875 €	21 %	22 %	15 %
Déchets verts et déchèteries	592 410	21 701 €	21 %	18 %	22 %
Grandes agglomérations	1 406 628	23 031 €	49 %	16 %	9 %
Ordures ménagères élevées	500 037	20 749 €	20 %	37 %	11 %



Outre-mer : Guadeloupe (Ordures ménagères élevées) ; Martinique (Grandes agglomérations) ; Guyane (Grandes agglomérations) ; La Réunion (Déchets verts et déchèteries). Mayotte : pas de détail par type de déchet.

Figure 9 — Carte des 4 groupes.

Profil intermédiaire — 59 départements

Membres (du plus typique au moins typique) : Haute-Loire, Haute-Vienne, Gers, Ain, Creuse, Allier, Aveyron, Tarn, Doubs, Loire, Jura, Cantal, Saône-et-Loire, Vienne, Isère, Puy-de-Dôme, Haute-Savoie, Meuse, Hautes-Pyrénées, Cote-d'Or, Nord, Tarn-et-Garonne, Indre, Vosges, Ille-et-Vilaine, Moselle, Pyrénées-Atlantiques, Maine-et-Loire, Marne, Nièvre, Indre-et-Loire, Gironde, Bas-Rhin, Drôme, Cher, Corrèze, Haut-Rhin, Savoie, Sarthe, Lozère, Loire-Atlantique, Haute-Marne, Meurthe-et-Moselle, Ardèche, Dordogne, Gard, Yonne, Aube, Ardennes, Lot-et-Garonne, Charente, Deux-Sèvres, Hautes-Alpes, Aisne, Pas-de-Calais, Eure-et-Loir, Hérault, Haute-Saône, Lot.

La France « moyenne » : le Centre, l'Est, le Massif central, une grande partie du Sud-Ouest. Toutes les quantités sont proches de la moyenne, avec un peu moins d'ordures ménagères et un peu plus de recyclables. C'est le groupe le plus cohérent (silhouette de 0,39).

Déchets verts et déchèteries — 19 départements

Membres : Manche, Finistère, Calvados, Mayenne, Landes, Cotes-d'Armor, Oise, Loir-et-Cher, Morbihan, Seine-Maritime, Ariège, La Réunion, Orne, Eure, Somme, Charente-Maritime, Vendée, Loiret, Territoire-de-Belfort.

Surtout le **Grand Ouest** : Bretagne, Normandie, façade atlantique jusqu'aux Landes, Les déchets verts y sont 1,7 fois plus élevés que la moyenne (280 kg/hab dans les Landes), et les encombrants aussi : des déchets apportés en déchèterie, typiques de maisons avec jardin. C'est aussi le groupe qui composte le plus (22 % de valorisation organique) : le traitement suit ce qui est collecté. La part d'habitat individuel reste une hypothèse, non vérifiée avec nos données.

Grandes agglomérations — 13 départements

Membres : Seine-Saint-Denis, Hauts-de-seine, Paris, Val-de-Marne, Val-d'Oise, Martinique, Yvelines, Bouches-du-Rhône, Seine-et-Marne, Guyane, Rhône, Essonne, Haute-Garonne.

Les 8 départements d'Île-de-France, plus ceux de Lyon, Marseille et Toulouse. Ils produisent le **moins de déchets au total** (456 kg/hab) mais trient peu : deux fois moins de recyclables et de déchets verts que la moyenne, trois fois moins de déchets dangereux. Ce sont les plus peuplés, les plus aisés, et ceux qui incinèrent le plus (49 %). Lecture : habitat collectif, pas de jardin, peu d'accès aux déchèteries ; ce qui n'est pas trié part dans la poubelle ordinaire, puis à l'incinérateur. La Martinique et la Guyane rejoignent ce groupe pour une autre raison : elles aussi trient peu et collectent peu de déchets verts, mais ce ne sont pas des agglomérations. Le nom du groupe décrit la majorité de ses membres.

Ordures ménagères élevées — 9 départements

Membres : Var, Corse-du-Sud, Alpes-Maritimes, Haute-Corse, Pyrénées-Orientales, Alpes-de-Haute-Provence, Guadeloupe, Vaucluse, Aude.

Le pourtour méditerranéen et la Corse. Les ordures ménagères y sont 1,5 fois plus élevées que la moyenne (459 kg/hab en Corse-du-Sud), et le groupe produit **le plus de déchets au total** (674 kg/hab). Il stocke aussi le plus (37 %) et a le revenu médian le plus bas. Hypothèse : le **tourisme**. Le ratio est calculé avec la population résidente, alors que les touristes produisent des déchets sans être comptés. C'est la piste déjà ouverte par l'analyse des erreurs du modèle supervisé, où la Corse était le territoire le plus mal prédit.

ÉTAPE 10 · 24 septembre 2026

10. Clustering hiérarchique et dendrogramme

Le clustering hiérarchique ne demande pas k à l'avance : il construit toute une hiérarchie de regroupements, que l'on coupe ensuite au niveau voulu. Le cours en présente deux approches :

Approche	Principe
Agglomérative (bottom-up)	Chaque département commence seul ; à chaque étape, les deux groupes les plus proches fusionnent, jusqu'à n'en avoir plus qu'un
Divisive (top-down)	Tous les départements commencent ensemble ; le groupe est divisé récursivement jusqu'à ce que chaque département soit seul

Nous avons utilisé l'approche **agglomérative**. La « proximité » entre deux groupes est définie par une **méthode de liaison** ; nous avons choisi celle de **Ward** : on fusionne les deux groupes dont la réunion fait le moins augmenter l'inertie. C'est le même critère que le k -means, ce qui rend la comparaison directe.

Le dendrogramme

Le dendrogramme représente toutes les fusions. L'axe horizontal porte les départements, l'axe vertical la distance à laquelle deux groupes fusionnent. Couper l'arbre à une hauteur donnée fournit un nombre de groupes.




Figure 10 — Dendrogramme (liaison de Ward) des 100 départements ; pointillé : coupe en 4 groupes.

Où couper ? On cherche un grand saut de hauteur entre deux fusions successives : il signale que l'on fusionnerait des groupes vraiment différents.

Nombre de groupes après la coupe	Hauteur de fusion	Saut avec la fusion suivante
2	16,28	4,07
3	12,21	2,50
4	9,71	2,19
5	7,52	0,58

Nombre de groupes après la coupe	Hauteur de fusion	Saut avec la fusion suivante
6	6,94	0,02
7	6,92	1,27
8	5,65	0,39

Les sauts sont grands jusqu'à 4 groupes (4,07, puis 2,50, puis 2,19), puis s'effondrent (0,58, puis 0,02) : au-delà de 4 groupes, les fusions se font à des hauteurs presque égales, sans structure nouvelle. Le dendrogramme confirme donc qu'une coupe à **4 groupes** est la plus fine qui ait encore un sens.

Comparaison avec le k-means

Groupe k-means	Hiérarchique 1	Hiérarchique 2	Hiérarchique 3	Hiérarchique 4
Profil intermédiaire	0	57	0	2
Déchets verts et déchèteries	0	4	15	0
Grandes agglomérations	13	0	0	0
Ordures ménagères élevées	0	0	0	9

Les deux méthodes s'accordent à 0,82 (indice ARI, défini au chapitre 12) : les grandes agglomérations et la Méditerranée sont identiques, et le hiérarchique ne fait que rattacher quatre départements de l'Ouest et deux départements intermédiaires à un groupe voisin. Les quatre profils ne dépendent donc pas de l'algorithme.

ÉTAPE 11 · 24 septembre 2026

11. DBSCAN : un clustering par densité

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) regroupe les points situés dans des zones denses. Contrairement au k-means, il ne demande pas le nombre de groupes, peut trouver des groupes de forme quelconque, et classe à part les points isolés. Il a deux réglages :

Réglage	Signification
ϵ (« epsilon »)	le rayon du voisinage autour de chaque point
MinPts	le nombre minimal de voisins dans ce rayon pour qu'un point soit « de cœur »

Type de point	Définition
Point de cœur	Au moins MinPts points dans son rayon ϵ
Point de bordure	Dans le rayon ϵ d'un point de cœur, sans être lui-même de cœur
Point de bruit	Ni de cœur, ni de bordure : isolé, considéré comme une anomalie

Régler MinPts et ϵ

Nous avons pris **MinPts = 10**, soit deux fois le nombre de variables, un réglage courant. Pour ϵ , on trie les départements selon la distance à leur 10^e voisin (courbe des k-distances) et l'on prend la valeur au coude de la courbe, là où les distances se mettent à grimper : au-delà, on n'a plus que des points isolés.




Figure 11 — Courbe des k-distances (distance au 10^e voisin) ; pointillé : ϵ retenu au coude de la courbe.

Résultat




Figure 12 — Résultat de DBSCAN sur le plan PC1-PC2 : points de cœur, de bordure et de bruit.

DBSCAN ne trouve qu'un **seul groupe dense** : 90 points de cœur, 8 points de bordure, et 2 points de bruit : **Landes, Guadeloupe**, les deux départements les plus atypiques (un record de déchets verts, un record d'ordures ménagères associé à très peu de tri).

Le résultat dépend-il des réglages ?

ϵ	Groupes (MinPts = 5)	Bruit (MinPts = 5)	Groupes (MinPts = 10)	Bruit (MinPts = 10)
1,0	1	43	1	54
1,2	1	32	1	38
1,4	1	27	1	28
1,6	1	13	1	21
1,8	1	7	1	14
2,0	1	3	1	7

Quel que soit le réglage, DBSCAN ne trouve jamais plus d'un groupe dense : il ne fait que varier le nombre de points classés comme bruit.

Ce que DBSCAN nous apprend

Nos départements ne forment pas des îlots séparés par des zones vides, mais un **seul nuage continu**, plus dense au centre. C'est cohérent avec la silhouette modérée du k-means (0,315) : les 4 profils sont des découpages utiles d'un continuum, pas des catégories naturellement séparées. DBSCAN est en revanche l'outil adapté à la **détection d'anomalies** : il désigne sans hésiter les Landes et la Guadeloupe comme les cas hors norme, ceux qui tirent le plus les centroïdes du k-means.

ÉTAPE 12 · 24 septembre 2026

12. Qualité et solidité des groupes

La silhouette, département par département




Figure 13 — Silhouette de chaque département, par groupe (trait pointillé : moyenne).

Groupe	Silhouette moyenne	Minimum	Maximum
Profil intermédiaire	0,388	0,108	0,542
Déchets verts et déchèteries	0,141	-0,104	0,330
Grandes agglomérations	0,344	0,100	0,531
Ordures ménagères élevées	0,163	-0,055	0,358

Les groupes « Profil intermédiaire » et « Grandes agglomérations » sont nets. « Déchets verts » et « Ordures ménagères élevées » sont plus fragiles : quatre départements y ont une silhouette négative, c'est-à-dire qu'ils seraient presque aussi bien dans un autre groupe : **Aude, Loiret, Vendée, Territoire-de-Belfort**. Ce sont des cas frontières, à ne pas sur-interpréter.

Le groupe change-t-il si l'on change la méthode ?

Pour comparer deux clusterings, on utilise l'**indice de Rand ajusté** (ARI) : il vaut 1 si les deux découpages forment exactement les mêmes groupes, et environ 0 s'ils n'ont pas plus de points communs qu'un découpage fait au hasard.

Essai	ARI avec nos 4 groupes	Silhouette
k-means relancé avec 10 autres graines	de 0,81 à 1,00	de 0,312 à 0,319
Autre méthode : classification hiérarchique (Ward)	0,82	0,315
k-means sans l'outre-mer (96 départements)	0,65	0,291
Clustering du traitement (partie supervisée)	0,006	—

- **D'une graine à l'autre**, les groupes restent très proches. Quand ils diffèrent, seule la frontière du groupe « déchets verts » bouge ; les agglomérations et la Méditerranée sont identiques. Notre solution est celle de plus faible inertie, c'est-à-dire la meilleure au sens du k-means.
- **Le clustering hiérarchique** (chapitre 10) retrouve les mêmes agglomérations et la même Méditerranée.
- **Sans l'outre-mer**, les agglomérations restent stables, mais le groupe « ordures ménagères élevées » s'élargit à des départements du Nord et de Normandie. Les départements d'outre-mer, aux valeurs extrêmes, déplacent les frontières sans changer les cœurs de groupe.

Une découverte : production et traitement sont indépendants

Nos groupes n'ont **aucun lien** avec les groupes formés dans la partie supervisée à partir du traitement des déchets (ARI de 0,006, celui du hasard). Ce que les habitants jettent et ce que le territoire fait de ses déchets (incinérer, stocker, recycler) sont deux choses distinctes. Chaque clustering apporte donc une information que l'autre n'a pas.

ÉTAPE 13 · 24 septembre 2026

13. Synthèse des méthodes

Méthode	Principe	Ce qu'elle a apporté ici
k-means	Partitionnement autour de k centroïdes	Les 4 profils, avec k choisi par le coude et la silhouette
Clustering hiérarchique	Fusions successives, dendrogramme	La confirmation de k = 4 (derniers grands sauts du dendrogramme) et des mêmes groupes (ARI 0,82)
DBSCAN	Groupe fondés sur la densité, points de bruit	La preuve que les données forment un continuum, et les deux anomalies : Landes, Guadeloupe
PCA	Composantes principales de variance maximale	Trois dimensions lisibles (84% de l'information) : tri et déchèteries (PC1), volume de la poubelle (PC2), part végétale (PC3) ; une carte des groupes

Les méthodes se complètent : la PCA explique **sur quoi** les départements diffèrent, le k-means et le clustering hiérarchique découpent ces différences en profils, et DBSCAN rappelle que ces profils sont des zones d'un même nuage, avec deux cas hors norme.

14. Problèmes rencontrés et conclusion

Problème	Ce que nous avons fait
Une ligne par département et par année, alors qu'il en faut une par département	Moyenne des enquêtes 2019 et 2021, les plus récentes détaillées par type
Des variables aux échelles très différentes (240 kg contre 10 kg)	Standardisation (StandardScaler)
Deux familles de variables qui se recouvrent (production et traitement)	Une seule famille active, l'autre gardée pour interpréter
Coude et silhouette ne désignent pas le même k	k = 4, seul point d'accord des deux méthodes, sans groupe réduit à un département
Un résultat qui dépend du tirage au hasard	20 lancements par k, graine fixe, stabilité vérifiée
Des valeurs extrêmes (Guadeloupe, Landes, Corse-du-Sud)	Repérées par DBSCAN ; effet mesuré en retirant l'outre-mer : les cœurs de groupe tiennent
Deux composantes principales ne suffisent pas (71 % de l'information)	Règle des 80-90 % : 3 composantes retenues, plan PC1-PC3 ajouté

Conclusion

Existe-t-il des profils types de départements selon ce que leurs habitants jettent ? **Oui, quatre**, désignés conjointement par la méthode du coude et le score de silhouette, et retrouvés par une autre méthode de clustering, le clustering hiérarchique, dont le dendrogramme situe aussi la dernière coupe utile à 4 groupes. Leur séparation reste modérée (silhouette de 0,315) : ce ne sont pas des catégories étanches, mais des tendances nettes dans un ensemble continu, ce que DBSCAN confirme en ne trouvant qu'un seul nuage dense, avec deux départements hors norme.

Le résultat le plus frappant est géographique. Le modèle n'a reçu que des kilos de déchets, et il a dessiné une carte : l'Ouest des jardins et des déchèteries, les grandes agglomérations, la Méditerranée et la Corse, et une France intermédiaire. La PCA en donne la clé : les départements se distinguent d'abord par le **tri et les apports en déchèterie** (PC1), ensuite par le **volume de la poubelle ordinaire** (PC2), enfin par la **part végétale** de ce qu'ils apportent (PC3). Derrière ces axes se dessinent, comme hypothèses, le type d'habitat (maisons avec jardin contre habitat collectif) et le tourisme.

Deux enseignements dépassent le clustering lui-même. D'abord, le total de déchets ne suffit pas à juger un territoire : les agglomérations produisent le moins mais trient le moins, l'Ouest produit beaucoup mais surtout des déchets verts qu'il composte. Ensuite, ce que les habitants jettent est indépendant de la façon dont leur territoire traite ses déchets : les deux clusterings du projet se complètent au lieu de se répéter.

Ces profils éclairent enfin la partie supervisée : ils décrivent les écarts **durables** entre départements, ceux que la valeur de l'enquête précédente capte déjà. Ils n'aideraient donc pas à mieux prédire l'évolution d'une enquête à l'autre, mais ils expliquent pourquoi les niveaux diffèrent, et appellent des actions différentes : le tri en habitat collectif dans les agglomérations, le compostage de proximité dans l'Ouest, la collecte adaptée aux pics touristiques en Méditerranée.

Glossaire

Terme	Définition
ACP / PCA	Analyse en composantes principales (<i>Principal Component Analysis</i>) : résumé de nombreuses variables en quelques composantes qui gardent l'essentiel des différences.
Apprentissage non supervisé	Chercher une structure dans des données sans réponse connue à retrouver.
ARI	<i>Adjusted Rand Index</i> , indice de Rand ajusté : compare deux découpages en groupes (1 = identiques, environ 0 = pas plus de points communs qu'au hasard).
Centre (centroïde)	Point moyen d'un groupe : la moyenne de ses membres sur chaque variable.
Cercle des corrélations	Graphique de la PCA montrant le lien de chaque variable avec PC1 et PC2.
Chargement	Corrélation entre une variable d'origine et une composante principale : indique l'importance et le sens de sa contribution.
Classification hiérarchique (Ward)	Méthode qui regroupe pas à pas les éléments les plus proches ; la variante de Ward limite la dispersion des groupes.
Clustering	Regrouper des éléments qui se ressemblent, sans réponse connue à l'avance.
Composante principale	Nouvelle variable créée par la PCA, combinaison des variables d'origine, non corrélée aux autres composantes.
Corrélation	Mesure, de -1 à 1 , de la force du lien linéaire entre deux variables.
DBSCAN	Clustering fondé sur la densité : regroupe les points situés dans des zones denses et classe les points isolés comme bruit.
Dendrogramme	Arbre qui représente les fusions successives du clustering hiérarchique ; le couper à une hauteur donne un nombre de groupes.
Distance de Manhattan	Somme des écarts absolus entre deux points, variable par variable.
Distance euclidienne	Distance « en ligne droite » entre deux points : racine de la somme des écarts au carré. Utilisée par le k-means.
Fléau de la dimensionnalité	Difficulté croissante à visualiser, interpréter et modéliser des données quand le nombre de variables augmente.
Graine (random_state)	Nombre qui fixe le tirage au hasard, pour obtenir le même résultat à chaque exécution.
Inertie	Somme des distances au carré entre chaque élément et le centre de son groupe : plus elle est faible, plus les groupes sont compacts.
k	Nombre de groupes demandé au k-means.
k-means	Algorithme qui forme k groupes autour de k centres en minimisant l'inertie.
Liaison (méthode de)	Règle qui définit la distance entre deux groupes dans le clustering hiérarchique ; Ward minimise la hausse d'inertie.
Matrice de covariance	Tableau des covariances entre toutes les paires de variables ; sur des données standardisées, égale à la matrice de corrélation.

Terme	Définition
MinPts	Nombre minimal de voisins dans le rayon ϵ pour qu'un point soit « de cœur » dans DBSCAN.
Méthode du coude	Repérer le nombre de groupes à partir duquel l'inertie ne baisse presque plus.
n_init	Nombre de lancements du k-means avec des départs différents ; on garde le meilleur.
PC1, PC2, PC3	Première, deuxième, troisième composantes principales, par ordre d'information portée.
Point de bruit	Pour DBSCAN : point ni de cœur ni de bordure, considéré comme une anomalie.
Point de cœur, de bordure	Pour DBSCAN : point avec au moins MinPts voisins dans le rayon ϵ (cœur), ou voisin d'un tel point sans l'être lui-même (bordure).
Silhouette	Mesure, de -1 à 1 , de la place d'un élément dans son groupe : proche de 1 = bien placé, négatif = mieux ailleurs.
Standardisation	Transformer une variable pour qu'elle ait une moyenne de 0 et un écart-type de 1 : $z = (x - \mu) / \sigma$.
Valeur extrême	Élément très éloigné des autres, qui peut tirer un centre de groupe vers lui.
Valeur propre	Quantité d'information (variance) portée par une composante principale.
Variable active	Variable utilisée pour former les groupes.
Variable illustrative	Variable qui ne sert pas à former les groupes, seulement à les interpréter.
Variance expliquée	Part des différences entre éléments captée par une composante principale.
Vecteur propre	Direction d'une composante principale : les coefficients de chaque variable d'origine dans cette composante.
WCSS	<i>Within-Cluster Sum of Squares</i> , somme des carrés intra-cluster : autre nom de l'inertie.
Éboulis des valeurs propres	Graphique des valeurs propres triées, pour choisir le nombre de composantes (coude, règle des 80–90 %).
Écart-type (σ)	Écart moyen des valeurs à leur moyenne.
ϵ (epsilon)	Rayon du voisinage utilisé par DBSCAN.

Annexe A. Détail des calculs

A.1 Une silhouette calculée à la main : Paris

Distances calculées sur les 5 variables standardisées.

Étape	Valeur
a : distance moyenne de Paris aux autres départements de son groupe (Grandes agglomérations)	2,434
b : distance moyenne de Paris aux départements du groupe voisin le plus proche (Profil intermédiaire)	4,684
$s = (b - a) / \max(a, b)$	$(4,684 - 2,434) / 4,684 =$ 0,480

Paris est nettement plus proche des autres grandes agglomérations que de tout autre groupe : il est bien placé. Le score de silhouette du clustering (0,315) est la moyenne de ce calcul sur les 100 départements.

A.2 Profils standardisés des groupes (valeurs z moyennes)

Groupe	Ordures ménagères résiduelles	Matériaux recyclables	Déchets verts et biodéchets	Encombrants	Déchets dangereux
Profil intermédiaire	-0,39	0,34	-0,21	-0,26	0,20
Déchets verts et déchèteries	-0,23	0,37	1,49	0,95	0,31
Grandes agglomérations	0,64	-1,85	-1,11	-0,94	-1,71
Ordures ménagères élevées	2,17	-0,36	-0,15	1,08	0,46

Lecture : 0 = moyenne nationale ; +1 = un écart-type au-dessus. Les agglomérations sont à plus d'un écart-type sous la moyenne pour les recyclables, les déchets verts et les déchets dangereux.

A.3 PCA : vecteurs propres (coefficients de chaque variable dans chaque composante)

Variable	PC1 (45%)	PC2 (26%)	PC3 (13%)	PC4 (9%)	PC5 (6%)
Ordures ménagères résiduelles	-0,23	0,70	-0,37	0,57	0,05
Matériaux recyclables	0,53	-0,29	-0,35	0,40	-0,60
Déchets verts et biodéchets	0,50	0,14	0,68	0,44	0,27
Encombrants	0,35	0,64	0,13	-0,52	-0,43
Déchets dangereux	0,55	0,04	-0,52	-0,22	0,62

A.4 PCA : chargements sur les 5 composantes

Chargement = vecteur propre $\times \sqrt{\text{valeur propre}}$. Par exemple, pour les ordures ménagères sur PC2 : $0,698 \times \sqrt{1,330} = 0,805$.

Variable	PC1	PC2	PC3	PC4	PC5
Ordures ménagères résiduelles	-0,35	0,81	-0,30	0,39	0,03
Matériaux recyclables	0,79	-0,33	-0,28	0,27	-0,34
Déchets verts et biodéchets	0,75	0,16	0,55	0,30	0,16
Encombrants	0,52	0,74	0,11	-0,36	-0,24
Déchets dangereux	0,83	0,05	-0,42	-0,15	0,35

A.5 Stabilité selon la graine du k-means

Essai	ARI	Silhouette
k-means, graine 0	0,968	0,312
k-means, graine 1	1,000	0,315
k-means, graine 2	0,805	0,317
k-means, graine 3	0,968	0,312
k-means, graine 4	1,000	0,315
k-means, graine 5	0,968	0,312
k-means, graine 6	1,000	0,315
k-means, graine 7	0,968	0,312
k-means, graine 8	0,813	0,319
k-means, graine 9	1,000	0,315

Annexe B. Guide d'utilisation

Le volet clustering se lance comme le reste du projet, au choix dans Google Colab ou sur Linux.

Option 1 : Google Colab, sans rien installer

Le notebook `dechets/notebooks/projet_dechets.ipynb` rejoue tout le projet : la partie supervisée, puis la partie clustering (*Partie 2*), avec les explications et toutes les figures de ce rapport. Ouvert dans Google Colab, il télécharge lui-même le dépôt et les données :

- ouvrir l'adresse ci-dessous (ou le bouton « Open in Colab » du README du dépôt) ;
- lancer *Exécution* > *Tout exécuter* ;
- la partie clustering commence à la section 11 du notebook.

```
https://colab.research.google.com/github/Rxdy/ML-DMA/blob/main/
dechets/notebooks/projet_dechets.ipynb
```

Option 2 : Linux, testé sur Ubuntu 22.04 et 24.04

```
sudo apt update && sudo apt install -y git make python3 python3-venv
git clone https://github.com/Rxdy/ML-DMA.git
cd ML-DMA
make installer          # crée .env et installe les dépendances
make non-supervise      # scripts 12 à 14 : tout le clustering
```

Commande	Script	Ce qu'elle fait
<code>make profils</code>	12	Choix des variables, coude, silhouette, 4 groupes, profils, carte
<code>make analyses-profils</code>	13	Corrélations, PCA (PC1, PC2, PC3), nuages de points, silhouette, robustesse
<code>make autres-methodes</code>	14	Clustering hiérarchique (dendrogramme) et DBSCAN
<code>make non-supervise</code>	12 à 14	Tout le volet clustering
<code>make all</code>	01 à 14	Tout le projet, supervisé et non supervisé

Les résultats s'affichent dans la console et sont enregistrés dans `dechets/data/processed/` (tableaux `clustering_*.csv`) et `dechets/data/figures/` (figures `clustering_*.png`). Le raisonnement détaillé est aussi résumé dans `dechets/CLUSTERING.md`.