

Machine learning : Déchets

Clustering : des profils de départements selon ce que leurs habitants jettent

MEMBRES DU GROUPE

ALVES Rudy

ANTHONY Josselin

BENASSIE Noé

TAVERNIER Florian

DATE

24 septembre 2026

DÉPÔT GITHUB

github.com/Rxdy/ML-DMA

Données : ADEME (SINOE) et INSEE, data.gouv.fr, licence Ouverte 2.0

Sommaire

Introduction	3
1. Du supervisé au non supervisé	4
2. Les données de départ	5
3. Choisir les variables	6
4. Les corrélations entre les variables	7
5. Préparer les données	8
6. Voir en plusieurs dimensions	9
7. L'algorithme k-means	13
8. Choisir le nombre de groupes	14
9. Les 4 groupes	16
10. Qualité et solidité des groupes	19
11. Problèmes rencontrés et conclusion	21
Glossaire	22
Annexe A. Détail des calculs	23
Annexe B. Guide d'utilisation	25

Introduction

Ce rapport est la suite du rapport sur l'apprentissage supervisé. Il reprend les **mêmes données** (ADEME / SINOE et INSEE), mais change de question : il ne s'agit plus de prédire une valeur connue, mais de **découvrir des groupes** de départements qui se ressemblent. Comme le premier, il suit l'ordre dans lequel nous avons pris nos décisions, et explique pour chacune ce que nous avons fait et pourquoi.

La question posée : existe-t-il des profils types de départements selon la façon dont leurs habitants jettent leurs déchets ?

Le résultat en trois phrases

Les 100 départements se répartissent en **4 profils** : une France intermédiaire, un Ouest des déchets verts, les grandes agglomérations qui trient peu, et la Méditerranée aux ordures ménagères élevées. Ces profils forment une carte cohérente alors qu'aucune information géographique n'a été donnée au modèle. Ils semblent liés au type d'habitat et au tourisme, et sont indépendants de la façon dont chaque territoire traite ses déchets.

Le code est disponible sur le dépôt github.com/Rxdy/ML-DMA (scripts `12_clustering_production.py` et `13_clustering_analyses.py`).

Chronologie en un coup d'œil

Étape	Ce qui a été fait	Script
1	Passer du supervisé au non supervisé : la question	—
2	Les données de départ : une ligne par département	12
3	Choisir les variables qui définiront les groupes	12
4	Étudier les corrélations entre ces variables	13
5	Préparer les données : kg par habitant, standardisation	12
6	Voir en plusieurs dimensions : ACP et nuages de points	13
7	Comprendre l'algorithme k-means	12
8	Choisir le nombre de groupes : coude et silhouette	12
9	Décrire et interpréter les 4 groupes	12
10	Vérifier la qualité et la solidité des groupes	13

ÉTAPE 1 · 24 septembre 2026

1. Du supervisé au non supervisé

En apprentissage **supervisé**, chaque exemple a une réponse connue (y) : le modèle apprend à la retrouver à partir des entrées (X). En apprentissage **non supervisé**, il n'y a pas de y . Le modèle reçoit seulement X et cherche une structure dans les données : ici, des groupes d'éléments proches les uns des autres. C'est le **clustering**.

	Supervisé (premier rapport)	Non supervisé (ce rapport)
Question	Combien de kg par habitant à la prochaine enquête ?	Quels types de départements existe-t-il ?
Données	X et y	X seulement
Une ligne =	un département à une date	un département
Modèles	régression linéaire, arbre, Random Forest	k-means (et Ward pour comparaison)
Évaluation	comparer les prédictions aux vraies valeurs (MAE, R^2)	pas de « bonne réponse » : mesurer la cohésion des groupes (inertie, silhouette) et leur stabilité

Ce que change l'absence de réponse attendue

Il n'existe pas de « bon » clustering à retrouver. Un clustering est utile s'il forme des groupes compacts, bien séparés, stables, et surtout **interprétables**. C'est pourquoi le choix des variables et l'interprétation comptent autant que l'algorithme.

ÉTAPE 2 · 24 septembre 2026

2. Les données de départ

Nous repartons du fichier principal de l'ADEME, `sinoe_dma.csv`, qui détaille pour chaque département et chaque enquête le tonnage de 7 types de déchets, et du fichier « chiffres-clés hors gravats » pour la population. Les contrôles faits dans la partie supervisée restent valables : aucune valeur manquante, aucun doublon, jointure validée sur la clé département × année.

Une ligne par département

Le clustering compare des départements : il lui faut **une seule ligne par département**. Or les données ont une ligne par département et par enquête. Nous avons retenu la **moyenne des enquêtes 2019 et 2021** :

- ce sont les deux enquêtes les plus récentes détaillées par type de déchet (le détail s'arrête en 2021) ;
- faire la moyenne de deux enquêtes lisse les variations ponctuelles, comme les allers-retours observés dans la partie supervisée.

Résultat : **100 départements**. Mayotte est absente, faute de détail par type de déchet.

ÉTAPE 3 · 24 septembre 2026

3. Choisir les variables

Le clustering regroupe les départements qui se ressemblent **sur les variables qu'on lui donne**. Choisir les variables, c'est décider de ce que « se ressembler » veut dire. C'est l'étape la plus importante.

Trois familles possibles

Famille	Variables	Ce qu'elles décrivent
Production	kg par habitant de chaque type de déchet	ce que les habitants jettent
Traitement	part incinérée, stockée, recyclée, compostée	ce que le territoire fait de ses déchets
Contexte	population, revenu médian	qui est le territoire

Nous avons retenu la **production**, pour deux raisons :

- le traitement a déjà été clusterisé dans la partie supervisée (annexe A du premier rapport) ;
- mélanger production et traitement compterait deux fois la même information. Les départements qui collectent beaucoup de déchets verts sont aussi ceux qui en compostent beaucoup (corrélation de 0,71), et ceux qui collectent beaucoup de recyclables en recyclent beaucoup (0,63).

Le traitement et le contexte ne sont pas perdus : ils servent de **variables illustratives**. Ils ne participent pas à la formation des groupes, mais aident à les interpréter ensuite.

Les 5 variables retenues

Variable (kg par habitant)	Moyenne	Minimum	Maximum
Ordures ménagères résiduelles	239	135,1	459
Matériaux recyclables	132	20,5	201
Déchets verts et biodéchets	88	0,6	280
Encombrants	78	35,3	122
Déchets dangereux	10	0,2	28

Ce qui a été écarté

Écarté	Raison
Déblais et gravats	Ils viennent surtout des chantiers, pas des habitants (même choix qu'en supervisé)
« Autres »	Catégorie presque vide et très irrégulière : son écart-type vaut 1,85 fois sa moyenne
Total de déchets par habitant	C'est la somme des autres : il ferait doublon
Population, revenu, traitement	Gardés comme variables illustratives, pour interpréter

ÉTAPE 4 · 24 septembre 2026

4. Les corrélations entre les variables

Avant de regrouper, on regarde comment les 5 variables évoluent ensemble. Deux variables très corrélées (au-delà de 0,8) porteraient presque la même information et pèseraient deux fois ; il faudrait alors en retirer une.




Figure 1 — Corrélations entre les 5 variables (de -1 à 1).

Paire de variables	Corrélation	Lecture
Recyclables Déchets dangereux	0,59	Les départements qui trient leurs emballages apportent aussi leurs déchets dangereux en déchèterie
Déchets verts Encombrants	0,42	Deux déchets apportés en déchèterie : ils montent ensemble
Recyclables Déchets verts	0,41	Même logique d'apport volontaire
Ordures ménagères Recyclables	-0,36	Ce qui n'est pas trié finit dans la poubelle ordinaire

Ce que ça montre

Aucune corrélation ne dépasse 0,6 : les 5 variables apportent chacune une information propre, on peut toutes les garder. Deux logiques se dessinent déjà : le **tri et les apports en déchèterie** (recyclables, dangereux, verts, encombrants montent ensemble) d'un côté, la **poubelle ordinaire** de l'autre, qui baisse quand le tri augmente.

ÉTAPE 5 · 24 septembre 2026

5. Préparer les données

Des kg par habitant, pas des tonnes

En tonnes, les départements les plus peuplés écraseraient tout : Paris ressemblerait aux Bouches-du-Rhône simplement parce qu'ils ont beaucoup d'habitants. Diviser par la population permet de comparer les comportements.

Standardiser

Le k-means regroupe les départements proches au sens de la **distance**. Or les ordures ménagères (environ 240 kg) et les déchets dangereux (environ 10 kg) n'ont pas la même échelle : sans précaution, un écart de 10 kg d'ordures ménagères compterait autant qu'un écart de 10 kg de déchets dangereux, qui est pourtant énorme pour eux. Les ordures ménagères décideraient seules des groupes. On standardise donc chaque variable (`StandardScaler`) :

$$z = (x - \mu) / \sigma$$

Symbole	Signification
x	valeur d'origine (en kg par habitant)
μ (« mu »)	moyenne de la variable sur les 100 départements
σ (« sigma »)	écart-type : l'écart moyen à la moyenne
z	valeur standardisée : de combien d'écart-types le département s'écarte de la moyenne

Exemple : les Landes collectent 280 kg de déchets verts par habitant. Avec $\mu = 88,4$ et $\sigma = 42,0$, $z = (279,7 - 88,4) / 42,0 = 4,55$: les Landes sont à 4,6 écarts-types au-dessus de la moyenne. Après standardisation, chaque variable a une moyenne de 0 et un écart-type de 1 : elles pèsent toutes autant.

Pourquoi `StandardScaler` et pas `MinMaxScaler` ?

En supervisé, nous avons ramené les variables entre 0 et 1 (`MinMaxScaler`). Ici, un département extrême (les Landes pour les déchets verts) fixerait à lui seul le maximum et tasserait tous les autres près de 0. La standardisation est moins sensible à un seul extrême, et c'est la préparation habituelle avant un k-means.

À la fin de cette étape, X est un tableau de **100 lignes × 5 colonnes**, sans y.


ÉTAPE 6 · 24 septembre 2026

6. Voir en plusieurs dimensions

Chaque département est un point dans un espace à 5 dimensions, impossible à dessiner directement. Deux outils permettent de le voir quand même.

Les nuages de points, deux variables à la fois

La matrice ci-dessous croise chaque paire de variables. Chaque point est un département, coloré selon le groupe qu'il recevra à l'étape 9. Sur la diagonale, la distribution de chaque variable.



On y voit déjà les groupes se séparer : les agglomérations (vert) en bas des recyclables et des déchets verts, la Méditerranée (jaune) en haut des ordures ménagères, l'Ouest (orange) en haut des déchets verts. Mais aucune paire ne sépare à elle seule les 4 groupes : il faut les 5 dimensions.

L'ACP : résumer 5 dimensions en 2

L'**analyse en composantes principales** (ACP) cherche de nouveaux axes, combinaisons des 5 variables, qui résument le mieux les différences entre départements. Le premier axe capte le plus d'information possible, le deuxième le plus possible de ce qui reste, et ainsi de suite.




Figure 3 — Part de l'information (variance) portée par chaque axe de l'ACP.

Les deux premiers axes résument **72%** de l'information (45% + 27%) : une carte à plat est donc une image fidèle des 5 dimensions.

Que représentent les axes ? Le cercle des corrélations

Chaque flèche est une variable. Sa direction indique l'axe auquel elle est liée, sa longueur la force du lien (1 = parfaitement représentée).




Figure 4 — Cercle des corrélations : liens entre les variables et les deux premiers axes.

Variable	Axe 1	Axe 2
Ordures ménagères résiduelles	-0,35	0,81
Matériaux recyclables	0,79	-0,33
Déchets verts et biodéchets	0,75	0,16
Encombrants	0,52	0,74
Déchets dangereux	0,83	0,05

- **Axe 1 (45%) : le tri et les apports en déchèterie.** Recyclables, déchets dangereux, déchets verts et encombrants y sont fortement positifs, les ordures ménagères négatives. À droite, les départements qui trient et apportent en déchèterie ; à gauche, ceux où tout va dans la poubelle ordinaire.
- **Axe 2 (27%) : le volume d'ordures ménagères et d'encombrants.** En haut, les départements qui jettent beaucoup, indépendamment du tri.

Les départements sur le plan de l'ACP




Figure 5 — Les 100 départements projetés sur les deux premiers axes, colorés par groupe final.

Paris et la petite couronne sont à l'extrême gauche (peu de tri), les Landes et la Bretagne à l'extrême droite (beaucoup de déchets verts et de tri), la Corse-du-Sud et la Guadeloupe tout en haut (beaucoup d'ordures ménagères). Les 4 groupes occupent chacun une zone du plan : l'ACP confirme visuellement la structure que le k-means va trouver.

ÉTAPE 7 · 24 septembre 2026

7. L'algorithme k-means

Le k-means forme k groupes autour de k **centres** (ou centroïdes). Il répète deux étapes jusqu'à ce que plus rien ne bouge :

- **Affectation** : chaque département rejoint le centre le plus proche ;
- **Mise à jour** : chaque centre se déplace au milieu (la moyenne) de ses départements.

Ce faisant, il minimise l'**inertie** : la somme des distances au carré entre chaque département et le centre de son groupe. Plus elle est faible, plus les groupes sont compacts.

$$\text{Inertie} = \sum_k \sum_{x \in C_k} \|x - c_k\|^2$$

Symbole	Signification
k	numéro du groupe (de 1 au nombre de groupes)
C_k	l'ensemble des départements du groupe k
c_k	le centre du groupe k : la moyenne de ses départements
x	un département (ses 5 valeurs standardisées)
$\ x - c_k\ $	la distance entre le département et le centre de son groupe
Σ	somme

Deux précautions

Le k-means part de centres tirés au hasard, et le résultat peut dépendre de ce tirage. Nous l'avons donc lancé **20 fois** pour chaque k (`n_init=20`) en gardant le résultat de plus faible inertie, avec une graine fixe (`random_state=42`) pour que le résultat soit reproductible. Enfin, le k-means ne choisit pas le nombre de groupes : c'est à nous de le fixer (étape suivante).

ÉTAPE 8 · 24 septembre 2026

8. Choisir le nombre de groupes

Nous avons lancé le k-means pour $k = 2$ à 10 et regardé deux indicateurs.

La méthode du coude

L'inertie baisse toujours quand on ajoute des groupes : avec autant de groupes que de départements, elle vaudrait 0. On cherche le **coude**, le point à partir duquel ajouter un groupe n'apporte plus grand-chose.

Le score de silhouette

Pour chaque département, on compare sa distance moyenne aux membres de son groupe (a) et sa distance moyenne aux membres du groupe voisin le plus proche (b) :

$$s = (b - a) / \max(a, b)$$

Symbole	Signification
a	distance moyenne aux autres membres de son groupe : la cohésion
b	distance moyenne aux membres du groupe voisin le plus proche : la séparation
$\max(a, b)$	la plus grande des deux, pour ramener s entre -1 et 1
s	proche de 1 : bien dans son groupe ; proche de 0 : à la frontière ; négatif : mieux ailleurs

Le score de silhouette d'un clustering est la moyenne des s de tous les départements.




Figure 6 — Méthode du coude (à gauche) et score de silhouette (à droite) selon le nombre de groupes.

k	Inertie	Baisse de l'inertie	Silhouette	Plus petit groupe
2	364	—	0,358	21.0 départements
3	290	−20 %	0,292	13.0 départements
4	239	−18 %	0,315	9.0 départements
5	211	−12 %	0,250	10.0 départements
6	185	−12 %	0,241	1.0 département
7	163	−12 %	0,270	1.0 département
8	145	−11 %	0,252	1.0 département
9	138	−5 %	0,190	1.0 département
10	124	−10 %	0,205	1.0 département

Lecture

- **Le coude est à k = 4.** Passer à 3 puis à 4 groupes réduit l'inertie de 20 % puis 18 %. Au-delà, chaque groupe ajouté ne la réduit plus que de 10 à 12 %.
- **La silhouette est la plus haute à k = 2 (0,358)**, puis présente un pic à **k = 4 (0,315)**, mieux que 3 et que 5.
- **À partir de k = 6, un groupe ne contient plus que la Guadeloupe.** Le k-means isole alors un cas extrême au lieu de former un profil : ces valeurs de k sont à écarter.

Décision : k = 4

k = 2 a la meilleure silhouette, mais il se contente de séparer « les grandes villes et la Méditerranée » du reste de la France : trop grossier pour apprendre quelque chose. **k = 4 est le seul point où les deux méthodes s'accordent** (coude et pic de silhouette), sans groupe réduit à un seul département.

ÉTAPE 9 · 24 septembre 2026

9. Les 4 groupes

Groupe	Nb	OMR	Recycl.	Verts	Encombr.	Dang.	Total
Profil intermédiaire	59	217	144	80	74	11	528
Déchets verts et déchèteries	19	226	145	151	93	12	629
Grandes agglomérations	13	275	67	42	64	3	456
Ordures ménagères élevées	9	360	120	82	95	12	674
<i>Moyenne nationale</i>	100	239	132	88	78	10	

En kg par habitant (moyenne 2019–2021). Total : hors gravats, issu du fichier « chiffres-clés ».





Figure 7 — Profil de chaque groupe, en indice : 100 = moyenne des 100 départements.

Variables illustratives

Ces variables n'ont pas servi à former les groupes : elles servent à les comprendre.

Groupe	Population moyenne	Revenu médian	Incineration	Stockage	Valorisation organique
Profil intermédiaire	561 927	21 875 €	21 %	22 %	15 %
Déchets verts et déchèteries	592 410	21 701 €	21 %	18 %	22 %
Grandes agglomérations	1 406 628	23 031 €	49 %	16 %	9 %
Ordures ménagères élevées	500 037	20 749 €	20 %	37 %	11 %



Outre-mer : Guadeloupe (Ordures ménagères élevées) ; Martinique (Grandes agglomérations) ; Guyane (Grandes agglomérations) ; La Réunion (Déchets verts et déchèteries). Mayotte : pas de détail par type de déchet.

Figure 8 — Carte des 4 groupes.

Profil intermédiaire — 59 départements

Membres (du plus typique au moins typique) : Haute-Loire, Haute-Vienne, Gers, Ain, Creuse, Allier, Aveyron, Tarn, Doubs, Loire, Jura, Cantal, Saône-et-Loire, Vienne, Isère, Puy-de-Dôme, Haute-Savoie, Meuse, Hautes-Pyrénées, Cote-d'Or, Nord, Tarn-et-Garonne, Indre, Vosges, Ille-et-Vilaine, Moselle, Pyrénées-Atlantiques, Maine-et-Loire, Marne, Nièvre, Indre-et-Loire, Gironde, Bas-Rhin, Drôme, Cher, Corrèze, Haut-Rhin, Savoie, Sarthe, Lozère, Loire-Atlantique, Haute-Marne, Meurthe-et-Moselle, Ardèche, Dordogne, Gard, Yonne, Aube, Ardennes, Lot-et-Garonne, Charente, Deux-Sèvres, Hautes-Alpes, Aisne, Pas-de-Calais, Eure-et-Loir, Hérault, Haute-Saône, Lot.

La France « moyenne » : le Centre, l'Est, le Massif central, une grande partie du Sud-Ouest. Toutes les quantités sont proches de la moyenne, avec un peu moins d'ordures ménagères et un peu plus de recyclables. C'est le groupe le plus cohérent (silhouette de 0,39).

Déchets verts et déchèteries — 19 départements

Membres : Manche, Finistère, Calvados, Mayenne, Landes, Cotes-d'Armor, Oise, Loir-et-Cher, Morbihan, Seine-Maritime, Ariège, La Réunion, Orne, Eure, Somme, Charente-Maritime, Vendée, Loiret, Territoire-de-Belfort.

Surtout le **Grand Ouest** : Bretagne, Normandie, façade atlantique jusqu'aux Landes, Les déchets verts y sont 1,7 fois plus élevés que la moyenne (280 kg/hab dans les Landes), et les encombrants aussi : des déchets apportés en déchèterie, typiques de maisons avec jardin. C'est aussi le groupe qui composte le plus (22 % de valorisation organique) : le traitement suit ce qui est collecté. La part d'habitat individuel reste une hypothèse, non vérifiée avec nos données.

Grandes agglomérations — 13 départements

Membres : Seine-Saint-Denis, Hauts-de-seine, Paris, Val-de-Marne, Val-d'Oise, Martinique, Yvelines, Bouches-du-Rhône, Seine-et-Marne, Guyane, Rhône, Essonne, Haute-Garonne.

Les 8 départements d'Île-de-France, plus ceux de Lyon, Marseille et Toulouse. Ils produisent le **moins de déchets au total** (456 kg/hab) mais trient peu : deux fois moins de recyclables et de déchets verts que la moyenne, trois fois moins de déchets dangereux. Ce sont les plus peuplés, les plus aisés, et ceux qui incinèrent le plus (49 %). Lecture : habitat collectif, pas de jardin, peu d'accès aux déchèteries ; ce qui n'est pas trié part dans la poubelle ordinaire, puis à l'incinérateur. La Martinique et la Guyane rejoignent ce groupe pour une autre raison : elles aussi trient peu et collectent peu de déchets verts, mais ce ne sont pas des agglomérations. Le nom du groupe décrit la majorité de ses membres.

Ordures ménagères élevées — 9 départements

Membres : Var, Corse-du-Sud, Alpes-Maritimes, Haute-Corse, Pyrénées-Orientales, Alpes-de-Haute-Provence, Guadeloupe, Vaucluse, Aude.

Le pourtour méditerranéen et la Corse. Les ordures ménagères y sont 1,5 fois plus élevées que la moyenne (459 kg/hab en Corse-du-Sud), et le groupe produit **le plus de déchets au total** (674 kg/hab). Il stocke aussi le plus (37 %) et a le revenu médian le plus bas. Hypothèse : le **tourisme**. Le ratio est calculé avec la population résidente, alors que les touristes produisent des déchets sans être comptés. C'est la piste déjà ouverte par l'analyse des erreurs du modèle supervisé, où la Corse était le territoire le plus mal prédit.

ÉTAPE 10 · 24 septembre 2026

10. Qualité et solidité des groupes

La silhouette, département par département




Figure 9 — Silhouette de chaque département, par groupe (trait pointillé : moyenne).

Groupe	Silhouette moyenne	Minimum	Maximum
Profil intermédiaire	0,388	0,108	0,542
Déchets verts et déchèteries	0,141	-0,104	0,330
Grandes agglomérations	0,344	0,100	0,531
Ordures ménagères élevées	0,163	-0,055	0,358

Les groupes « Profil intermédiaire » et « Grandes agglomérations » sont nets. « Déchets verts » et « Ordures ménagères élevées » sont plus fragiles : quatre départements y ont une silhouette négative, c'est-à-dire qu'ils seraient presque aussi bien dans un autre groupe : **Aude, Loiret, Vendée, Territoire-de-Belfort**. Ce sont des cas frontières, à ne pas sur-interpréter.

Le groupe change-t-il si l'on change la méthode ?

Pour comparer deux clusterings, on utilise l'**indice de Rand ajusté** (ARI) : il vaut 1 si les deux découpages forment exactement les mêmes groupes, et environ 0 s'ils n'ont pas plus de points communs qu'un découpage fait au hasard.

Essai	ARI avec nos 4 groupes	Silhouette
k-means relancé avec 10 autres graines	de 0,81 à 1,00	de 0,312 à 0,319
Autre méthode : classification hiérarchique (Ward)	0,82	0,315
k-means sans l'outre-mer (96 départements)	0,65	0,291
Clustering du traitement (partie supervisée)	0,006	—

- **D'une graine à l'autre**, les groupes restent très proches. Quand ils diffèrent, seule la frontière du groupe « déchets verts » bouge ; les agglomérations et la Méditerranée sont identiques. Notre solution est celle de plus faible inertie, c'est-à-dire la meilleure au sens du k-means.
- **Une autre méthode, la classification hiérarchique de Ward**, qui regroupe pas à pas les départements les plus proches, retrouve les mêmes agglomérations et la même Méditerranée ; elle ne déplace que quelques départements de l'Ouest vers le profil intermédiaire.
- **Sans l'outre-mer**, les agglomérations restent stables, mais le groupe « ordures ménagères élevées » s'élargit à des départements du Nord et de Normandie. Les départements d'outre-mer, aux valeurs extrêmes, déplacent les frontières sans changer les cœurs de groupe.

Une découverte : production et traitement sont indépendants

Nos groupes n'ont **aucun lien** avec les groupes formés dans la partie supervisée à partir du traitement des déchets (ARI de 0,006, celui du hasard). Ce que les habitants jettent et ce que le territoire fait de ses déchets (incinérer, stocker, recycler) sont deux choses distinctes. Chaque clustering apporte donc une information que l'autre n'a pas.

11. Problèmes rencontrés et conclusion

Problème	Ce que nous avons fait
Une ligne par département et par année, alors qu'il en faut une par département	Moyenne des enquêtes 2019 et 2021, les plus récentes détaillées par type
Des variables aux échelles très différentes (240 kg contre 10 kg)	Standardisation (StandardScaler)
Deux familles de variables qui se recouvrent (production et traitement)	Une seule famille active, l'autre gardée pour interpréter
Coude et silhouette ne désignent pas le même k	k = 4, seul point d'accord des deux méthodes, sans groupe réduit à un département
Un résultat qui dépend du tirage au hasard	20 lancements par k, graine fixe, stabilité vérifiée
Des valeurs extrêmes (Guadeloupe, Landes, Corse-du-Sud)	Effet mesuré en retirant l'outre-mer : les cœurs de groupe tiennent

Conclusion

Existe-t-il des profils types de départements selon ce que leurs habitants jettent ? **Oui, quatre**, désignés conjointement par la méthode du coude et le score de silhouette, et retrouvés par une autre méthode de clustering. Leur séparation reste modérée (silhouette de 0,315) : ce ne sont pas des catégories étanches, mais des tendances nettes dans un ensemble continu, avec quelques départements frontières.

Le résultat le plus frappant est géographique. Le modèle n'a reçu que des kilos de déchets, et il a dessiné une carte : l'Ouest des jardins et des déchèteries, les grandes agglomérations, la Méditerranée et la Corse, et une France intermédiaire. L'ACP en donne la clé : les départements se distinguent d'abord par le **tri et les apports en déchèterie**, ensuite par le **volume de la poubelle ordinaire**. Derrière ces deux axes se dessinent, comme hypothèses, le type d'habitat (maisons avec jardin contre habitat collectif) et le tourisme.

Deux enseignements dépassent le clustering lui-même. D'abord, le total de déchets ne suffit pas à juger un territoire : les agglomérations produisent le moins mais trient le moins, l'Ouest produit beaucoup mais surtout des déchets verts qu'il composte. Ensuite, ce que les habitants jettent est indépendant de la façon dont leur territoire traite ses déchets : les deux clusterings du projet se complètent au lieu de se répéter.

Ces profils éclairent enfin la partie supervisée : ils décrivent les écarts **durables** entre départements, ceux que la valeur de l'enquête précédente capte déjà. Ils n'aideraient donc pas à mieux prédire l'évolution d'une enquête à l'autre, mais ils expliquent pourquoi les niveaux diffèrent, et appellent des actions différentes : le tri en habitat collectif dans les agglomérations, le compostage de proximité dans l'Ouest, la collecte adaptée aux pics touristiques en Méditerranée.

Glossaire

Terme	Définition
ACP	Analyse en composantes principales : résumé de nombreuses variables en quelques axes qui gardent l'essentiel des différences.
Apprentissage non supervisé	Chercher une structure dans des données sans réponse connue à retrouver.
ARI	<i>Adjusted Rand Index</i> , indice de Rand ajusté : compare deux découpages en groupes (1 = identiques, environ 0 = pas plus de points communs qu'au hasard).
Centre (centroïde)	Point moyen d'un groupe : la moyenne de ses membres sur chaque variable.
Cercle des corrélations	Graphique de l'ACP montrant le lien de chaque variable avec les deux premiers axes.
Classification hiérarchique (Ward)	Méthode qui regroupe pas à pas les éléments les plus proches ; la variante de Ward limite la dispersion des groupes.
Clustering	Regrouper des éléments qui se ressemblent, sans réponse connue à l'avance.
Composante principale (axe)	Nouvelle variable créée par l'ACP, combinaison des variables d'origine.
Corrélation	Mesure, de -1 à 1 , de la force du lien linéaire entre deux variables.
Graine (random_state)	Nombre qui fixe le tirage au hasard, pour obtenir le même résultat à chaque exécution.
Inertie	Somme des distances au carré entre chaque élément et le centre de son groupe : plus elle est faible, plus les groupes sont compacts.
k	Nombre de groupes demandé au k-means.
k-means	Algorithme qui forme k groupes autour de k centres en minimisant l'inertie.
Méthode du coude	Repérer le nombre de groupes à partir duquel l'inertie ne baisse presque plus.
n_init	Nombre de lancements du k-means avec des départs différents ; on garde le meilleur.
Silhouette	Mesure, de -1 à 1 , de la place d'un élément dans son groupe : proche de 1 = bien placé, négatif = mieux ailleurs.
Standardisation	Transformer une variable pour qu'elle ait une moyenne de 0 et un écart-type de 1 : $z = (x - \mu) / \sigma$.
Valeur extrême	Élément très éloigné des autres, qui peut tirer un centre de groupe vers lui.
Variable active	Variable utilisée pour former les groupes.
Variable illustrative	Variable qui ne sert pas à former les groupes, seulement à les interpréter.
Variance expliquée	Part des différences entre éléments captée par un axe de l'ACP.
Écart-type (σ)	Écart moyen des valeurs à leur moyenne.

Annexe A. Détail des calculs

A.1 Une silhouette calculée à la main : Paris

Distances calculées sur les 5 variables standardisées.

Étape	Valeur
a : distance moyenne de Paris aux autres départements de son groupe (Grandes agglomérations)	2,434
b : distance moyenne de Paris aux départements du groupe voisin le plus proche (Profil intermédiaire)	4,684
$s = (b - a) / \max(a, b)$	$(4,684 - 2,434) / 4,684 =$ 0,480

Paris est nettement plus proche des autres grandes agglomérations que de tout autre groupe : il est bien placé. Le score de silhouette du clustering (0,315) est la moyenne de ce calcul sur les 100 départements.

A.2 Profils standardisés des groupes (valeurs z moyennes)

Groupe	Ordures ménagères résiduelles	Matériaux recyclables	Déchets verts et biodéchets	Encombrants	Déchets dangereux
Profil intermédiaire	-0,39	0,34	-0,21	-0,26	0,20
Déchets verts et déchèteries	-0,23	0,37	1,49	0,95	0,31
Grandes agglomérations	0,64	-1,85	-1,11	-0,94	-1,71
Ordures ménagères élevées	2,17	-0,36	-0,15	1,08	0,46

Lecture : 0 = moyenne nationale ; +1 = un écart-type au-dessus. Les agglomérations sont à plus d'un écart-type sous la moyenne pour les recyclables, les déchets verts et les déchets dangereux.

A.3 ACP : corrélation de chaque variable avec chaque axe

Variable	Axe 1 (45%)	Axe 2 (27%)	Axe 3 (13%)	Axe 4 (9%)	Axe 5 (6%)
Ordures ménagères résiduelles	-0,35	0,81	-0,30	0,39	0,03
Matériaux recyclables	0,79	-0,33	-0,28	0,27	-0,34
Déchets verts et biodéchets	0,75	0,16	0,55	0,30	0,16
Encombrants	0,52	0,74	0,11	-0,36	-0,24
Déchets dangereux	0,83	0,05	-0,42	-0,15	0,35

A.4 Stabilité selon la graine du k-means

Essai	ARI	Silhouette
k-means, graine 0	0,968	0,312
k-means, graine 1	1,000	0,315
k-means, graine 2	0,805	0,317
k-means, graine 3	0,968	0,312
k-means, graine 4	1,000	0,315
k-means, graine 5	0,968	0,312
k-means, graine 6	1,000	0,315
k-means, graine 7	0,968	0,312
k-means, graine 8	0,813	0,319
k-means, graine 9	1,000	0,315

Annexe B. Guide d'utilisation

Le volet clustering se lance comme le reste du projet, au choix dans Google Colab ou sur Linux.

Option 1 : Google Colab, sans rien installer

Le notebook `dechets/notebooks/projet_dechets.ipynb` rejoue tout le projet : la partie supervisée, puis la partie clustering (*Partie 2*), avec les explications et toutes les figures de ce rapport. Ouvert dans Google Colab, il télécharge lui-même le dépôt et les données :

- ouvrir l'adresse ci-dessous (ou le bouton « Open in Colab » du README du dépôt) ;
- lancer *Exécution* > *Tout exécuter* ;
- la partie clustering commence à la section 11 du notebook.

```
https://colab.research.google.com/github/Rxdy/ML-DMA/blob/main/
dechets/notebooks/projet_dechets.ipynb
```

Option 2 : Linux, testé sur Ubuntu 22.04 et 24.04

```
sudo apt update && sudo apt install -y git make python3 python3-venv
git clone https://github.com/Rxdy/ML-DMA.git
cd ML-DMA
make installer          # crée .env et installe les dépendances
make non-supervise     # scripts 12 et 13 : tout le clustering
```

Commande	Script	Ce qu'elle fait
<code>make profils</code>	12	Choix des variables, coude, silhouette, 4 groupes, profils, carte
<code>make analyses-profils</code>	13	Corrélations, ACP, nuages de points, silhouette par département, robustesse
<code>make non-supervise</code>	12 et 13	Tout le volet clustering
<code>make all</code>	01 à 13	Tout le projet, supervisé et non supervisé

Les résultats s'affichent dans la console et sont enregistrés dans `dechets/data/processed/` (tableaux `clustering_*.csv`) et `dechets/data/figures/` (figures `clustering_*.png`). Le raisonnement détaillé est aussi résumé dans `dechets/CLUSTERING.md`.