MACHINE LEARNING · DONNÉES PUBLIQUES ADEME ET INSEE

Les déchets des départements français

Prédire la production de déchets ménagers par habitant (apprentissage supervisé), puis découvrir des profils de départements selon ce que leurs habitants jettent (apprentissage non supervisé).

ALVES Rudy, ANTHONY Josselin, BENASSIE Noé, TAVERNIER Florian · iRUP Alternance · septembre 2026 · github.com/Rxdy/ML-DMA

Sommaire

PARTIE 1
Explorer
Les données, le thème, ce qu'on peut en faire.

PARTIE 2
Prédire et évaluer
Problématique supervisée, X et Y, modèles, test, performance et géolocalisation des erreurs.

PARTIE 3
Segmenter
K-means, choix des variables, interprétation des clusters.

PARTIE 4
Conclusions
Prise de recul, limites, pistes d'amélioration.

En bref

0,716
R^2 du meilleur modèle sur le test. La règle « comme à l'enquête précédente » obtient 0,702.

94,9 %
de l'importance des variables portée par la valeur de l'enquête précédente.

4 profils
de départements trouvés sans aucune information géographique.

100
départements classés, sur 5 types de déchets en kg par habitant.

- **Supervisé.** Les modèles battent largement la moyenne mais pas la règle naïve : la production par habitant d'un département change très peu d'une enquête à l'autre.
- **Non supervisé.** Les départements se répartissent en 4 profils, qui dessinent une géographie : le Grand Ouest, les grandes agglomérations, la Méditerranée et la Corse, et une France intermédiaire.
- **Lien entre les deux.** Les profils expliquent pourquoi les niveaux diffèrent durablement entre départements, mais pas comment ils évoluent d'une enquête à l'autre.

PARTIE 1

Explorer : les données et leur thème

Le thème et ce qu'on peut en faire

Chaque département français produit des déchets ménagers et assimilés (DMA) : ordures ménagères, recyclables, déchets verts, encombrants, déchets dangereux. L'ADEME les recense dans la base SINOE, enquête après enquête. Ces tonnages, croisés avec la population (et le revenu, source INSEE), répondent à deux questions de nature différente.

PRÉDIRE	SEGMENTER	DÉCIDER
Quelle quantité par habitant un département produira-t-il à la prochaine enquête ? C'est l'apprentissage supervisé : une réponse connue pour le passé sert d'exemple.	Les départements se ressemblent-ils par ce qu'ils jettent ? C'est l'apprentissage non supervisé : aucune réponse attendue, on cherche des groupes.	Un territoire qui sait où il se situe adapte sa collecte, son tri et son compostage.

Les données

Toutes les sources sont publiques (data.gouv.fr, licence Ouverte 2.0). Les fichiers bruts sont inclus dans le dépôt : aucun téléchargement n'est nécessaire pour rejouer le projet.

FICHIER	PRODUCTEUR	LIGNES	PÉRIODE	UTILISATION
`sinoe_dma.csv`	ADEME (SINOE)	14 660	2009–2021	Tonnage par département, type de déchet et traitement
`sinoe_chiffres_cles_hors_gravats.csv`	ADEME (SINOE)	800	2009–2023	Base de la régression
`sinoe_chiffres_cles_avec_gravats.csv`	ADEME (SINOE)	701	2009–2021	Contrôle des populations, puis écarté
`insee_revenu_median_dep_2013_2021.csv`	INSEE (Filosofi)	491	2013–2021	Test du revenu médian

Vérifications faites à l'exploration : aucune valeur manquante, aucun doublon (lignes identiques, mais aussi clés répétées avec des valeurs différentes). L'enquête SINOE est biennale, d'où les seules années impaires : ce n'est pas un trou à combler. On a gardé le fichier « hors gravats », car les gravats viennent surtout des chantiers et pas du comportement des ménages (écart-type du ratio de 100,6 kg avec gravats contre 80,3 kg sans).

PARTIE 2

Prédire et évaluer : l'apprentissage supervisé

Problématique : X et Y

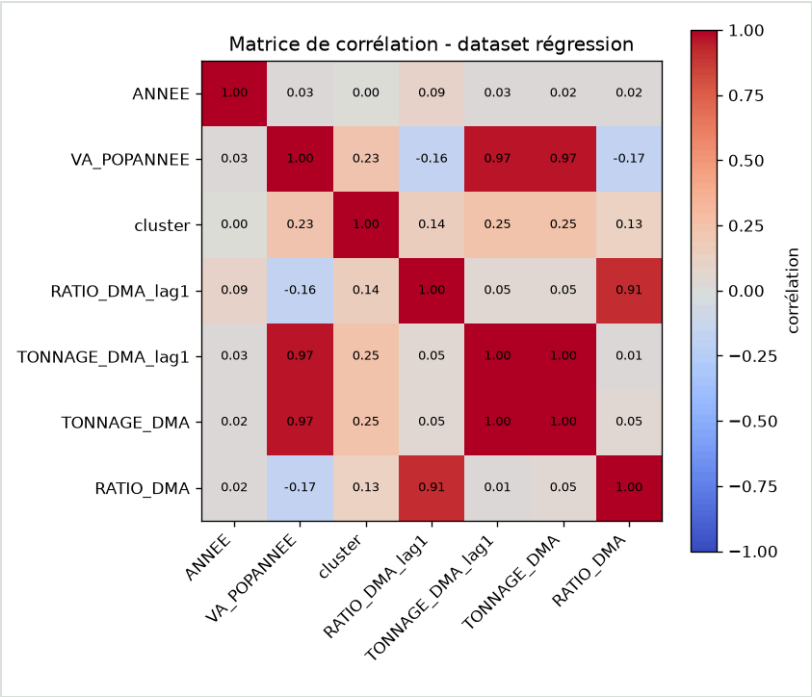
Peut-on prédire la quantité de déchets ménagers par habitant d'un département à la prochaine enquête, à partir des enquêtes précédentes ? C'est une régression : la cible est une valeur continue, connue pour les années passées.

RÔLE	VARIABLE	CONTENU
Y (cible)	**RATIO_DMA**	**Déchets en kg par habitant, à prédire**
X	RATIO_DMA_lag1, TONNAGE_DMA_lag1	Ratio et tonnage de l'enquête précédente du même département
X	VA_POPANNEE	Population
X	cluster	Profil de traitement (4 clusters issus d'un k-means préalable)

> **Pourquoi le ratio (kg/habitant) et pas le tonnage ?** Le tonnage est corrélé à 0,97 avec la population. Le prédire reviendrait à réapprendre une multiplication, et le modèle aurait l'air excellent sans rien avoir appris d'utile. Le ratio retire l'effet de taille.

Corrélation avec la cible

VARIABLE	CORRÉLATION	LECTURE
RATIO_DMA_lag1 (enquête précédente)	0,91	Signal très fort : un département change peu en 2 ans
VA_POPANNEE (population)	−0,17	Faible : les départements peuplés produisent un peu moins par habitant
cluster (profil de traitement)	0,13	Faible
ANNEE	0,02	Quasi nul : l'année seule n'explique rien



Matrice de corrélation des variables retenues.

Préparation des données

- **Formats harmonisés.** Les fichiers « chiffres-clés » utilisent ; et la virgule décimale. Sans harmonisation, les nombres sont lus comme du texte.
- **Codes département sur 2 caractères** (`1` devient `01`). Sinon la jointure perd des départements sans aucun message d'erreur.
- **Doublons contrôlés aux jointures** (`validate="many_to_one"`, nombre de lignes comparé avant et après). Une clé en double multiplierait les lignes en silence et casserait le lag, ce qui ferait fuiter la cible.
- **Variables d'historique (lag).** Le ratio et le tonnage de l'enquête précédente du même département portent l'information temporelle (0,91), contrairement à l'année brute (0,02).
- **Année 2009 retirée** (101 lignes) : première enquête, donc sans historique. Il reste 699 lignes.
- **Découpage temporel, pas aléatoire.** Entraînement 2011–2019 (501 lignes), test 2021 et 2023 (198 lignes), jamais vus. Un découpage aléatoire mélangerait passé et futur.

Preprocessor et pipeline

NUMÉRIQUES	CATÉGORIELLE	PIPELINE
Population, ratio et tonnage précédents : `MinMaxScaler`, entre 0 et 1.	Le cluster est une typologie, pas une quantité : `OneHotEncoder`, 4 colonnes 0/1.	Preprocessor puis modèle en un seul objet, calibré sur le train seul.

La pipeline évite la fuite de données par construction : le min/max du scaler est calculé sur le train seulement, y compris à chaque pli de validation croisée. Tous les modèles reçoivent le même preprocessor, on ne change que le modèle.

Modèles comparés

MODÈLE	RÔLE
Baseline moyenne	Prédit toujours la moyenne du train. Plancher absolu.
Baseline naïve	Prédit « comme à l'enquête précédente », sans modèle. Le vrai repère à battre.
Régression linéaire	Simple et interprétable : une combinaison pondérée des variables.
Arbre de décision	Questions à seuil. Profondeur 4 choisie par validation croisée : sans limite, R^2 de 1,000 à l'entraînement contre 0,573 au test.
Random Forest	300 arbres de profondeur 6 au plus. Capte le non linéaire et donne l'importance des variables.

Résultats

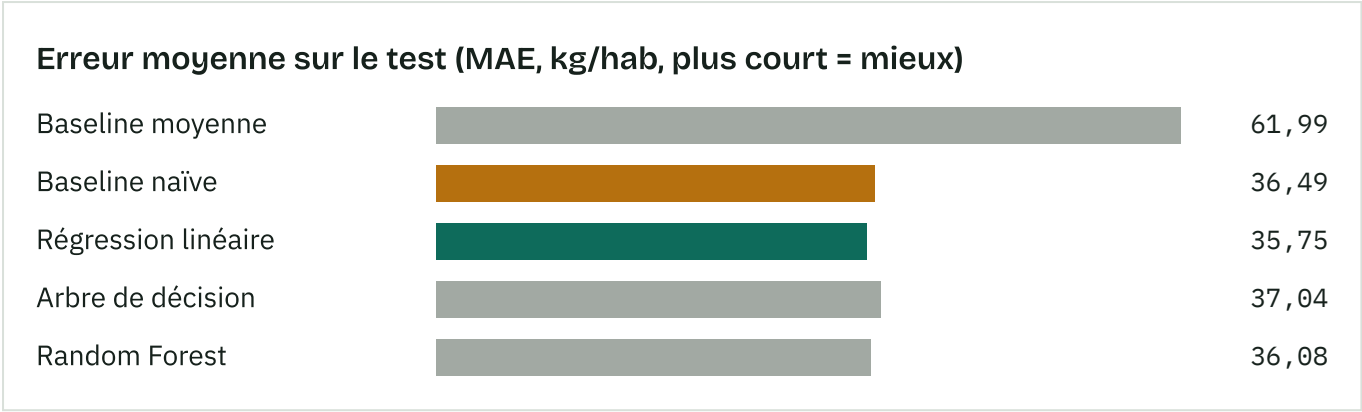
MAE : erreur moyenne en kg par habitant, la plus lisible. **RMSE** : même unité, pénalise davantage les grosses erreurs. **R^2** : part de la variation entre départements expliquée (1 = parfait, 0 = pas mieux que la moyenne).

Validation croisée temporelle (4 plis, 2013 à 2019)

MODÈLE	MAE	R^2
Baseline moyenne	62,23	−0,013 ± 0,009
Baseline naïve	**18,68**	**0,872 ± 0,043**
Régression linéaire	19,55	0,865 ± 0,039
Arbre de décision	21,85	0,840 ± 0,049
Random Forest	20,88	0,845 ± 0,045

Test final (2021 et 2023)

MODÈLE	MAE	RMSE	R^2
Baseline moyenne	61,99	82,14	−0,010
Baseline naïve	36,49	44,58	0,702
Régression linéaire	**35,75**	**43,53**	**0,716**
Arbre de décision	37,04	45,58	0,689
Random Forest	36,08	44,36	0,705



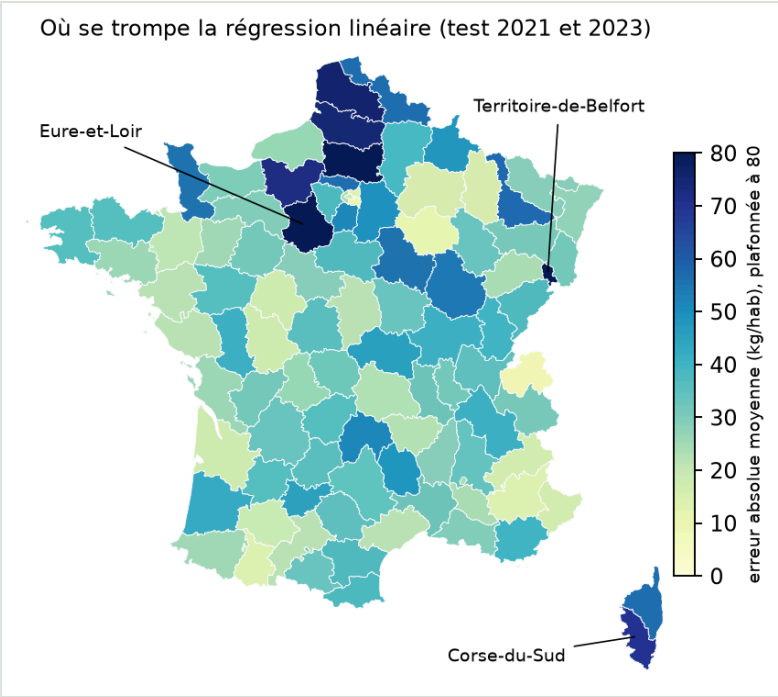
Aucun modèle ne bat réellement la baseline naïve. Sur le test, la régression linéaire se trompe de 0,74 kg/hab de moins (intervalle de confiance à 95 % par bootstrap : 0,14 à 1,34). Le gain est réel au sens statistique mais minuscule : 2 % de l'erreur, pour un ratio moyen d'environ 520 kg/hab. Elle ne fait mieux que sur 54 % des départements-années. Réentraînée sur la seule variable précédente, elle donne `ratio ≈ 0,97 × ratio précédent + 17` : presque la valeur précédente telle quelle. On retient la régression linéaire, plus simple que la forêt, en sachant que la règle naïve fait aussi bien.

Interprétation

- **Presque toute l'information est dans la valeur précédente** (94,9 % de l'importance dans la forêt). Population et type de traitement ne bougent pas dans le temps : ils ne peuvent pas expliquer un changement.
- **Plus de lignes n'aiderait pas.** Avec 10 %, 50 % puis 100 % du train, le R^2 reste entre 0,70 et 0,72. La limite vient du contenu des variables, pas du volume.
- **La baisse de 0,865 (validation croisée) à 0,716 (test) n'est pas du surapprentissage.** La baseline naïve, qui n'apprend rien, chute de la même façon : son R^2 passe de 0,82 à 0,93 sur 2011–2019 à 0,81 en 2021, puis 0,53 en 2023. Les années de test marquent une rupture (pic en 2021, baisse nette en 2023). Cause non identifiable avec ces données ; hypothèses non vérifiées : Covid et extension des consignes de tri.
- **Le revenu médian n'aide pas** : R^2 de 0,885 avec contre 0,887 sans, sur 2015–2021.

Géolocalisation des erreurs

Où le modèle se trompe-t-il ? La carte montre l'erreur absolue moyenne de la régression linéaire par département sur le test. Les erreurs ne sont pas réparties au hasard.



Erreur absolue moyenne par département, test 2021 et 2023. Les trois cas les plus marqués sont nommés. Outre-mer non représenté.

RÉGION	ERREUR MOYENNE SIGNÉE (KG/HAB)
Corse	**+51,8**
Nouvelle-Aquitaine	+15,2
Grand Est	+14,4
Île-de-France	+14,2
Normandie	−0,9

Positif : le modèle surestime. Moyenne par région sur 2021 et 2023 ; sélection des extrêmes, les 14 régions sont dans le dépôt.

- **Une erreur surtout commune à tous les départements.** Le modèle sous-estime de 22 kg/hab en 2021 et surestime de 43 kg/hab en 2023, année où 97 % des départements baissent. Il manque une information nationale qui varie dans le temps. Connaître l'évolution nationale ferait passer la MAE de 36,5 à 19,9 et le R^2 de 0,70 à 0,88.
- **Un biais local fort en Corse** (+51,8 kg/hab). Hypothèse non vérifiée : la population touristique n'est pas comptée dans les habitants.

Deux départements à regarder de près : Eure-et-Loir et Territoire-de-Belfort

Ce sont les deux départements où la régression se trompe le plus (erreur moyenne de 123 et 110 kg/hab). Voici leur série, avec l'Oise comme point de comparaison.

RATIO DMA (KG/HAB)	2017	2019	2021	2023
Eure-et-Loir	567	513	609	454
Territoire-de-Belfort	524	502	603	479
Oise (comparaison)	569	559	607	492

- **Ce que montrent nos données.** Les deux départements montent fortement en 2021 (+96 et +101 kg/hab), puis chutent en 2023 (−155 et −124). Leur population varie à peine : c'est donc la quantité de déchets déclarée qui a changé, pas le nombre d'habitants. Le modèle prédit « comme l'enquête précédente » : il rate le saut vers le haut en 2021, puis rate la chute en 2023, d'où ces grosses erreurs.
- **Ce que cela ne prouve pas.** Ce mouvement (pic en 2021, baisse en 2023) existe presque partout : 97 % des départements baissent en 2023, et l'Oise fait la même chose. Ces deux départements le font avec plus d'ampleur, ce qui ne suffit pas à dire que leurs chiffres sont faux.
- **Ce que l'on peut conclure.** Seulement ceci : dans les données dont nous disposons, ces deux séries s'écartent plus que les autres. Nous ne savons pas si la cause est réelle (changement de collecte, nouvelle déchèterie, événement ponctuel) ou administrative (changement de périmètre ou de méthode de déclaration). Pour trancher, il faudrait interroger la source, l'ADEME ou la collectivité.

PARTIE 3

Segmenter : le k-means et les profils de départements

Problématique

Il n'y a plus de réponse à prédire. On cherche des groupes de départements qui se ressemblent. **Existe-t-il des profils types selon la façon dont leurs habitants jettent leurs déchets ?**

Choix des variables

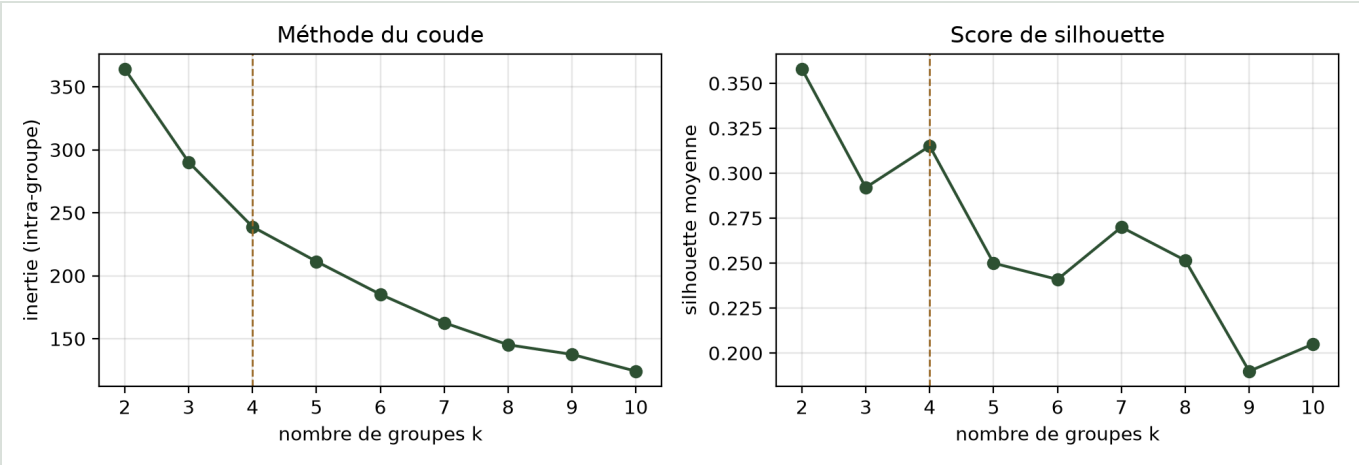
Le clustering regroupe sur les variables qu'on lui donne : leur choix décide de ce que « se ressembler » veut dire. On retient la **production** (ce que les habitants jettent). Le traitement a déjà été clusterisé dans la partie supervisée, et mélanger les deux compterait deux fois la même information (déchets verts et compostage : 0,71 ; recyclables et recyclage : 0,63).

VARIABLE (KG/HABITANT)	MOYENNE	MIN	MAX
Ordures ménagères résiduelles (OMR)	239	135	459
Matériaux recyclables	132	21	201
Déchets verts et biodéchets	88	1	280
Encombrants	78	35	122
Déchets dangereux	10	0,2	28

- **Écartés :** gravats (chantiers), « autres » (presque vide, très irrégulier), total (somme des autres, donc doublon).
- **Gardés pour interpréter après coup :** population, revenu médian, traitement.
- **Kg par habitant, pas tonnes**, pour comparer Paris et la Lozère.
- **Une ligne par département :** moyenne des enquêtes 2019 et 2021, les plus récentes détaillées par type de déchet. 100 départements (Mayotte n'a pas de détail).
- **Standardisation.** Le k-means compare des distances : sans elle, les ordures ménagères (~240 kg) pèseraient 24 fois plus que les déchets dangereux (~10 kg).

Combien de groupes ? Coude et silhouette

L'inertie mesure l'éloignement des départements au centre de leur groupe ; elle baisse toujours quand k augmente, on cherche le coude. La silhouette va de −1 à 1 : proche de 1, le département est bien à sa place. Chaque k-means est lancé 20 fois avec une graine fixe, car le résultat dépend du point de départ.

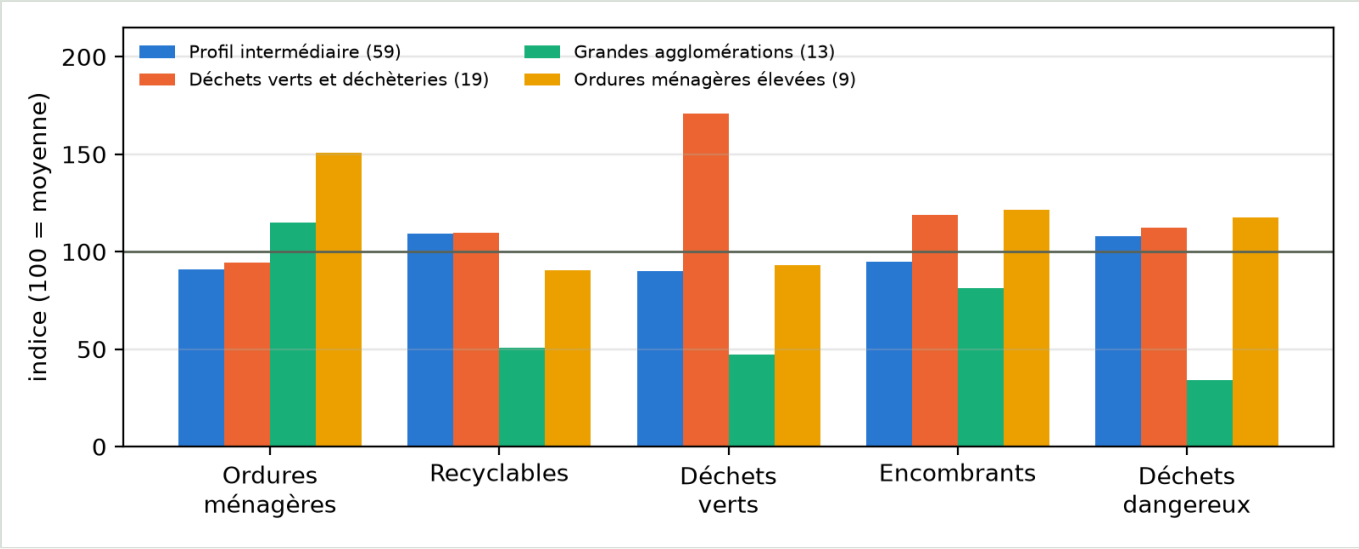


Inertie (coude) et silhouette pour k de 2 à 10.

K	INERTIE	BAISSE	SILHOUETTE	PLUS PETIT GROUPE
2	364	—	0,358	21
3	290	−20 %	0,292	13
4	**239**	**−18 %**	**0,315**	**9**
5	211	−12 %	0,250	10
6	185	−12 %	0,241	1
8	145	−11 %	0,252	1
10	124	−10 %	0,205	1

Décision : k = 4. Le coude est à 4 et la silhouette y fait un pic local. k = 2 a la meilleure silhouette (0,358) mais ne sépare que les grandes villes et la Méditerranée du reste. À partir de k = 6, un groupe ne contient plus qu'un département (la Guadeloupe) : le k-means isole un cas extrême au lieu de former un profil.

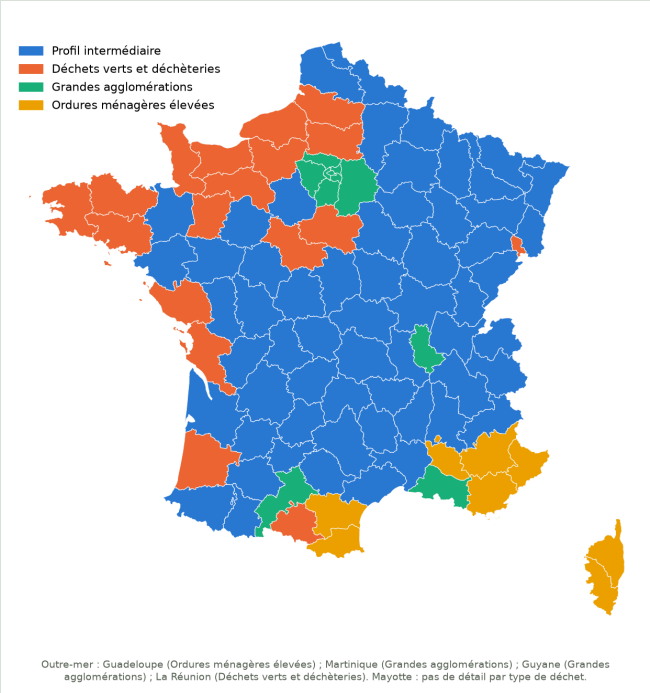
Les 4 groupes



Profils des 4 groupes. Indice 100 = moyenne des 100 départements.

GROUPE	DÉP.	OMR	RECYCL.	VERTS	ENCOMB.	DANG.	TOTAL	SILH.
Profil intermédiaire	59	217	144	80	74	11	528	0,39
Déchets verts et déchèteries	19	226	145	151	93	12	629	0,14
Grandes agglomérations	13	275	67	42	64	3	456	0,34
Ordures ménagères élevées	9	361	120	82	95	12	674	0,16
Moyenne nationale	100	239	132	88	78	10		

kg par habitant. Total hors gravats, issu du fichier « chiffres-clés ».



Carte des 4 groupes. Aucune information géographique n'a été donnée au modèle.

Profil intermédiaire — 59 dép.

La France « moyenne » : Centre, Est, Massif central, une grande partie du Sud-Ouest. Un peu moins d'ordures ménagères, un peu plus de recyclables. Le groupe le plus cohérent.

Revenu 21 900 € · incinération 21 % · stockage 22 %

Déchets verts et déchèteries — 19 dép.

Surtout le Grand Ouest, de la Bretagne aux Landes. Déchets verts 1,7 fois la moyenne (151 kg/hab, 280 dans les Landes). Habitat en maisons avec jardin (hypothèse non vérifiée). Le groupe qui composte le plus.

Revenu 21 700 € · valorisation organique 22 %

Grandes agglomérations — 13 dép.

Les 8 départements d'Île-de-France, plus Lyon, Marseille, Toulouse. Le moins de déchets au total (456 kg/hab) mais le moins de tri : deux fois moins de recyclables et de déchets verts, trois fois moins de dangereux. Martinique et Guyane les rejoignent pour une autre raison.

1,4 million d'habitants en moyenne · revenu 23 000 € · incinération 49 %

Ordures ménagères élevées — 9 dép.

Le pourtour méditerranéen et la Corse. Ordures ménagères 1,5 fois la moyenne (361 kg/hab, 459 en Corse-du-Sud) et le plus de déchets au total (674). Hypothèse : le tourisme, car les touristes produisent des déchets sans être comptés dans la population résidente.

Revenu 20 700 € · stockage 37 %

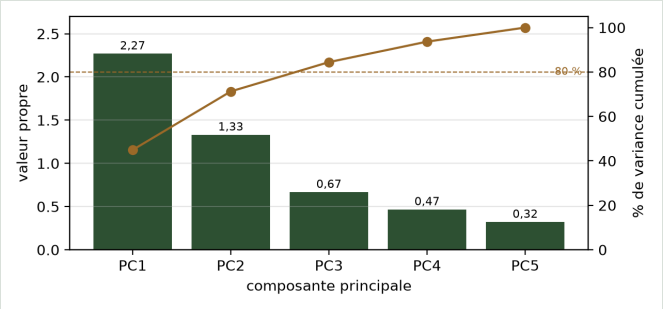
Réduire la dimension : la PCA

La PCA transforme les 5 variables corrélées en composantes non corrélées, triées par quantité d'information : standardisation, matrice de covariance, valeurs et vecteurs propres, sélection, projection.

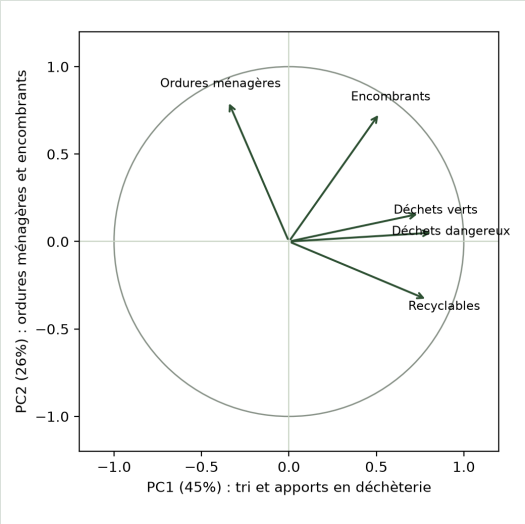
COMPOSANTE	VALEUR PROPRE	VARIANCE	CUMUL
PC1	2,27	44,9 %	44,9 %
PC2	1,33	26,3 %	71,3 %
PC3	**0,67**	**13,2 %**	**84,4 %**
PC4	0,47	9,2 %	93,7 %
PC5	0,32	6,3 %	100 %

3 composantes retenues : l'éboulis fait un coude après PC3 et la règle des 80 à 90 % est atteinte (84 %).

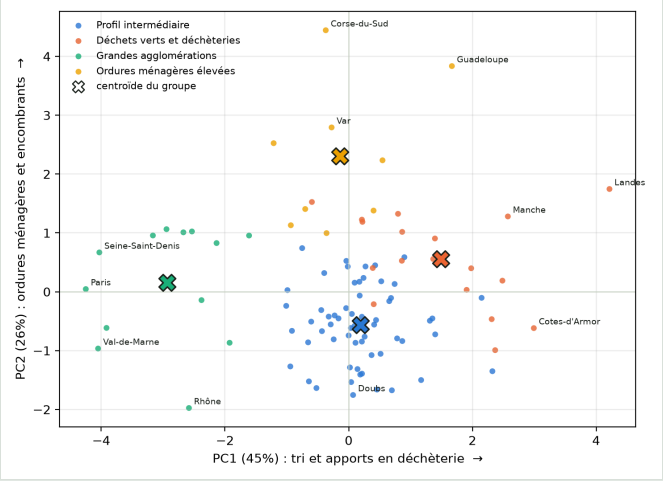
- **PC1 (45 %)** : le tri et les apports en déchèterie, face à la poubelle ordinaire.
- **PC2 (26 %)** : le volume d'ordures ménagères et d'encombrants.
- **PC3 (13 %)** : les déchets verts plutôt que le tri des emballages et des déchets dangereux.



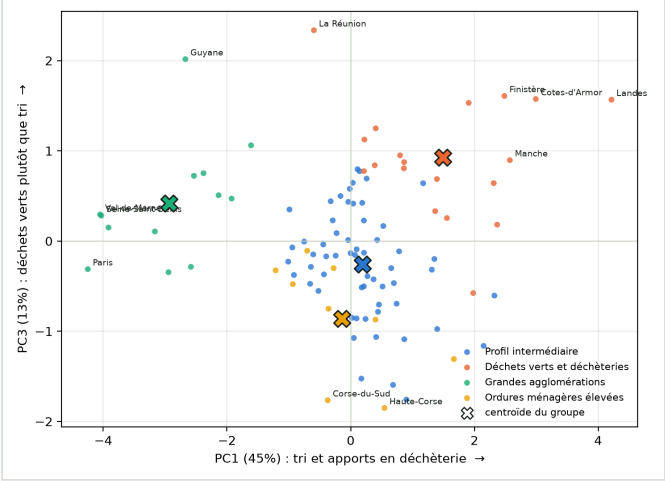
Éboulis des valeurs propres.



Cercle des corrélations.



Plan PC1-PC2 avec les centroïdes (croix).

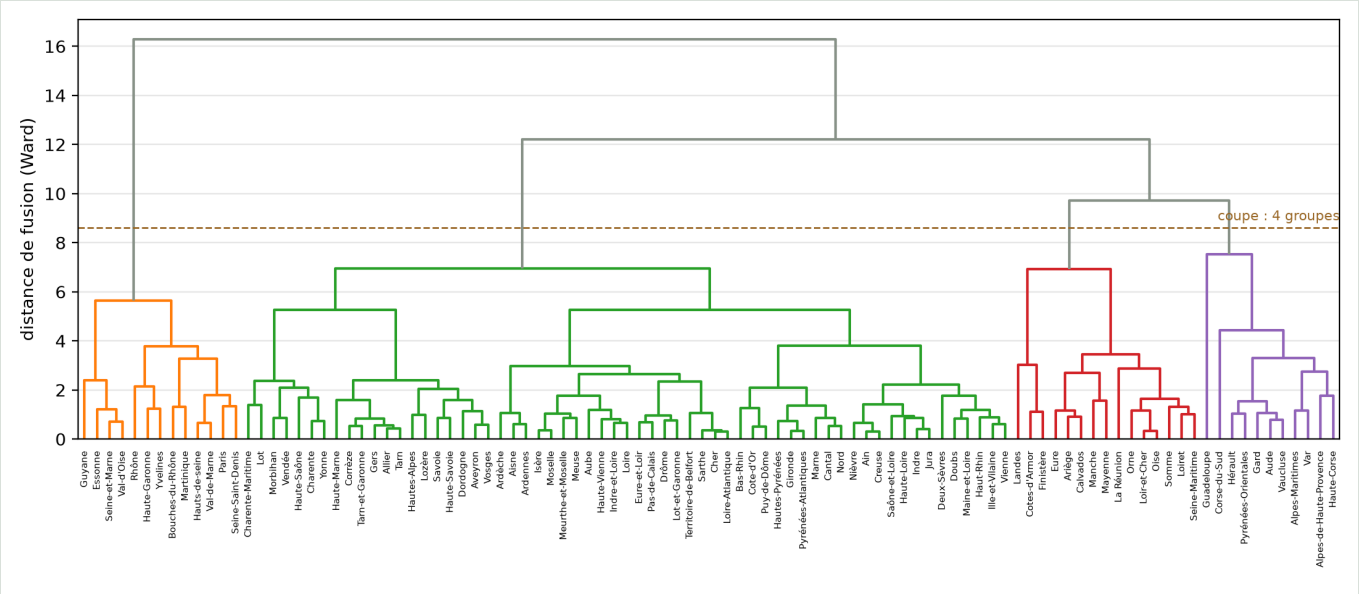


Plan PC1-PC3 : sépare l'Ouest de la Méditerranée.

Deux autres méthodes

Clustering hiérarchique (Ward)

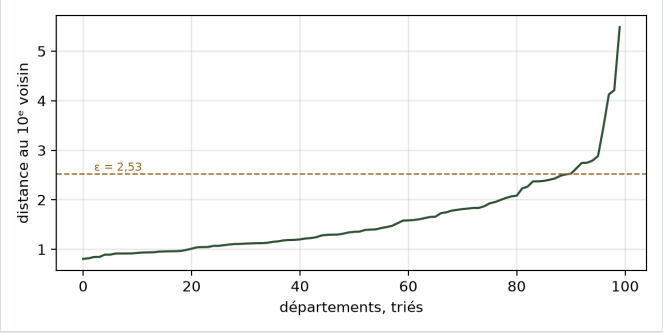
Chaque département part seul, puis les deux groupes les plus proches fusionnent à chaque étape. Les sauts de hauteur sont grands jusqu'à 4 groupes puis s'effondrent (2,19 à la coupe en 4, puis 0,58 et 0,02) : 4 est la coupe la plus fine qui garde un sens. Accord avec le k-means : ARI de 0,83.



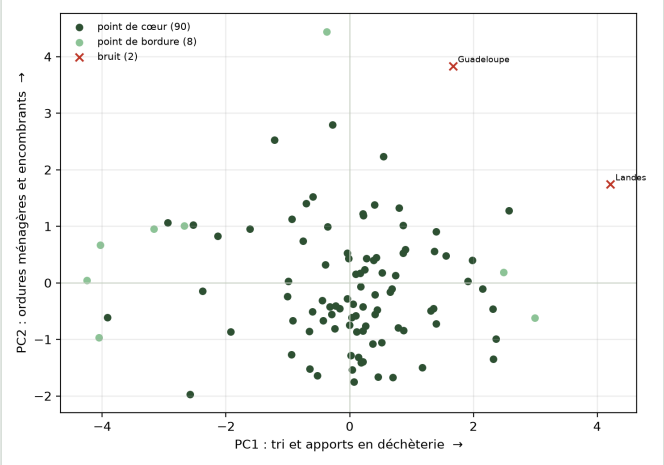
Dendrogramme (liaison de Ward).

DBSCAN (densité)

Réglages : MinPts = 10 (deux fois le nombre de variables), ε = 2,53 au coude de la courbe des k-distances. Résultat : **un seul groupe dense** et 2 points de bruit, les Landes et la Guadeloupe. Aucun réglage testé ne donne plus d'un groupe. Les départements forment un **continuum**, pas des îlots : les 4 profils sont des découpages utiles d'un même nuage, et DBSCAN sert ici à repérer les cas extrêmes.



Courbe des k-distances.



DBSCAN : un groupe et deux points de bruit.

PARTIE 4

Prise de recul : conclusions, limites, pistes

Ce qu'il faut retenir

- Prédire la production de déchets d'un département revient presque à recopier l'enquête précédente. Les modèles apprennent cette règle (R^2 de 0,716 contre 0,702) mais n'en savent pas plus.
- Les départements se répartissent en 4 profils, choisis parce que le coude et la silhouette s'accordent sur k = 4, et confirmés par le clustering hiérarchique.
- Ces profils sont géographiques alors que le modèle n'a reçu que des kilos de déchets. Deux facteurs semblent structurer la carte : le type d'habitat et le tourisme.
- Aucun profil n'est meilleur qu'un autre : les agglomérations produisent le moins mais trient le moins ; l'Ouest produit beaucoup, surtout des déchets verts qu'il composte.
- Les deux volets se complètent : les profils expliquent pourquoi les niveaux diffèrent durablement, la prédiction montre que ces niveaux bougent peu.

Limites

Du côté supervisé

- Seulement 8 enquêtes, une tous les 2 ans, et rien pour les années paires.
- Variables trop stables : population et type de traitement ne peuvent pas expliquer un changement.
- Une rupture sur les années de test (pic en 2021, baisse nette en 2023) dont la cause reste inconnue. Hypothèses non vérifiées : Covid et extension des consignes de tri.
- Périmètres légèrement différents : le clustering de traitement inclut les gravats, la cible de régression les exclut (écart documenté et assumé).

Du côté non supervisé

- **Structure modérée.** Silhouette de 0,315 : des groupes réels mais qui se chevauchent, plutôt un nuage avec des tendances. DBSCAN ne trouve qu'un seul groupe dense.
- **Deux groupes fragiles** (silhouette 0,14 et 0,16), et quatre cas frontières à ne pas sur-interpréter : Aude, Loiret, Vendée, Territoire-de-Belfort.
- **Sensibilité aux valeurs extrêmes** : Landes, Corse-du-Sud, Guadeloupe, Guyane.
- **Robustesse.** ARI de 0,81 à 1 selon la graine ; 0,65 sans l'outre-mer (frontières déplacées, cœurs stables). Les départements d'outre-mer ont probablement d'autres causes.
- **Une photo, pas un film** (moyenne 2019–2021), et des explications qui restent des hypothèses.

Pistes d'amélioration

Des données plus fines, dans le temps et dans l'espace

DANS LE TEMPS	DANS L'ESPACE	PAR ZONE
Des données mensuelles au lieu d'une enquête tous les 2 ans : 12 points par an au lieu d'un demi-point, de quoi voir les ruptures (2021, 2023) et la saisonnalité, notamment touristique.	Des données par ville au lieu du département : on pourrait relier la production à la taille de la ville et repérer des écarts à l'intérieur d'un même département.	Chaque ville serait rattachée à sa zone et à son département : en regroupant les villes, on retrouve le compte rendu départemental et on mesure d'où viennent ses écarts.

> **Le prix à payer.** Ces données n'existent pas dans les bases publiques utilisées ici. Les obtenir demande davantage de moyens : un recueil mensuel auprès de chaque collectivité qui collecte, avec un format commun. Le bénéfice attendu est une meilleure gestion des déchets et une vue sur les écarts entre territoires, que les moyennes départementales cachent.

Autres pistes

- **Ajouter une information nationale qui varie dans le temps** : c'est la piste prioritaire, car l'erreur est surtout commune à tous les départements.
- **Des variables locales qui évoluent** : tarification incitative, extension des consignes de tri, part de population urbaine.
- **Des variables INSEE sur le logement et le tourisme**, pour vérifier les hypothèses d'habitat et de tourisme, et corriger le biais corse.
- **Vérifier à la source** les séries d'Eure-et-Loir et de Territoire-de-Belfort, qui s'écartent plus que les autres, avant de les corriger ou de les exclure.
- **Traiter l'outre-mer à part**, avec ses propres variables.

Usages concrets des profils

Améliorer le tri en habitat collectif dans les agglomérations, développer le compostage de proximité dans l'Ouest, adapter la collecte aux pics touristiques en Méditerranée.

Reproduire

Sur Ubuntu : `sudo apt install git make python3 python3-venv`, puis `git clone https://github.com/Rxdy/ML-DMA.git`, `make installer` et `make all`. Sans rien installer, le notebook s'ouvre dans Google Colab.