MACHINE LEARNING · DONNÉES PUBLIQUES ADEME ET INSEE

Les déchets des départements français

Prédire la production de déchets ménagers par habitant (apprentissage supervisé), puis découvrir des profils de départements selon ce que leurs habitants jettent (apprentissage non supervisé).

ALVES Rudy, ANTHONY Josselin, BENASSIE Noé, TAVERNIER Florian · iRUP Alternance · septembre 2026 · github.com/Rxdy/ML-DMA

Sommaire

PARTIE 1
Explorer
Les données, le thème, ce qu'on peut en faire. **4 min**

PARTIE 2
Prédire et évaluer
Rappel : problématique, X et Y, modèles, performance et géolocalisation des erreurs. **5 min**

PARTIE 3
Segmenter
K-means, choix des variables, interprétation des clusters, PCA, robustesse. **16 min**

PARTIE 4
Conclusions
Prise de recul, limites, pistes d'amélioration. **5 min**

Durée totale de la présentation : 30 minutes. La partie 2 a déjà été présentée au professeur avec son rapport PDF : elle sert ici de rappel.

En bref

0,716
R^2 du meilleur modèle sur le test. La règle « comme à l'enquête précédente » obtient 0,702.

94,9 %
de l'importance des variables portée par la valeur de l'enquête précédente.

4 profils
de départements trouvés sans aucune information géographique.

100
départements classés, sur 5 types de déchets en kg par habitant.

- **Supervisé.** Les modèles battent largement la moyenne mais pas la règle naïve : la production par habitant d'un département change très peu d'une enquête à l'autre.
- **Non supervisé.** Les départements se répartissent en 4 profils, qui dessinent une géographie : le Grand Ouest, les grandes agglomérations, la Méditerranée et la Corse, et une France intermédiaire.
- **Lien entre les deux.** Les profils expliquent pourquoi les niveaux diffèrent durablement entre départements, mais pas comment ils évoluent d'une enquête à l'autre.

PARTIE 1 · 4 MIN
Explorer : les données et leur thème

Le thème et ce qu'on peut en faire

Chaque département français produit des déchets ménagers et assimilés (DMA) : ordures ménagères, recyclables, déchets verts, encombrants, déchets dangereux. L'ADEME les recense dans la base SINOE, enquête après enquête. Ces tonnages, croisés avec la population (et le revenu, source INSEE), répondent à deux questions de nature différente.

PRÉDIRE	SEGMENTER	DÉCIDER
Quelle quantité par habitant un département produira-t-il à la prochaine enquête ? C'est l'apprentissage supervisé : une réponse connue pour le passé sert d'exemple.	Les départements se ressemblent-ils par ce qu'ils jettent ? C'est l'apprentissage non supervisé : aucune réponse attendue, on cherche des groupes.	Un territoire qui sait où il se situe adapte sa collecte, son tri et son compostage.

Les données

Toutes les sources sont publiques (data.gouv.fr, licence Ouverte 2.0). Les fichiers bruts sont inclus dans le dépôt : aucun téléchargement n'est nécessaire pour rejouer le projet.

FICHIER	PRODUCTEUR	LIGNES	PÉRIODE	UTILISATION
`sinoe_dma.csv`	ADEME (SINOE)	14 660	2009–2021	Tonnage par département, type de déchet et traitement
`sinoe_chiffres_cles_hors_gravats.csv`	ADEME (SINOE)	800	2009–2023	Base de la régression
`sinoe_chiffres_cles_avec_gravats.csv`	ADEME (SINOE)	701	2009–2021	Contrôle des populations, puis écarté
`insee_revenu_median_dep_2013_2021.csv`	INSEE (Filosofi)	491	2013–2021	Test du revenu médian

Vérifications faites à l'exploration : aucune valeur manquante, aucun doublon (lignes identiques, mais aussi clés répétées avec des valeurs différentes). L'enquête SINOE est biennale, d'où les seules années impaires : ce n'est pas un trou à combler. On a gardé le fichier « hors gravats », car les gravats viennent surtout des chantiers et pas du comportement des ménages (écart-type du ratio de 100,6 kg avec gravats contre 80,3 kg sans).

PARTIE 2 · 5 MIN **Rappel : prédire et évaluer**

Le problème et la méthode

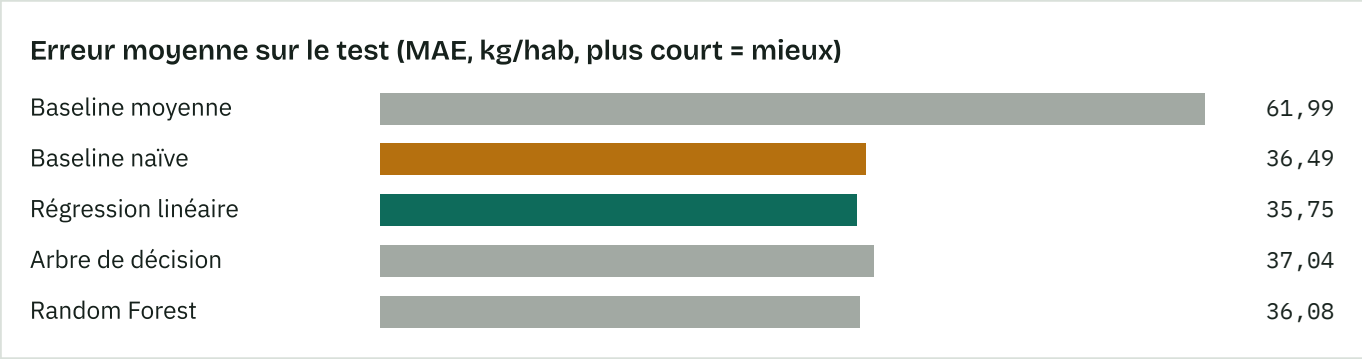
Cette partie a déjà été présentée ; elle est détaillée dans le rapport supervisé. L'idée tient en une question : peut-on prédire la quantité de déchets ménagers par habitant d'un département à la prochaine enquête, à partir des enquêtes précédentes ? La cible (Y) est ce ratio en kg par habitant, et non le tonnage brut, qui est corrélé à 0,97 avec la population : prédire le tonnage reviendrait à réapprendre une multiplication. Les variables d'entrée (X) sont le ratio et le tonnage de l'enquête précédente, la population, et le profil de traitement du département, issu d'un premier k-means.

Pour que le test ressemble à une vraie prédiction, nous avons découpé dans le temps et non au hasard : l'entraînement porte sur 2011 à 2019, le test sur 2021 et 2023, que le modèle n'a jamais vus. Les transformations (mise à l'échelle des nombres, encodage du cluster) sont regroupées dans une pipeline, calibrée sur l'entraînement seul, pour qu'aucune information du test ne fuite vers le modèle.

Les modèles et leur résultat

Nous avons comparé cinq modèles, de la baseline aux plus élaborés : la moyenne, une règle naïve (« comme à l'enquête précédente »), la régression linéaire, un arbre de décision et une Random Forest. Mesurées sur le test, leurs erreurs sont presque identiques.

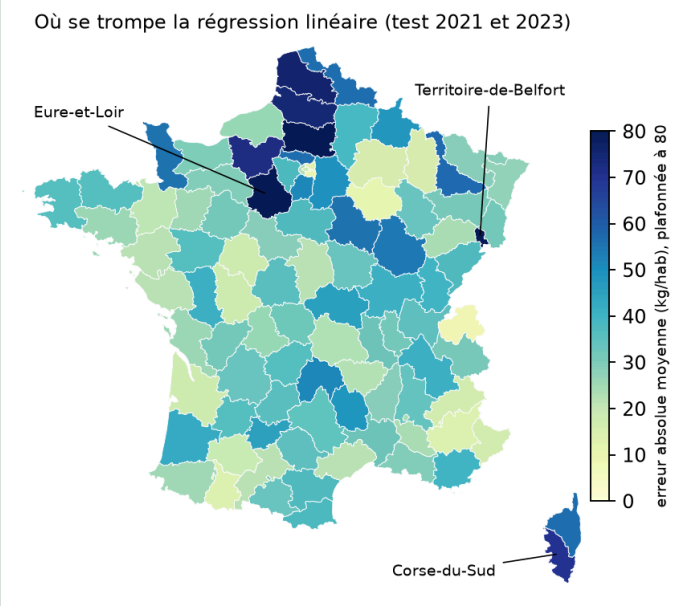
MODÈLE	MAE (KG/HAB)	RMSE	R^2
Baseline moyenne	61,99	82,14	−0,010
Baseline naïve	36,49	44,58	0,702
Régression linéaire	**35,75**	**43,53**	**0,716**
Arbre de décision	37,04	45,58	0,689
Random Forest	36,08	44,36	0,705



Tous battent largement la moyenne, mais aucun ne bat réellement la règle naïve. La régression linéaire ne se trompe que de 0,74 kg/hab de moins qu'elle (intervalle de confiance à 95 % de 0,14 à 1,34), soit 2 % de l'erreur, et elle ne fait mieux que sur 54 % des départements-années. Ce n'est pas un échec du modèle, c'est ce que révèlent les données : la production par habitant d'un département change très peu d'une enquête à l'autre, et la valeur précédente porte 94,9 % de l'importance des variables dans la forêt. La population et le profil de traitement ne varient presque pas dans le temps : ils ne peuvent pas expliquer un changement. Augmenter le nombre de lignes n'aiderait pas non plus, puisque le R^2 reste entre 0,70 et 0,72 que l'on entraîne sur 10 %, 50 % ou 100 % des données.

Où le modèle se trompe

La carte montre l'erreur absolue moyenne de la régression linéaire par département sur le test. Les erreurs ne sont pas réparties au hasard : la Corse ressort nettement (+51,8 kg/hab de surestimation en moyenne, contre 10 à 15 pour la plupart des régions), avec l'hypothèse, non vérifiée, que les touristes produisent des déchets sans être comptés dans la population résidente. Eure-et-Loir et Territoire-de-Belfort se distinguent aussi. Nous y revenons en conclusion, car leur cas éclaire la principale limite du modèle.



Erreur absolue moyenne par département, test 2021 et 2023. Outre-mer non représenté.

PARTIE 3 · 16 MIN **Segmenter : les profils de départements**

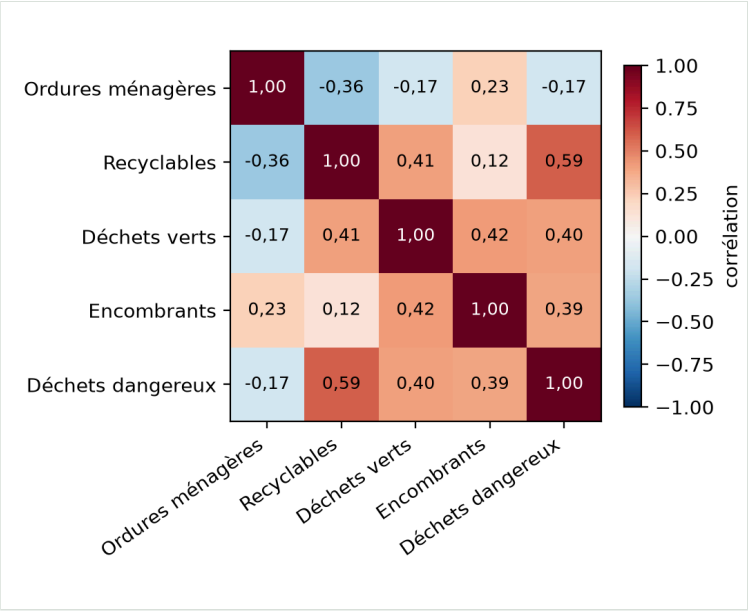
3.1 Une autre question, et le choix des variables 3 min

En supervisé, il y avait une réponse connue à prédire. Ici, il n'y en a pas : nous cherchons à découvrir des groupes de départements qui se ressemblent, sans qu'on leur dise lesquels. La question devient : **existe-t-il des profils types de départements selon la façon dont leurs habitants jettent leurs déchets ?** Le clustering regroupe des départements proches *sur les variables qu'on lui donne* : choisir les variables, c'est donc décider de ce que « se ressembler » veut dire.

Trois familles de variables étaient possibles : la production (ce que les habitants jettent), le traitement (ce que le territoire en fait) et le contexte (population, revenu). Nous avons retenu la production. Le traitement avait déjà été regroupé dans la partie supervisée, et mélanger les deux compterait deux fois la même information : les départements qui collectent beaucoup de déchets verts sont aussi ceux qui compostent beaucoup (corrélation de 0,71), et ceux qui collectent beaucoup de recyclables en recyclent beaucoup (0,63). Le contexte, lui, est gardé de côté pour *interpréter* les groupes après coup, ce qui est plus honnête que de le mêler au calcul.

VARIABLE RETENUE (KG/HABITANT)	MOYENNE	MIN	MAX
Ordures ménagères résiduelles (OMR, la poubelle « classique »)	239	135	459
Matériaux recyclables	132	21	201
Déchets verts et biodéchets	88	1	280
Encombrants	78	35	122
Déchets dangereux	10	0,2	28

Nous avons écarté les gravats, qui viennent surtout des chantiers et pas des habitants (même choix qu'en supervisé), la catégorie « autres », presque vide et très irrégulière, et le total par habitant, qui est la somme des autres variables et ferait donc doublon. Trois choix de mise en forme comptent ensuite. D'abord des kg par habitant et non des tonnes, pour pouvoir comparer Paris et la Lozère : en tonnes, les départements les plus peuplés écraseraient tout. Ensuite une seule ligne par département, obtenue en moyennant les enquêtes de 2019 et 2021, les plus récentes détaillées par type de déchet, ce qui lisse les écarts d'une enquête à l'autre et donne 100 départements (Mayotte n'a pas de détail). Enfin la standardisation : chaque variable est ramenée à une moyenne de 0 et un écart-type de 1, sans quoi les ordures ménagères (environ 240 kg) pèseraient 24 fois plus que les déchets dangereux (environ 10 kg) dans le calcul des distances et décideraient seules des groupes.



Corrélations entre les 5 variables retenues.

Avant de regrouper, nous avons vérifié que ces cinq variables ne se répètent pas. Deux variables corrélées au-delà de 0,8 porteraient presque la même information et pèseraient deux fois ; or aucune paire ne dépasse 0,6. Les plus liées sont les recyclables et les déchets dangereux (0,59), deux apports en déchèterie, puis les déchets verts et les encombrants (0,42). À l'inverse, les ordures ménagères baissent quand les recyclables montent (−0,36) : ce qui n'est pas trié finit dans la poubelle ordinaire. Deux logiques se dessinent déjà, le tri et les apports en déchèterie d'un côté, la poubelle ordinaire de l'autre.

3.2 Comment fonctionne le k-means

3 min

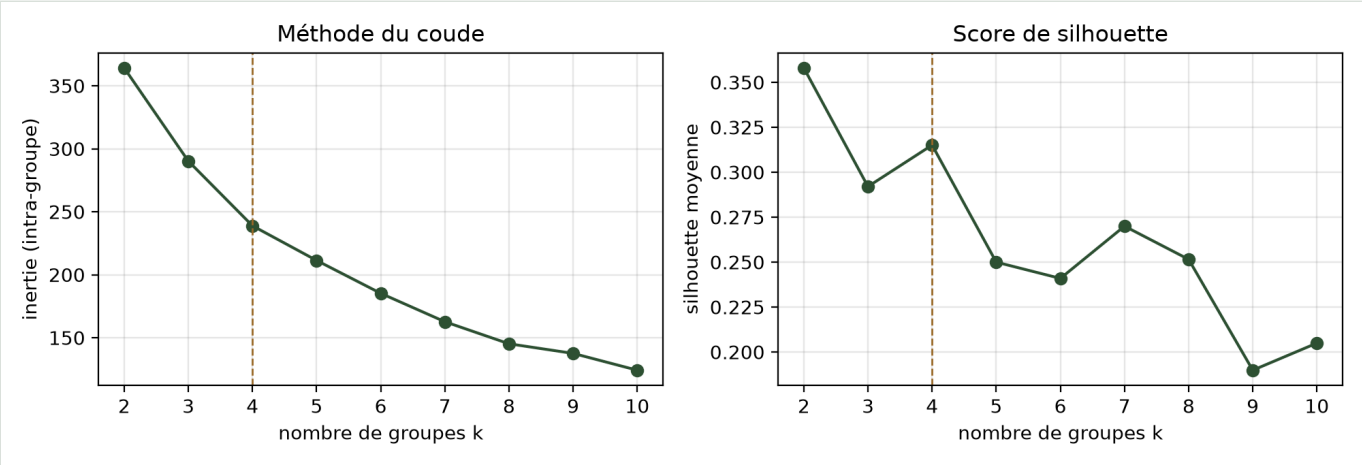
Le k-means forme k groupes de départements proches les uns des autres. « Proches » se mesure par une distance : nous avons utilisé la distance euclidienne, la ligne droite entre deux départements décrits par leurs 5 valeurs standardisées. C'est précisément pour cela qu'il fallait standardiser, puisqu'une distance additionne des écarts qui doivent être exprimés dans la même unité. La qualité d'un découpage se mesure par l'**inertie** (WCSS) : la somme des distances au carré entre chaque département et le centre de son groupe. Plus elle est faible, plus les groupes sont compacts.

1 · INITIALISATION	2 · AFFECTATION	3 · MISE À JOUR	4 · ITÉRATION
On tire au hasard k centres de départ.	Chaque département rejoint le groupe dont le centre est le plus proche.	Chaque centre est recalculé comme la moyenne des départements de son groupe.	On répète 2 et 3 jusqu'à ce que plus rien ne bouge.

La méthode est simple et rapide, ce qui joue pleinement ici : 100 départements et 5 variables se traitent en une fraction de seconde, de quoi tester k de 2 à 10 et de nombreux tirages. Elle a trois limites connues, que nous avons traitées une à une. Il faut choisir k à l'avance : nous avons utilisé le coude et la silhouette, puis le dendrogramme du clustering hiérarchique pour confirmer. Le résultat dépend du point de départ tiré au hasard : chaque k-means est lancé 20 fois, on garde le meilleur résultat, avec une graine fixe pour que ce soit reproductible, et nous avons vérifié la stabilité sur 10 autres graines. Enfin, le k-means suppose des groupes plutôt arrondis : nous avons standardisé pour que toutes les directions pèsent pareil et testé DBSCAN, qui n'a pas cette hypothèse.

3.3 Combien de groupes ? 2 min

Nous avons lancé le k-means pour k de 2 à 10 et regardé deux indicateurs. L'inertie baisse toujours quand on ajoute des groupes (avec autant de groupes que de départements, elle serait nulle) : on cherche donc le « coude », le point où ajouter un groupe ne la fait plus beaucoup baisser. La silhouette compare, pour chaque département, sa distance aux membres de son groupe et sa distance au groupe voisin. Elle va de −1 à 1 : proche de 1, le département est bien à sa place ; proche de 0, il est à la frontière ; négatif, il serait mieux dans un autre groupe.



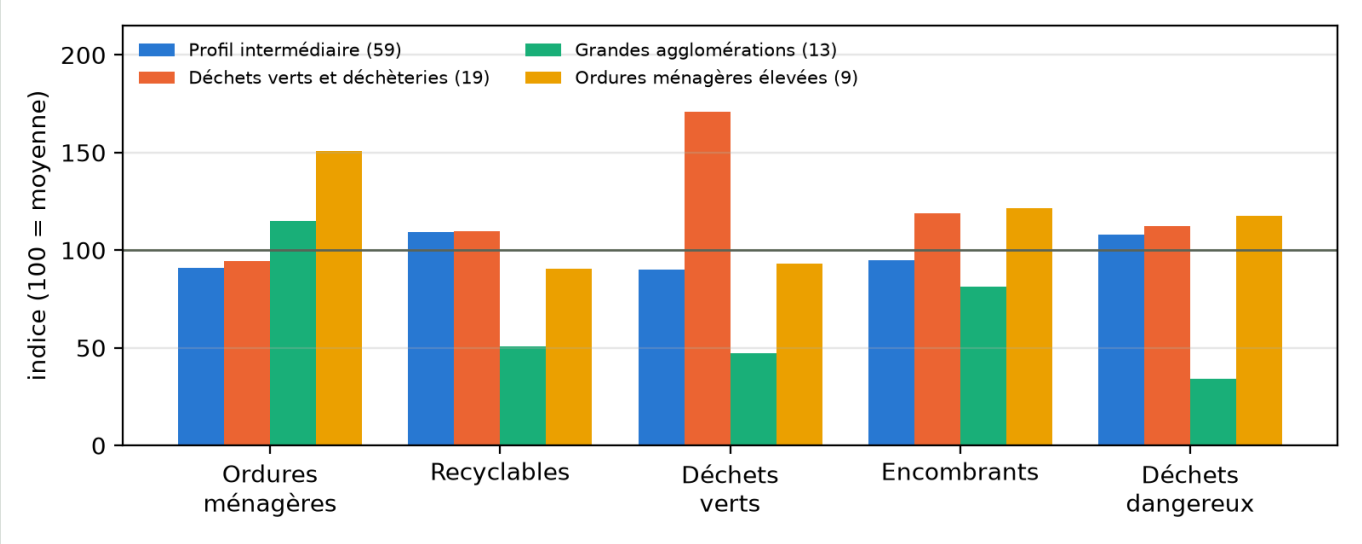
Inertie (coude) et silhouette pour k de 2 à 10.

K	INERTIE	BAISSE	SILHOUETTE	PLUS PETIT GROUPE
2	364	—	0,358	21
3	290	−20 %	0,292	13
4	**239**	**−18 %**	**0,315**	**9**
5	211	−12 %	0,250	10
6	185	−12 %	0,241	1
7	163	−12 %	0,270	1
8	145	−11 %	0,252	1
9	138	−5 %	0,190	1
10	124	−10 %	0,205	1

Le coude est à k = 4 : passer à 3 puis à 4 groupes fait baisser l'inertie de 20 % puis 18 %, alors qu'au-delà chaque groupe supplémentaire ne la fait plus baisser que de 10 à 12 %. La silhouette y fait aussi un pic local (0,315, mieux que k = 3 et k = 5). Elle est plus haute à k = 2 (0,358), mais ce découpage se contente de séparer les grandes villes et la Méditerranée du reste de la France : trop grossier pour apprendre quelque chose. À partir de k = 6, un groupe ne contient plus qu'un seul département, toujours la Guadeloupe : le k-means isole un cas extrême au lieu de former un profil, ce qui écarte ces valeurs de k. Nous retenons donc **k = 4**, le seul point où les deux méthodes s'accordent sans qu'un groupe se réduise à un département.

3.4 Lire les 4 groupes 4 min

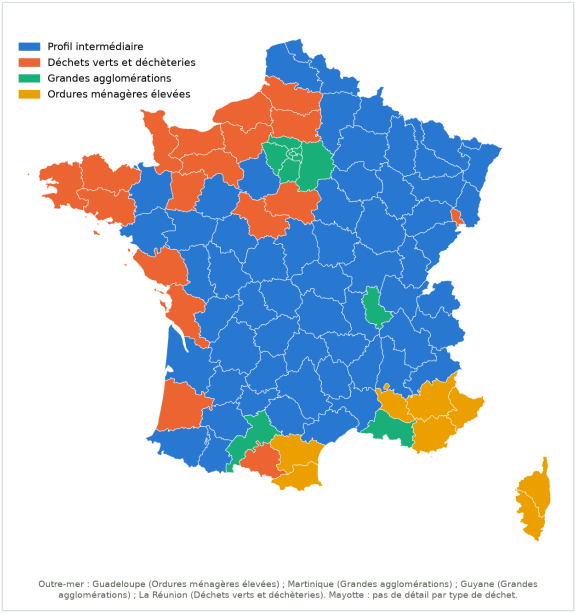
Chaque groupe a un profil net, que montre la figure en indice 100 (100 = moyenne des 100 départements), et la table en kg par habitant.



Profils des 4 groupes. Indice 100 = moyenne des 100 départements.

GROUPE	DÉP.	OMR	RECYCL.	VERTS	ENCOMB.	DANG.	TOTAL	SILH.
Profil intermédiaire	59	217	144	80	74	11	528	0,39
Déchets verts et déchèteries	19	226	145	151	93	12	629	0,14
Grandes agglomérations	13	275	67	42	64	3	456	0,34
Ordures ménagères élevées	9	361	120	82	95	12	674	0,16
Moyenne nationale	100	239	132	88	78	10		

kg par habitant. Total hors gravats, issu du fichier « chiffres-clés ».



Carte des 4 groupes. Aucune information géographique n'a été donnée au modèle.

Le résultat le plus frappant est que ces groupes dessinent une géographie, alors que le modèle n'a reçu que des kilos de déchets : ni région, ni coordonnées. Pour interpréter les groupes, nous les avons confrontés à des variables qui n'ont *pas* servi à les former, ce qui évite le raisonnement circulaire.

GROUPE	POPULATION MOYENNE	REVENU MÉDIAN	INCINÉRATION	STOCKAGE	VALORISATION ORGANIQUE
Profil intermédiaire	562 000	21 900 €	21 %	22 %	15 %
Déchets verts et déchèteries	592 000	21 700 €	21 %	18 %	22 %
Grandes agglomérations	1 407 000	23 000 €	49 %	16 %	9 %
Ordures ménagères élevées	500 000	20 700 €	20 %	37 %	11 %

Profil intermédiaire

59 dép.

C'est la France « moyenne » : Centre, Est, Massif central et une grande partie du Sud-Ouest (Haute-Loire, Gers, Ain, Isère, Nord, Gironde, Bas-Rhin…). Toutes les quantités sont proches de la moyenne, avec un peu moins d'ordures ménagères et un peu plus de recyclables. C'est le groupe le plus cohérent, avec la silhouette la plus élevée (0,39).

Déchets verts et déchèteries

19 dép.

Surtout le Grand Ouest : Bretagne, Normandie et la façade atlantique jusqu'aux Landes. Les déchets verts y sont 1,7 fois plus élevés que la moyenne (151 kg/hab, 280 dans les Landes) et les encombrants sont eux aussi au-dessus : ce sont des déchets apportés en déchèterie, typiques d'un habitat en maisons avec jardin. C'est aussi le groupe qui composte le plus (22 % de valorisation organique) : le traitement suit ce qui est collecté. L'habitat individuel reste une hypothèse, que nos données ne permettent pas de vérifier.

Grandes agglomérations

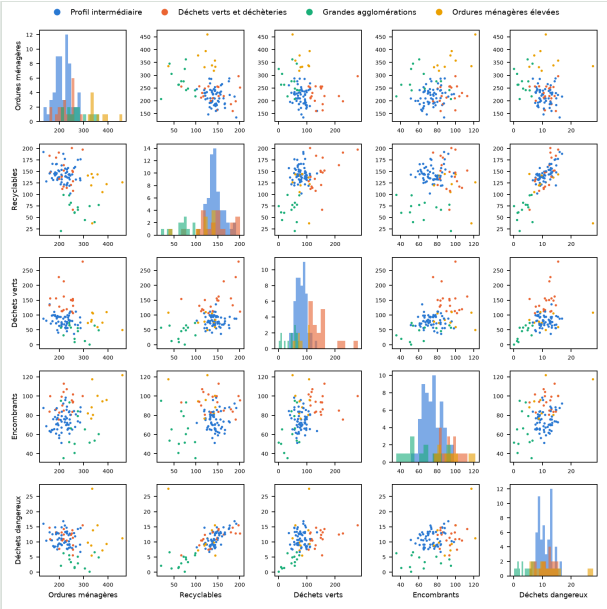
13 dép.

Les 8 départements d'Île-de-France, plus ceux de Lyon, Marseille et Toulouse. Ils produisent le moins au total (456 kg/hab) mais trient peu : deux fois moins de recyclables et de déchets verts que la moyenne, trois fois moins de déchets dangereux. Ce sont les plus peuplés (1,4 million d'habitants en moyenne), les plus aisés, et ceux qui incinèrent le plus (49 %). Lecture : habitat collectif, pas de jardin, peu d'accès aux déchèteries, donc ce qui n'est pas trié part dans la poubelle ordinaire puis à l'incinérateur. La Martinique et la Guyane les rejoignent pour une autre raison, le peu de tri et de déchets verts collectés : le nom du groupe décrit la majorité de ses membres, pas chacun d'eux.

Ordures ménagères élevées

9 dép.

Le pourtour méditerranéen et la Corse (Var, Alpes-Maritimes, Pyrénées-Orientales, Vaucluse, Aude, Corse-du-Sud, Haute-Corse…), plus la Guadeloupe. Les ordures ménagères y sont 1,5 fois plus élevées que la moyenne (361 kg/hab, 459 en Corse-du-Sud) et c'est le groupe qui produit le plus au total (674 kg/hab). C'est aussi celui qui stocke le plus (37 %, près du double des autres) et dont le revenu médian est le plus bas. Hypothèse : le tourisme, car le ratio est calculé avec la population résidente alors que les touristes produisent des déchets sans être comptés. C'est la même piste que celle ouverte par l'analyse des erreurs du modèle supervisé, où la Corse était le département le plus mal prédit.



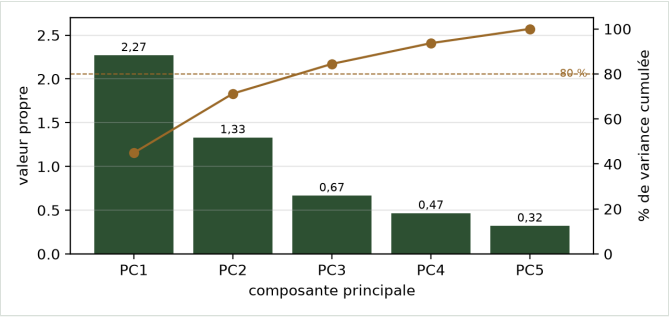
Les 5 variables deux à deux, colorées par groupe : les agglomérations (vert) se détachent par le tri, la Méditerranée (jaune) par les ordures ménagères, l'Ouest (orange) par les déchets verts.

3.5 Réduire la dimension : la PCA 2 min

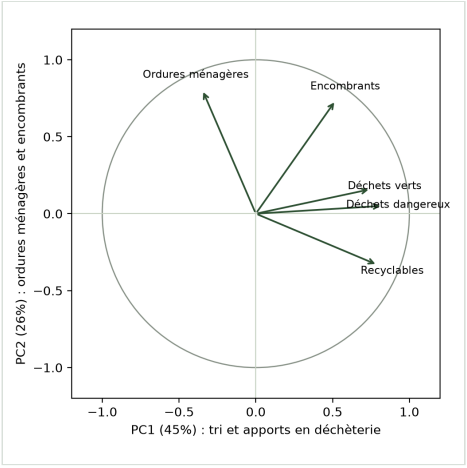
Avec 5 variables, on ne peut pas dessiner les départements dans un plan sans perdre quelque chose. L'analyse en composantes principales (PCA) transforme les 5 variables corrélées en nouvelles variables, les composantes PC1, PC2, PC3..., non corrélées entre elles et triées par quantité d'information. Les étapes sont la standardisation, la matrice de covariance (égale à la matrice de corrélation sur des données standardisées), le calcul des valeurs et vecteurs propres, le choix des composantes, puis la projection.

COMPOSANTE	VALEUR PROPRE	VARIANCE	CUMUL
PC1	2,27	44,9 %	44,9 %
PC2	1,33	26,3 %	71,3 %
PC3	**0,67**	**13,2 %**	**84,4 %**
PC4	0,47	9,2 %	93,7 %
PC5	0,32	6,3 %	100 %

Nous gardons **3 composantes** : l'éboulis des valeurs propres fait un coude après PC3, et la règle des 80 à 90 % de variance expliquée est atteinte (84 %). Le plan PC1-PC2 (71 %) sert aux dessins, complété par le plan PC1-PC3. Le sens des composantes se lit dans leurs chargements, c'est-à-dire la corrélation de chaque variable avec elles : PC1 (45 %) oppose le tri et les apports en déchèterie (recyclables 0,79, déchets dangereux 0,83, déchets verts 0,75) à la poubelle ordinaire ; PC2 (26 %) est le volume d'ordures ménagères (0,81) et d'encombrants (0,74) ; PC3 (13 %) distingue les déchets verts (0,55) du tri des emballages et des déchets dangereux.

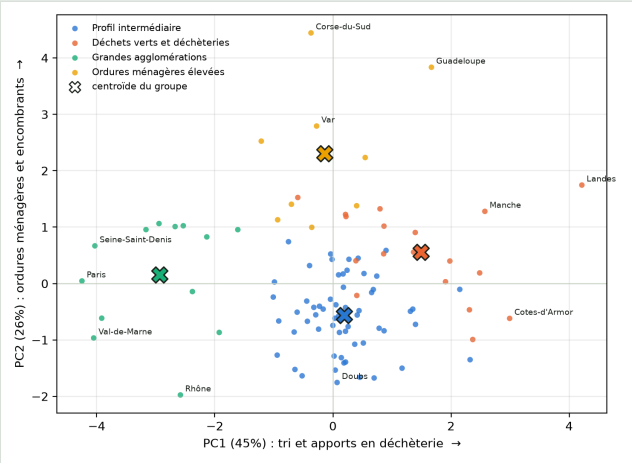


Éboulis des valeurs propres.

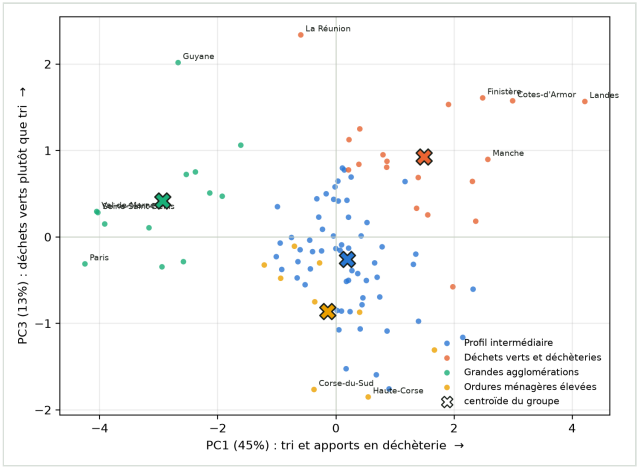


Cercle des corrélations.

Projetés sur ces axes, les groupes occupent chacun leur zone : les agglomérations à gauche (peu de tri), l'Ouest à droite, la Méditerranée en haut. Le plan PC1-PC3 sépare en plus l'Ouest (en haut) de la Méditerranée (en bas). La PCA confirme ainsi, par une autre voie, que les 4 groupes ne sont pas un artefact du k-means.



Plan PC1-PC2 avec les centroïdes (croix).



Plan PC1-PC3.

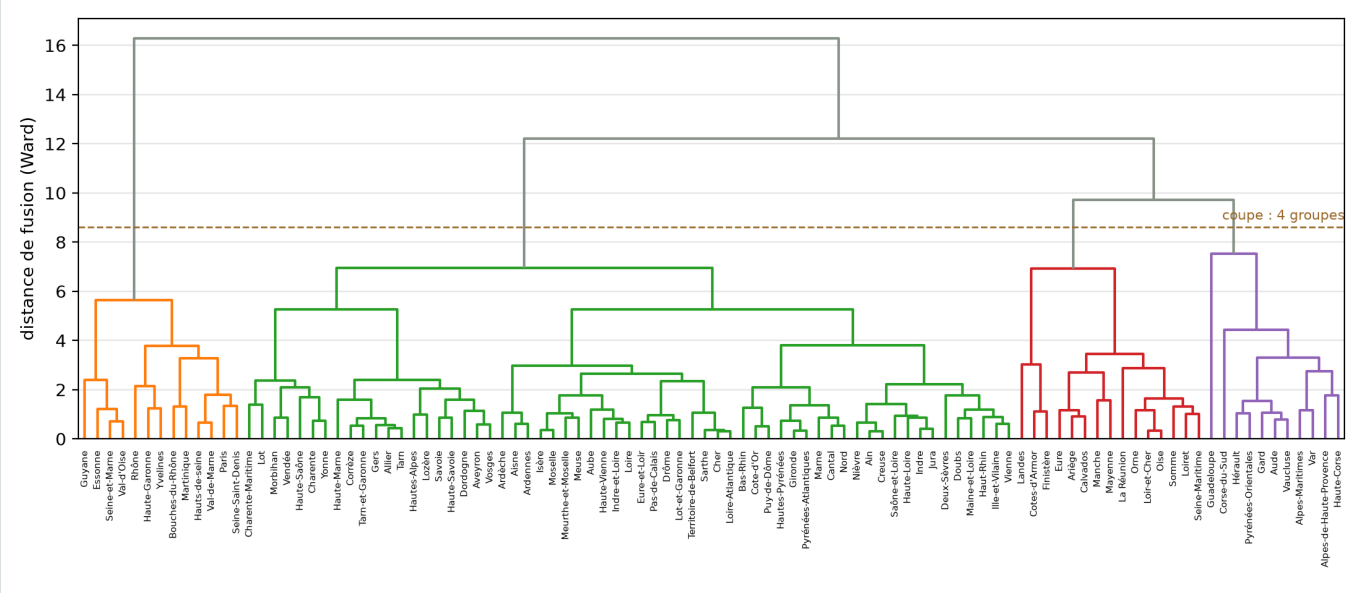
3.6 Ces groupes sont-ils solides ? 2 min

Trouver des groupes ne suffit pas : encore faut-il qu'ils ne dépendent ni du hasard ni de la méthode. Nous avons donc comparé notre découpage à d'autres, avec l'indice de Rand ajusté (ARI), qui vaut 1 si deux découpages forment exactement les mêmes groupes et environ 0 s'ils n'ont pas plus de points communs qu'un tirage au hasard.

ESSAI	ARI AVEC NOS 4 GROUPES	SILHOUETTE
k-means relancé avec 10 autres graines	de 0,81 à 1,00	de 0,312 à 0,319
Clustering hiérarchique (Ward)	0,82	0,315
k-means sans l'outre-mer (96 départements)	0,65	0,291
Clustering du traitement (partie supervisée)	0,006	—

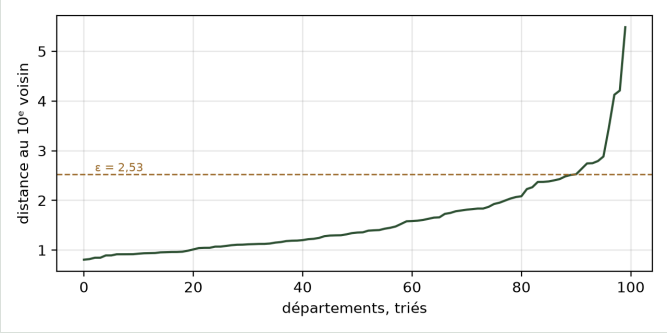
D'une graine à l'autre, les groupes restent très proches et seule la frontière du groupe « déchets verts » bouge ; les agglomérations et la Méditerranée sont identiques. Le clustering hiérarchique les retrouve aussi : il part de chaque département isolé et fusionne à chaque étape les deux groupes les plus proches, et son dendrogramme montre de grands sauts de hauteur jusqu'à 4 groupes (4,07, puis 2,50, puis 2,19) qui s'effondrent ensuite (0,58, puis 0,02). Quatre est donc la coupe la plus fine qui ait encore un sens, ce

qui confirme le choix de k. Sans l'outre-mer, les agglomérations restent stables mais le groupe « ordures ménagères élevées » s'élargit à des départements du Nord et de Normandie : les départements d'outre-mer, aux valeurs extrêmes, déplacent les frontières sans changer le cœur des groupes. Enfin, l'ARI de 0,006 avec le clustering du traitement montre que production et traitement sont des découpages indépendants, ce qui justifie de ne pas les avoir mélangés.

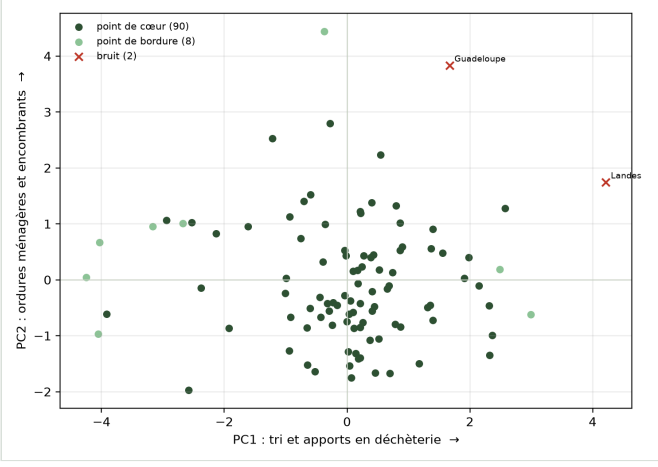


Dendrogramme (liaison de Ward).

DBSCAN, qui regroupe les points situés dans des zones denses, apporte un enseignement plus nuancé. Avec MinPts = 10 (deux fois le nombre de variables) et ε = 2,53 choisi au coude de la courbe des k-distances, il ne trouve qu'**un seul groupe dense** (90 points de cœur, 8 de bordure) et classe 2 départements comme bruit : les Landes (record de déchets verts) et la Guadeloupe (record d'ordures ménagères avec très peu de tri). Aucun réglage testé ne donne plus d'un groupe. Les départements forment donc un continuum, un seul nuage plus dense au centre, pas des îlots séparés par des zones vides. C'est cohérent avec la silhouette modérée du k-means : les 4 profils sont des découpages utiles d'un même nuage, pas des catégories naturelles. DBSCAN reste l'outil adapté pour repérer les cas hors norme, ceux qui tirent le plus les centres du k-means.

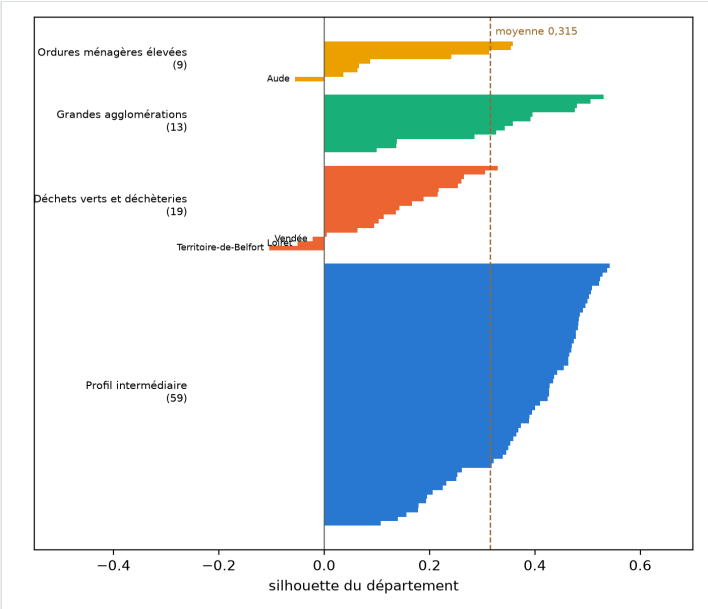


Courbe des k-distances.



DBSCAN : un groupe et deux points de bruit.

La silhouette par département précise où les groupes sont fragiles. Le profil intermédiaire (0,39) et les agglomérations (0,34) sont cohérents ; « déchets verts » (0,14) et « ordures ménagères élevées » (0,16) le sont moins, et quatre départements ont une silhouette négative, c'est-à-dire qu'ils seraient presque aussi bien dans un autre groupe : l'Aude, le Loiret, la Vendée et le Territoire-de-Belfort. Ce sont des cas frontières, à ne pas sur-interpréter.



Silhouette de chaque département, par groupe.

PARTIE 4 · 5 MIN **Prise de recul : conclusions, limites, pistes**

Ce qu'il faut retenir

Les deux volets racontent la même chose vue sous deux angles. En supervisé, prédire la production de déchets d'un département revient presque à recopier l'enquête précédente : les modèles apprennent cette règle (R^2 de 0,716 contre 0,702) sans en savoir plus. En non supervisé, les départements se répartissent en 4 profils, choisis parce que le coude et la silhouette s'accordent sur k = 4 et confirmés par le clustering hiérarchique. Ces profils sont géographiques alors que le modèle n'a reçu que des kilos de déchets, et deux facteurs semblent structurer la carte : le type d'habitat et le tourisme.

Les deux volets se complètent. Les profils expliquent *pourquoi* les niveaux diffèrent durablement d'un territoire à l'autre, la prédiction montre que ces niveaux bougent peu. Aucun profil n'est « meilleur » qu'un autre : les agglomérations produisent le moins mais trient le moins, l'Ouest produit beaucoup mais surtout des déchets verts qu'il composte. Le total seul ne suffit pas à juger un territoire, et chaque profil appelle une action différente : améliorer le tri en habitat collectif dans les agglomérations, développer le compostage de proximité dans l'Ouest, adapter la collecte aux pics touristiques en Méditerranée.

Prise de recul : ce qui manque au modèle

Une erreur commune à tous les départements

Le modèle suppose que chaque département fera « à peu près comme la dernière fois ». Or ce n'est pas ce qui s'est passé aux deux années de test. En 2021, les départements ont produit en moyenne 21,5 kg/hab de plus qu'à l'enquête précédente, et seuls 11 % ont baissé. En 2023, c'est l'inverse : 43,8 kg/hab de moins en moyenne, et 97 % des départements ont baissé. Le modèle n'a vu venir ni l'un ni l'autre. Il sous-estime donc de 22 kg/hab en 2021 et surestime de 43 kg/hab en 2023, dans presque tous les départements en même temps.

Cela change la nature du problème. Si chaque département se trompait dans son coin, on chercherait ce qui lui est propre (habitat, tourisme, collecte). Ici, tous se trompent dans le même sens la même année : ce qui manque touche toute la France à la fois. C'est ce que nous appelons une **information nationale qui varie dans le temps** : une valeur identique pour tous les départements à une enquête donnée, mais différente d'une enquête à l'autre, comme l'inflation, le pouvoir d'achat ou la consommation des ménages. Nos variables actuelles (population, valeur précédente, profil de traitement) diffèrent d'un département à l'autre mais ne disent rien de l'année : le modèle ne peut pas savoir que 2023 est une année où tout le monde jette moins.

Pour mesurer ce que vaudrait une telle information, nous avons fait une expérience de pensée : supposer connue l'évolution moyenne nationale de l'année à prédire et l'ajouter à la valeur précédente de chaque département. L'erreur moyenne tombe de 36,5 à 19,9 kg/hab et le R^2 passe de 0,70 à 0,88. C'est un plafond, pas un résultat réaliste, puisque cette évolution n'est pas connue à l'avance : une vraie variable nationale n'en capterait qu'une partie. L'écart est pourtant assez grand pour montrer où se trouve l'essentiel de ce qui manque.

> **Hypothèse : le pouvoir d'achat.** Les prix ont fortement augmenté en 2022 et 2023 (contexte général, pas une donnée du projet). Des ménages dont le pouvoir d'achat recule achètent moins, donc jettent moins : cela irait dans le sens d'une baisse simultanée dans presque tous les départements en 2023. Nous ne pouvons pas le vérifier avec nos données, pour trois raisons. Le revenu médian INSEE s'arrête en 2021 et ne couvre pas 2023. Il ne mesure de toute façon pas le pouvoir d'achat, car il ignore les prix. Enfin, le test du script 08 portait sur le niveau de revenu entre départements, pas sur son évolution dans le temps. Pour le tester, il faudrait ajouter une série nationale (inflation, pouvoir d'achat par unité de consommation, consommation des ménages) et regarder si elle réduit l'erreur commune. Avec seulement deux années de test et une valeur par année, une corrélation resterait un indice, pas une preuve : d'autres causes (Covid en 2021, extension des consignes de tri) agissent aux mêmes dates.

Deux départements à regarder de près : Eure-et-Loir et Territoire-de-Belfort

Ce sont les deux départements où la régression se trompe le plus (erreur moyenne de 123 et 110 kg/hab). Voici leur série, avec l'Oise comme point de comparaison.

RATIO DMA (KG/HAB)	2017	2019	2021	2023
Eure-et-Loir	567	513	609	454
Territoire-de-Belfort	524	502	603	479
Oise (comparaison)	569	559	607	492

Nos données montrent que les deux départements montent fortement en 2021 (+96 et +101 kg/hab) puis chutent en 2023 (−155 et −124), alors que leur population varie à peine : c'est la quantité de déchets déclarée qui a changé. Le modèle, qui prédit « comme l'enquête précédente », rate le saut vers le haut puis la chute, d'où ces grosses erreurs. Mais ce mouvement existe presque partout, et l'Oise fait la même chose ; ces deux départements l'amplifient, ce qui ne suffit pas à dire que leurs chiffres sont faux. Nous pouvons seulement conclure que, dans les données dont nous disposons, ces deux séries s'écartent plus que les autres. Savoir si la cause est réelle (changement de collecte, nouvelle déchèterie, événement ponctuel) ou administrative (changement de périmètre ou de méthode de déclaration) demande d'interroger la source.

Limites

Côté supervisé, nous ne disposons que de 8 enquêtes, une tous les 2 ans et rien pour les années paires, et de variables trop stables pour expliquer un changement. Les années de test marquent une rupture (pic en 2021, baisse nette en 2023) dont la cause reste inconnue ; les hypothèses (Covid, extension des consignes de tri, baisse du pouvoir d'achat) ne sont pas vérifiées. Les périmètres diffèrent légèrement : le clustering de traitement inclut les gravats, la cible de régression les exclut, écart documenté et assumé.

Côté non supervisé, la structure est modérée : une silhouette de 0,315 indique des groupes réels mais qui se chevauchent, et DBSCAN ne trouve qu'un seul groupe dense. Deux groupes sont fragiles et quatre départements sont des cas frontières. Le k-means est sensible aux valeurs extrêmes (Landes, Corse-du-Sud, Guadeloupe, Guyane), et les départements d'outre-mer, qui ont probablement d'autres causes, déplacent les frontières (ARI de 0,65 sans eux). Enfin, la moyenne 2019–2021 est une photo et non un film, et les explications (habitat, tourisme) restent des hypothèses.

Pistes d'amélioration

La piste prioritaire : une information nationale qui varie dans le temps

C'est l'amélioration qui promet le plus, parce qu'elle vise la cause principale de l'erreur. Le modèle se trompe surtout d'un même montant dans tous les départements, une année donnée, parce qu'il ignore ce qui change pour l'ensemble du pays d'une enquête à l'autre. Lui donner une valeur nationale annuelle, par exemple l'inflation ou le pouvoir d'achat par unité de consommation (INSEE), lui permettrait de corriger ce décalage commun. Notre expérience de pensée montre le plafond de ce qu'on peut espérer : une erreur divisée par près de deux si l'on connaissait l'évolution nationale exacte. En pratique le gain serait plus faible, et il faudrait vérifier que la variable est connue au moment de prédire, sinon on tricherait.

Des données plus fines, dans le temps et dans l'espace

DANS LE TEMPS	DANS L'ESPACE	PAR ZONE
Des données mensuelles au lieu d'une enquête tous les 2 ans : 12 points par an au lieu d'un demi-point, de quoi voir les ruptures (2021, 2023) et la saisonnalité, notamment touristique.	Des données par ville au lieu du département : on pourrait relier la production à la taille de la ville et repérer des écarts à l'intérieur d'un même département.	Chaque ville serait rattachée à sa zone et à son département : en regroupant les villes, on retrouve le compte rendu départemental et on mesure d'où viennent ses écarts.

> **Le prix à payer.** Ces données n'existent pas dans les bases publiques utilisées ici. Les obtenir demande davantage de moyens : un recueil mensuel auprès de chaque collectivité qui collecte, avec un format commun. Le bénéfice attendu est une meilleure gestion des déchets et une vue sur les écarts entre territoires, que les moyennes départementales cachent.

Autres pistes

Des variables locales qui évoluent (tarification incitative, extension des consignes de tri, part de population urbaine) compléteraient l'information nationale. Des variables INSEE sur le logement et le tourisme permettraient de vérifier les hypothèses d'habitat et de tourisme et de corriger le biais corse. Les séries d'Eure-et-Loir et de Territoire-de-Belfort sont à vérifier à la source avant d'être corrigées ou exclues, et l'outre-mer gagnerait à être traité à part, avec ses propres variables.

Reproduire

Sur Ubuntu : `sudo apt install git make python3 python3-venv`, puis `git clone https://github.com/Rxdy/ML-DMA.git`, `make installer` et `make all`. Sans rien installer, le notebook s'ouvre dans Google Colab.